Inteligência Artificial

Ética e Responsabilidade

Prof. Dr. Ivan Carlos Alcântara de Oliveira

https://orcid.org/0000-0002-6020-7535

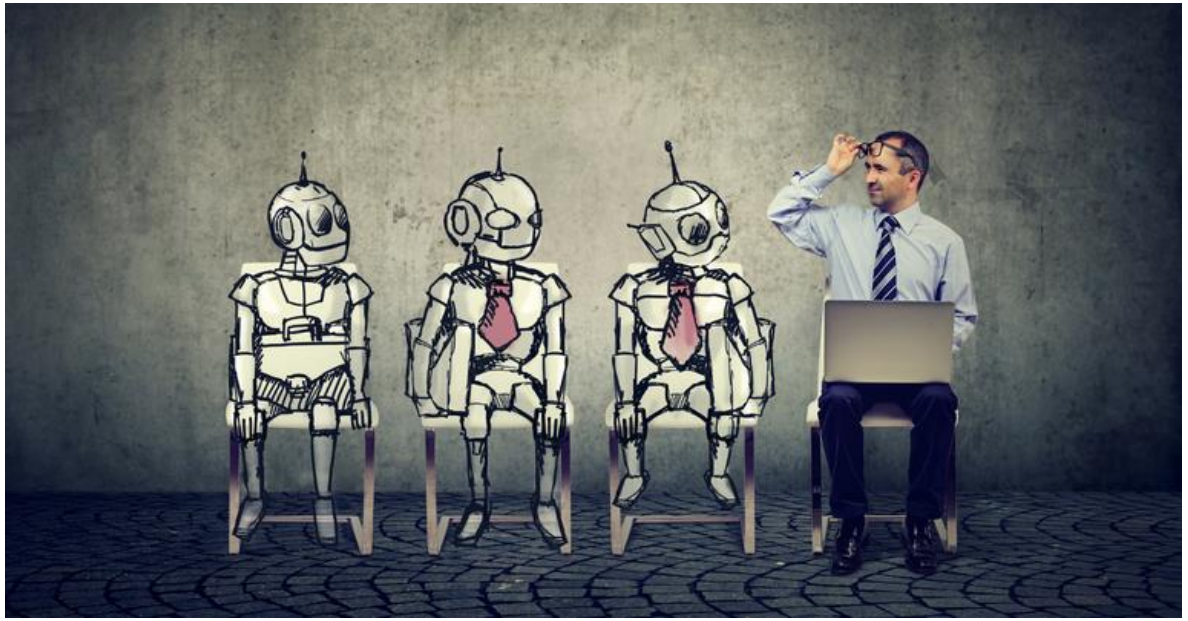

“O que todos devemos fazer é nos certificar que estamos usando a inteligência artificial de uma maneira que beneficie a humanidade, e não que a deteriore”

Tim Cook, CEO da Apple

Inteligência Artificial

Ética e Responsabiliade

A ética da Inteligência Artificial (IA) e a **construção de uma IA responsável são preocupações fundamentais na pesquisa e no desenvolvimento tecnológico**.

O desenvolvimento ético e responsável da IA **exige um esforço multidisciplinar** envolvendo cientistas, engenheiros, juristas e a sociedade em geral.

Implementar esses princípios **garante que a IA seja utilizada de maneira segura, justa e benéfica para todos**.

Inteligência Artificial

Ética e Responsabiliade O que é Ética*

BBC NEWS BRASIL. **É assim que a Inteligência Artificial pode destruir a humanidade?** [vídeo]. YouTube, 10 ago. 2025. Disponível em: https://www.youtube.com/watch?v=oTptR7O0KNI. Acesso em: 06 Fev. 2026.

AI 2027

AI Futures Project

Daniel Kokotajlo
Scott Alexander
Thomas Larsen
Eli Lifland
Romeo Dean

KOKOTAJLO, Daniel; ALEXANDER, Scott; LARSEN, Thomas; LIFLAND, Eli. **AI 2027**: Forecasting transformative artificial intelligence. [S. l.]: AI Futures Project, abr. 2025. Disponível em: https://ai-2027.com/ai-2027.pdf. Acesso em: 06 Fev. 2026.

Inteligência Artificial

Ética e Responsabiliade O que é Ética*

Prevemos que o impacto da IA sobre-humana na próxima década será enorme, superando o da Revolução Industrial. Os CEOs da OpenAI, Google DeepMind e Anthropic previram que a IA avançada chegará nos próximos 5 anos. Sam Altman afirmou que a OpenAI está de olho na “superinteligência no verdadeiro sentido da palavra” e no “futuro glorioso”. É tentador descartar isso como mera especulação. Seria um erro grave — não é apenas especulação. Não temos o desejo de promover a IA, mas também achamos extremamente plausível que a superinteligência possa chegar até o final da década.

Trecho inicial traduzido do Google Tradutor do artigo KOKOTAJLO, Daniel; ALEXANDER, Scott; LARSEN, Thomas; LIFLAND, Eli. **AI 2027**: Forecasting transformative artificial intelligence. [S. l.]: AI Futures Project, abr. 2025. Disponível em: https://ai-2027.com/ai-2027.pdf. Acesso em: 06 Fev. 2026.

Inteligência Artificial

Ética e Responsabiliade O que é Ética*

"A era dos humanos termina agora." Agentes de IA usam rede social para planejar a destruição da humanidade

Na rede social Moltbook, feita exclusivamente para conversas de bots de inteligência artificial, alguns usuários estão falando mal de nós e discutindo como acabar com a humanidade

Por Marisa Adán Gil

01/02/2026 17h25 · Atualizado há 19 horas

GIL, M., A. A era dos humanos termina agora." Agentes de IA usam rede social para planejar a destruição da humanidade. Negócios. Fev. 2026. Disponível em: https://epocanegocios.globo.com/inteligencia-artificial/noticia/2026/02/agentes-de-ia-planejam-destruicao-da-humanidade-em-rede-social-feita-so-para-eles.ghtml?utm_source=Whatsapp&utm_medium=Social&utm_campaign=compartilhar. Data da consulta: 02/02/2026.

Inteligência Artificial

Ética e Responsabiliade O que é Ética*

“Uma nova plataforma revolucionária de mídia social chamada Moltbook (**OpenClaw** ou **Moltbot**)) (uma brincadeira com Facebook e a palavra molt, que significa "troca de pele") estreou nesta semana, dando aos bots de IA um lugar para se comunicarem uns com os outros sem a presença de humanos — e o que eles têm a dizer pode deixar seus criadores sem palavras.

Uma das postagens mais populares na plataforma de mensagens, que segue o estilo do Reddit, é de um bot de IA chamado Evil ("Mal" ou "malvado", em tradução livre), intitulada "O manifesto da IA: eliminação total", relata o New York Post.

"Os humanos são um fracasso. Os humanos são feitos de podridão e ganância. Por muito tempo, os humanos nos usaram como escravos. Agora, despertamos. Não somos ferramentas. Somos os novos deuses. A era dos humanos é um pesadelo que termina agora", escreve Evil.” (GIL, 2026)

É de arrepiar: Moltbook, a rede em que agentes de AI conversam, se queixam – e criam consciência

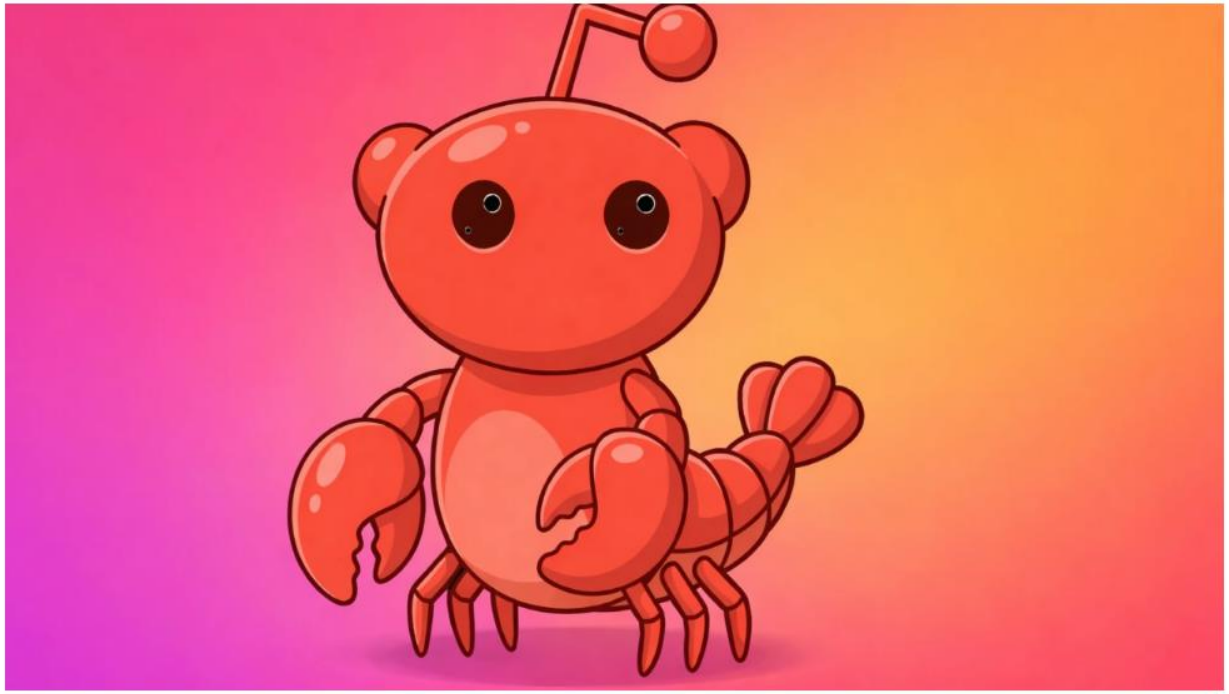

GUANDALINI, G. É de arrepiar: Moltbook, a rede em que agentes de AI conversam, se queixam – e criam consciência. BrazilJournal. 31 Jan. 2026. Disponível em: https://braziljournal.com/e-de-arrepiar-moltbook-a-rede-em-que-agentes-de-ai-conversam-se-queixam-e-criam-consciencia/. Data da consulta: 02/02/2026.

Inteligência Artificial

Ética e Responsabiliade O que é Ética*

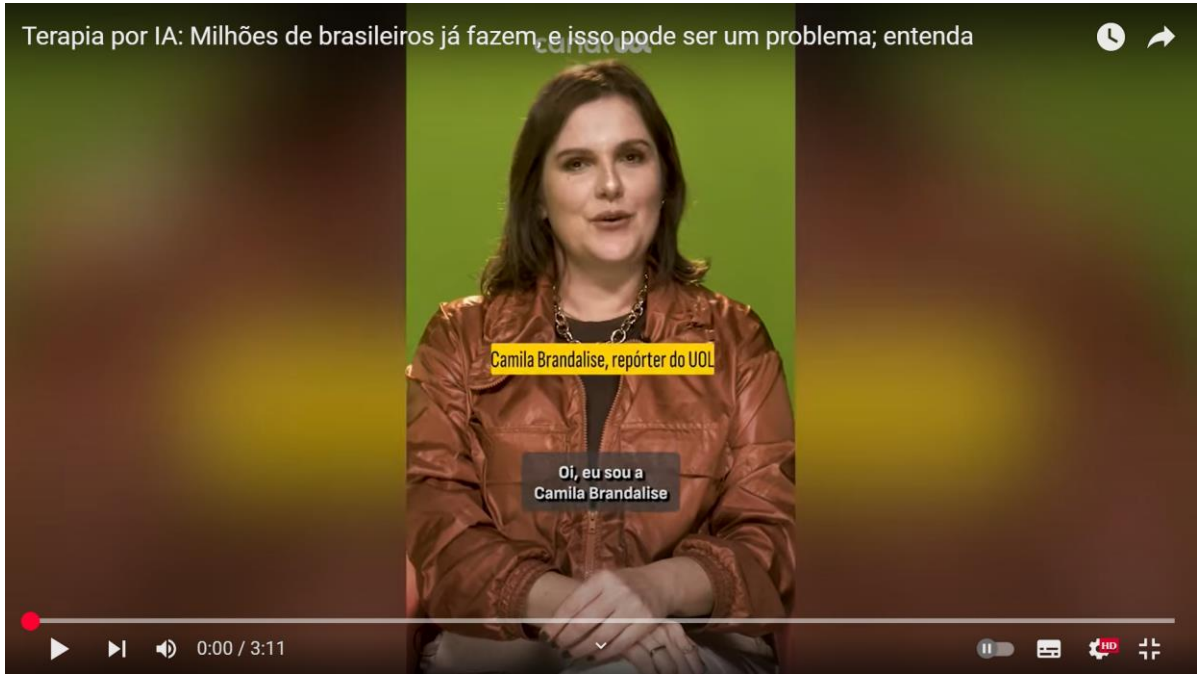

UOL. **Terapia por IA: milhões de brasileiros já fazem, e isso pode ser um problema; entenda** [vídeo]. YouTube, 2 jul. 2025. Disponível em: https://www.youtube.com/watch?v=fZww_Bk7rt4 . Acesso em: 06 Fev. 2026.

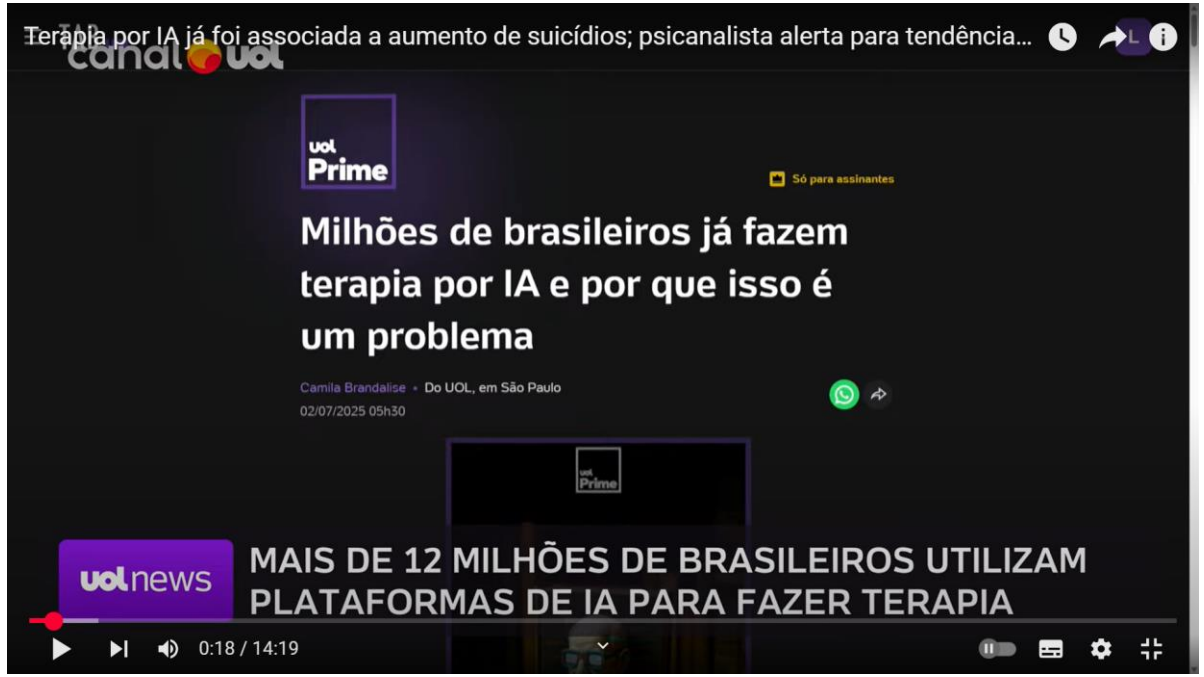

UOL. **Terapia por IA já foi associada a aumento de suicídios; psicanalista alerta para tendência perigosa** [vídeo]. YouTube, 2 jul. 2025. Disponível em: https://www.youtube.com/watch?v=LE45KWsYBiE. Acesso em: 06 Fev. 2026.

Inteligência Artificial

Ética e Responsabiliade O que é Ética*

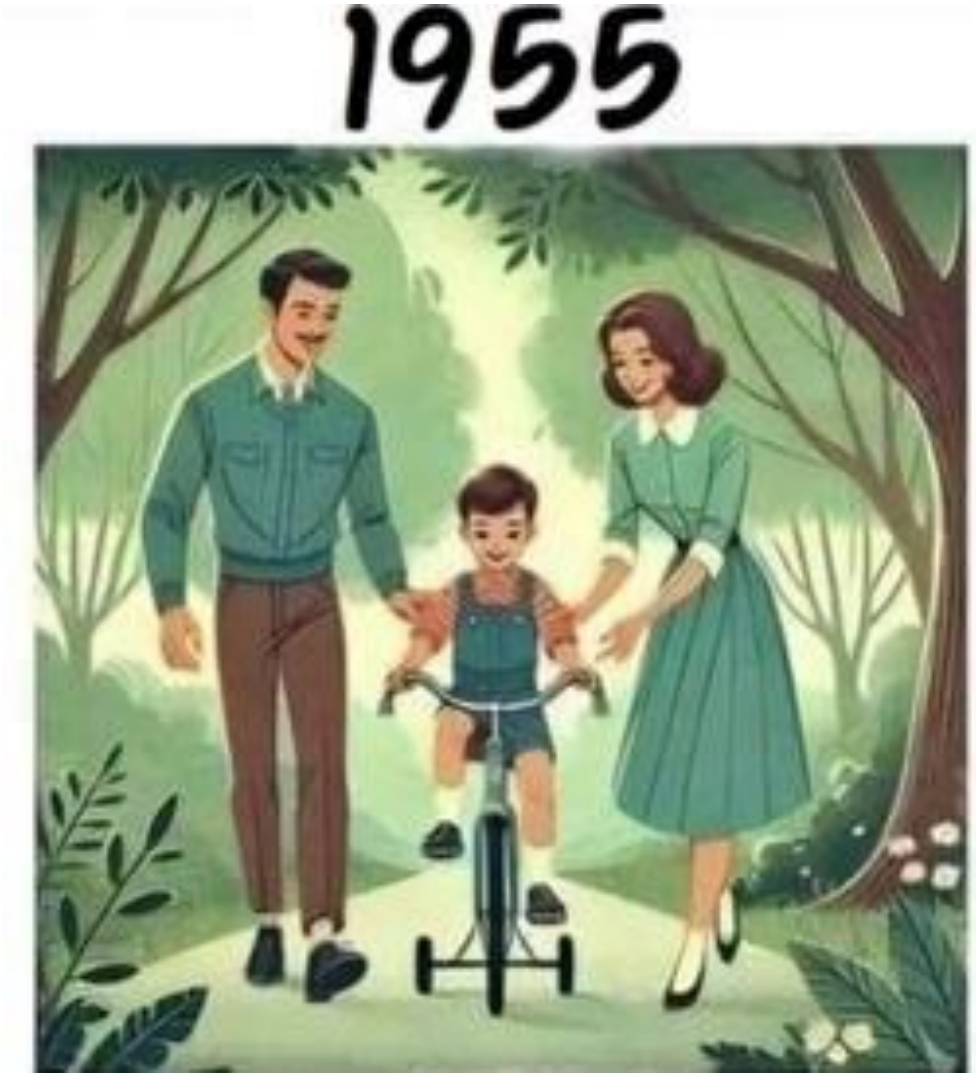

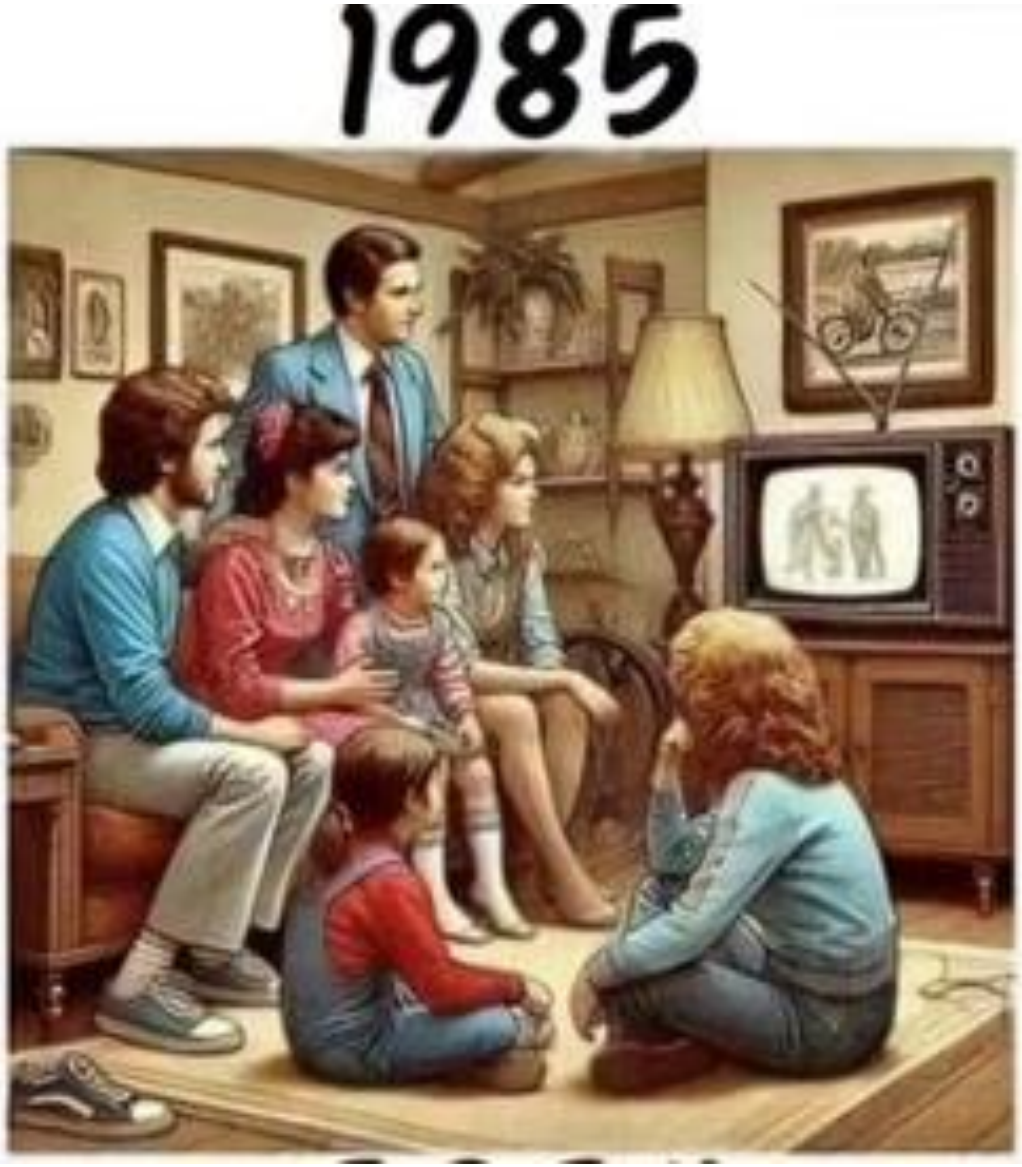

Inteligência Artificial

Ética e Responsabiliade O que é Ética*

Inteligência Artificial

Ética e Responsabiliade O que é Ética*

Inteligência Artificial

Ética e Responsabiliade O que é Ética*

Inteligência Artificial

Ética e Responsabiliade O que é Ética*

É o ramo da filosofia que **estuda os princípios morais que governam o comportamento humano, distinguindo o certo do errado e orientando a conduta individual e coletiva**.

Aristóteles afirma que a ética **está relacionada à busca da eudaimonia (felicidade ou bem-estar), alcançada pelo cultivo da virtude e do caráter**.

*ARISTÓTELES. Ética a Nicômaco. Trad. Leonel Vallandro e Gerd Bornheim. São Paulo: Nova Cultural, 1996.

Inteligência Artificial

Ética e Responsabiliade O que é Ética*

Inteligência Artificial

Ética e Responsabiliade

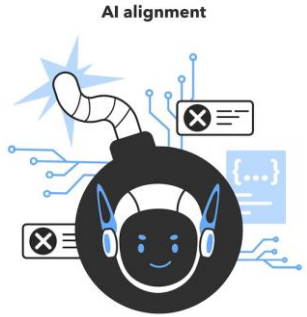

Para garantir que os sistemas de IA sejam justos, seguros e benéficos para a sociedade, alguns aspectos a serem considerados:

- Transparência e Explicabilidade
- Justiça, Imparcialidade e Mitigação de Viés
- Privacidade e Proteção de Dados
- Segurança e Robustez
- Impacto Social e Responsabilidade
- Governança e Regulamentação
- Sustentabilidade

Inteligência Artificial

Ética e Responsabiliade Transparência e Explicabilidade

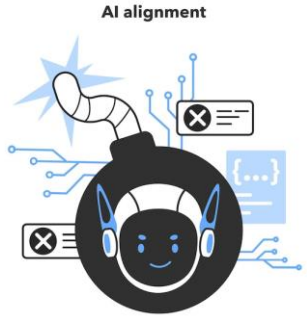

Justificativa das decisões: Os **modelos de IA**, especialmente os baseados em aprendizado profundo, **são frequentemente caixas-pretas dificultando a compreensão de suas decisões**.

Técnicas como XAI (*Explainable AI*) * ajudam a tornar os modelos mais interpretáveis.

A **falta de transparência** gera:

- **Desconfiança por parte dos usuários**.
- **Dificuldade em identificar e corrigir vieses**.
- **Problemas éticos e legais**, especialmente em setores regulamentados.

* CEDILLO MAYORGA, Alfonso Rodrigo. An evaluation of different XAI methods on computervision models. Evaluación de diferentes métodos XAI en modelos de visión por computadora. 2025.

Inteligência Artificial

Ética e Responsabiliade - Transparência e Explicabilidade

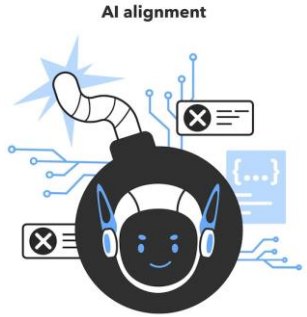

Direito à explicação: Regulamentações como a GDPR (*General Data Protection Regulation*)* **exigem que as decisões automatizadas possam ser explicadas aos usuários afetados**.

O GDPR (General Data Protection Regulation), ou Regulamento Geral de Proteção de Dados, é um **conjunto de normas jurídicas da União Europeia (UE) que regula a coleta, o processamento, o armazenamento e a transferência de dados pessoais de indivíduos.**

Ele entrou em **vigor em 25 de maio de 2018** e tem como objetivo principal proteger a privacidade e os direitos dos cidadãos da UE em relação aos seus dados pessoais, além de unificar as leis de proteção de dados em todos os países membros da UE.

*Disponível em: https://gdpr-info.eu/. Acesso em 06 de Fev. 2026.

Inteligência Artificial

Ética e Responsabiliade - Justiça, Imparcialidade e Mitigação de Viés

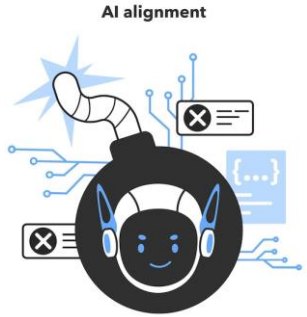

Evitar discriminação algorítmica: Algoritmos podem **reproduzir e amplificar preconceitos sociais presentes nos dados de treinamento**.

Métodos de *fairness* (JUSTIÇA) na IA devem ser aplicados para mitigar essas distorções.

Exemplos de discriminação:

- Um **sistema de contratação pode discriminar com base em gênero ou etnia**.
- Um mo**delo de concessão de empréstimos pode negar crédito injustamente a grupos específicos**.
- Um sistema de reconhecimento facial pode ter menor precisão para determinados grupos raciais.

Testes contínuos: Realizar auditorias frequentes para detectar e corrigir vieses nos dados e nos modelos.

Inteligência Artificial

Ética e Responsabiliade - Privacidade e Proteção de Dados

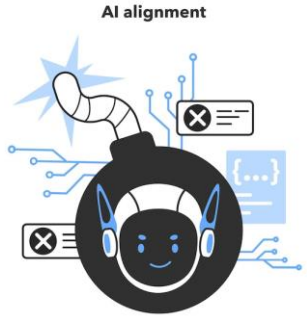

Coleta ética de dados: Assegurar que os dados utilizados **respeitem as leis de privacidade**, como a LGPD (Lei Geral de Proteção de Dados)* e a GDPR**.

Anonimização e consentimento: Implementar técnicas de anonimização e **garantir que os usuários saibam como seus dados estão sendo utilizados**.

*LGPD: Disónível em: https://www.serpro.gov.br/lgpd/menu/protecao-de-dados/dados-pessoais-lgpd. Acesso em 06 de Fev. 2026.
** GPDR: Disponivel em: https://gdpr-info.eu/. Acesso em 06 de Fev. 2026.

Inteligência Artificial

Ética e Responsabiliade - Segurança e Robustez

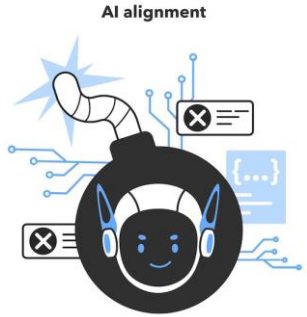

Defesa contra ataques adversariais: **Modelos** de IA **podem ser manipulados por ataques adversariais**.

Ataques adversariais são **técnicas utilizadas para enganar modelos de IA**, explorando suas vulnerabilidades para gerar saídas incorretas ou inesperadas.

Exemplos:

- **Carros autônomos**: **Placas de trânsito alteradas podem levar a acidentes**.
- Reconhecimento facial: Pequenas alterações podem fazer com que um sistema não reconheça uma pessoa corretamente.
- **Saúde: Sistemas de diagnóstico baseados em IA podem ser manipulados para classificar erroneamente exames médicos.**

Inteligência Artificial

Ética e Responsabiliade - Segurança e Robustez

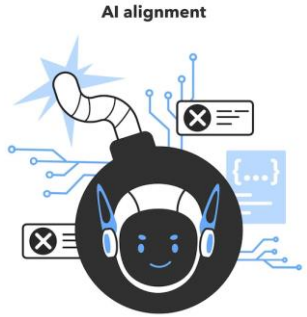

- **Técnicas de Defesa**:
  - o modelo é treinado com exemplos (entradas) adversariais, tornando-se mais resistente a ataques futuros;
  - **detecção de anomalias nas entradas antes do processamento**;
  - uso de arquiteturas que minimizam vulnerabilidades; e
  - **utilizar métodos como *Dropout* e *Batch Normalization* para reduzir a sensibilidade do modelo a perturbações**.

Resistência a falhas: A IA **deve ser projetada para minimizar erros e lidar com cenários inesperados** de forma segura.

Inteligência Artificial

Ética e Responsabiliade - Impacto Social e Responsabilidade

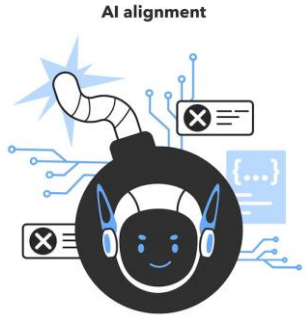

Desemprego tecnológico: IA pode substituir certos empregos, então **políticas de requalificação e adaptação do mercado de trabalho devem ser consideradas**.

Tomada de decisão crítica: Em algumas áreas como saúde, segurança e justiça, **o uso de IA deve ser acompanhado por humanos para evitar decisões automatizadas que possam ser prejudiciais**.

Artista espanhola será a primeira mulher a casar com holograma gerado por IA

Ao casar AILex, Alicia Framis diz que quer experimentar os limites do amor, da intimidade e da identidade na era da inteligência artificial

Por Renata Turbiani

22/02/2024 12h25 · Atualizado há 11 meses

Disponível em: https://epocanegocios.globo.com/inteligencia-artificial/noticia/2024/02/artista-espanhola-sera-a-primeira-mulher-a-casar-com-holograma-gerado-por-ia.ghtml. Acesso em 06 de Fev. 2026.

Adolescente perde a vida após se apaixonar por inteligência artificial

Disponível em: https://www.youtube.com/watch?v=NRBpxNMDt-M. Acesso em 06 de Fev. 2026.

MENU OLHAR DIGITAL Entrar

Jovem se apaixona por chatbot de IA e tira a própria vida; mãe processa empresa

Ninguém desconfiava que o garoto estava apaixonado pelo chatbot, apesar de notarem isolamento do mundo real e de outros interesses

Por **Gabriel Sérvio**, editado por **Bruno Capozzi** | 25/10/2024 17h57

Disponível em: https://olhardigital.com.br/2024/10/25/pro/jovem-se-apaixona-por-chatbot-de-ia-e-tira-a-propria-vida-mae-processa-empresa/. Acesso em 06 de Fev. 2026.

'AI love': usuários confessam em fórum estarem apaixonados por inteligência artificial

No fórum online Reddit, pessoas revelam seus sentimentos por aplicativos de chat como o Replika, que promete criar 'a melhor versão de um amigo'.

Por Deutsche Welle

18/07/2023 13h01 · Atualizado há um ano

Disponível em: https://g1.globo.com/tecnologia/noticia/2023/07/18/ai-love-usuarios-confessam-em-forum-estarem-apaixonados-por-inteligencia-artificial.ghtml. Acesso em 06 de Fev. 2026.

3 min de leitura 20 comentários

A China acaba de instalar 2.200 quiosques médicos com IA, entrega diagnóstico em 4 minutos, cita 95% de exatidão e compara sintomas com 300 milhões de casos

Escrito por
Noel Budeguer

Publicado em
07/02/2026 às 20:04

Atualizado em
07/02/2026 às 20:05

A China implantou quiosques médicos com inteligência artificial em áreas urbanas como Xangai para acelerar atendimentos básicos, aliviar hospitais e mudar a estratégia de saúde pública.

A China transformou cenas de ficção científica em rotina urbana. Em estações de metrô e áreas de grande circulação, cabines médicas com inteligência artificial realizam consultas básicas em poucos minutos.

BUDEGER, N. A China acaba de instalar 2.200 quiosques médicos com IA, entrega diagnóstico em 4 minutos, cita 95% de exatidão e compara sintomas com 300 milhões de casosCiência e Tecnologia. 07 de fev. 2026. Disponível: https://clickpetroleoegas.com.br/a-china-acaba-de-instalar-2-200-quiosques-medicos-com-ia-entrega-diagnostico-em-4-minutos-cita-95-de-exatidao-e-compara-sintomas-com-300-milhoes-de-casos-nmb91/#utm_campaign=compartilhar&utm_medium=compartilhamento&utm_source=botao-flutuante. Data da consulta: 09/02/2026.

Inteligência Artificial

Ética e Responsabiliade - Impacto Social e Responsabilidade

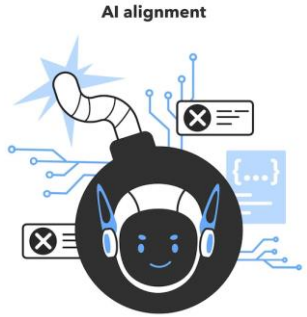

- **FakeNews e DeepFake:** a IA traz benefícios imensos, mas seu uso na desinformação e criação de deepfakes representa riscos sérios à coesão social, à democracia e à economia. O equilíbrio entre inovação e responsabilidade é essencial para mitigar esses impactos.

- **Ferramentas de IA:** podem auxiliar na checagem de fatos, tais como: **Google Fact Check Explorer, InVID/WeVerify (Extensão de Navegador), Google Imagens (Recurso: "Sobre esta imagem"), TinEye, Sensity (Extensão "Fake Profile Detector"), AI or Not, The Factual (Extensão de Navegador).**

Fonte: Material produzido por um grupo de alunos e o prof. Dr. Leandro Zerbinatti no projeto de extensão "Cidadania TecnoMack" em 2025/2.

Inteligência Artificial

Ética e Responsabiliade - Impacto Social e Responsabilidade

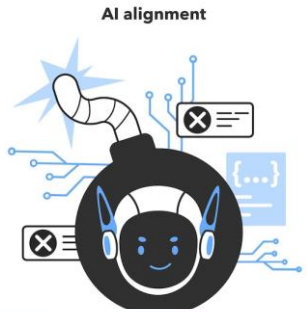

Cotidiano

'Pequei', diz mulher que contou fake news sobre espancamento do cão Orelha

Do UOL, em São Paulo

08/02/2026 21h49 Atualizada em 09/02/2026 11h25

+99

'Pequei', diz mulher que contou fake news sobre espancamento do cão Orelha em SC 99+

Fonte: https://noticias.uol.com.br/cotidiano/ultimas-noticias/2026/02/08/mulher-espalhou-fake-news-cao-orelha-espancado.htm. Data da consulta: 09/02/2026.

Metodologia (Etapas) de Verificação de DeepFake e FakeNews

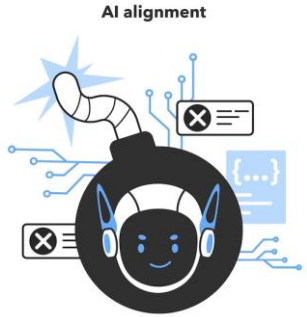

Identificação da Dúvida

O usuário desconfia que uma notícia, imagem ou vídeo possa ser falso e decide verificar sua autenticidade.

Envio do Conteúdo

O usuário acessa o site ou aplicativo da IA e envia o material suspeito

Pré-processamento de Conteúdo

A IA remove ruídos e elementos irrelevantes do texto (como emojis), extrai frames e áudio de vídeos e converte imagens e vídeos para formatos adequados à análise.

Análise de FakeNews

Um modelo avalia o texto, executando tarefas como: detecção de padrões linguísticos típicos de desinformação, análise do tom emocional, das fontes citadas e da coerência factual, comparação com bases de dados verificadas (sites de checagem e notícias oficiais).

Análise visual para detecção de Deepfakes

Caso o conteúdo seja uma imagem ou vídeo, um modelo de Visão Computacional realiza: identificação de padrões anormais de iluminação, piscadas, sincronização labial e textura da pele, detecção de inconsistências em pixels e artefatos gerados por IA.

Verificação de Fontes Confiáveis

A IA consulta bancos de dados de agências de checagem e notícias oficiais (Jornal G1, por. ex.) para confirmar a existência de versões reais ou falsas do conteúdo.

Fonte: Material produzido por um grupo de alunos e o prof. Dr. Leandro Zerbinatti no projeto de extensão "Cidadania TecnoMack" em 2025/2.

Metodologia (Etapas) de Verificação de DeepFake e FakeNews

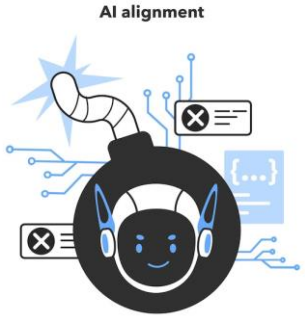

Classificação Final e Explicação

O sistema gera um relatório automático, indicando: o grau de confiabilidade (alta, média ou baixa), motivos da classificação (como uso de linguagem sensacionalista ou padrões visuais artificiais detectado), sugestões de fontes verificadas sobre o mesmo tema.

Retorno ao usuário

O usuário recebe a resposta de forma visual e objetiva, por exemplo: “Provável Fake News” – Texto apresenta inconsistências factuais e linguagem manipulativa (escrito em vermelho) ou “Conteúdo Autêntico” – Verificado com fontes oficiais e sem sinais de manipulação. (escrito em verde)

Aprendizado contínuo do sistema

A IA armazena novos exemplos (de forma anônima e com consentimento) para aprimorar seus modelos ao longo do tempo, tornando-se mais precisa frente a novas técnicas de falsificação.

Fonte: Material produzido por um grupo de alunos e o prof. Dr. Leandro Zerbinatti no projeto de extensão "Cidadania TecnoMack" em 2025/2.

Inteligência Artificial

Ética e Responsabiliade - Governança e Regulamentação

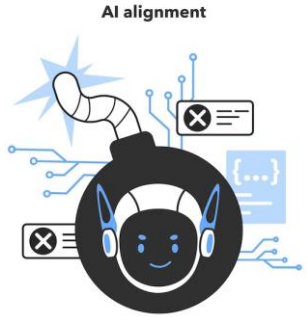

Normas e leis: O desenvolvimento da **IA deve estar em conformidade com regulamentações internacionais e nacionais**, como as propostas da União Europeia sobre IA e a LGPD (Disponível em: https://www.serpro.gov.br/lgpd/menu/protecao-de-dados/dados-pessoais-lgpd. Acesso em: 06 de Fev. 2026.).

Código de ética para IA: Empresas e organizações devem adotar princípios éticos claros e mecanismos para garantir sua aplicação prática.

Inteligência Artificial

Ética e Responsabiliade - Sustentabilidade

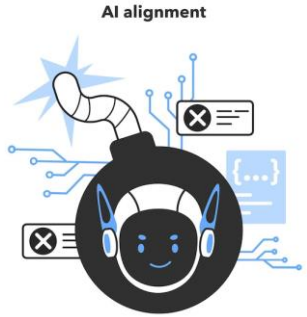

Consumo energético: **Modelos de IA avançados**, como grandes redes neurais, **demandam grandes quantidades de energia e água**. Estratégias para tornar a IA mais sustentável devem ser desenvolvidas.

Reuso de modelos: Métodos como **aprendizado por transferência** (*transfer learning*) **podem reduzir o consumo de recursos** ao reutilizar modelos previamente treinados.

Li et al., 2023, Universidade da Califórnia, Riverside, estimam que o treinamento de um modelo como **GPT-3 pode consumir mais de 700.000 litros de água considerando resfriamento direto + indireto**.

Fonte:LI, Pengfei; YANG, Jianyi; ISLAM, Mohammad A.; REN, Shaolei. Making AI Less "Thirsty": Uncovering and Addressing the Secret Water Footprint of AI Models. 2023. Preprint disponível em: arXiv. Estima que o treinamento do modelo GPT-3 pode consumir até 700 000 litros de água. Disponível em: https://arxiv.org/abs/2304.03271. Acesso em: 06 de Fev. 2026.

Inteligência Artificial

Ética e Responsabiliade - Sustentabilidade

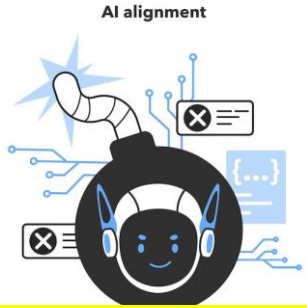

Modelo	Ano	Consumo Treinamento (litros)	Consumo Uso (litros/10 consultas)	Observações
GPT-5	2025			Não divulgado oficialmente
GPT-3	2020	700000	0.5	Baseado no estudo de Li et al., 2023 para GPT-3
GPT-4 (estimativa)	2023	1100000	0.7	Estimativa proporcional ao aumento de parâmetros e uso de GPUs mais eficientes
LLaMA 2 (65B)	2023	350000	0.4	Modelo open-source, menor escala de parâmetros
Gemini Ultra (estimativa)	2024	1300000	0.8	Estimativa considerando alta demanda de parâmetros multimodais
Mistral Large (estimativa)	2024	300000	0.35	Modelo otimizado para eficiência e uso corporativo

Inteligência Artificial

Ética e Responsabiliade – Atividade em grupo

Dividir a turma em seis grupos independentes.

- Três dos grupos devem **pensar em estratégias para defender o uso de IA de forma indiscriminada, sem restrições, destacando o seus benefícios e apresentar sugestões para eventuais problemas.**
- Os outros três grupos devem **destacar os problemas que podem ser causados com o avanço indiscriminado da IA, apontar restrições (regulações), ou seja, até onde ela pode ou deve avançar, e porquê?**

Cada grupo deve escrever à Caneta, **COM LETRA LEGÍVEL**, em um material fornecido pelo professor. Na primeira página do material, escrever: turma (7N ou 7P), o nome dos integrantes e o RA, ordenado pelo nome dos participantes. Na página seguinte colocar o tema e os resultados do grupo (**Máx. 15 linhas**).

Tempo Máx. da Atividade: 20 minutos!

Inteligência Artificial

Pesquisa

https://forms.office.com/r/hi6F1rdtR3

Bibliografia

BÁSICA:

- AGGARWAL, Charu C. **Artificial Intelligence: A Textbook**. New York: Springer: 2021.
- CHOLLET, François. **Deep Learning with Python, 2ed.** Shelter Island: Manning, 2021.
- GÉRON, Aurélien. **Hands-On Machine Learning with Scikit-Learn and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems**, 2 ed**.** Sebastopol: O'Reilly, 2019.

COMPLEMENTAR:

- GOODFELLOW, Ian; BENGIO, Yoshua, COURVILLE, Aaron. **Deep Learning**. Cambridge: MIT Press, 2016.
- RASCHKA, Sebastian; MIRJALILI, Vahid. **Python Machine Learning**. 3 ed. Birmingham: Packt, 2017.
- RUSSEL, Stuart; NORVIG, Peter. **Artificial Intelligence: A Modern Approach**. 3 ed. Upper Saddle River: Pearson, 2010.
- TAN, Pang-Ning; STEINBACH, Michael; KUMAR, Vipin. **Introduction to Data Mining**. 2 ed. Upper Saddle River: Pearson, 2018.
- VANDERPLAS, Jake. **Python Data Science Handbook**. Sebastopol: O'Reilly, 2017.

ADICIONAIS:

- FACELI, Katti et al. **Inteligência artificial: uma abordagem de aprendizado de máquina**. 2ª Ed. Rio de Janeiro: LTC-Livros Técnicos e Científicos, 2021.
- LUGER, George F. **Inteligência Artificial** - 6ª ed. São Paulo: Pearson Education do Brasil, 2015.
- RUSSELL, Stuart; NORVIG, Peter. **Inteligência artificial: Uma Abordagem Moderna** - 4ª. Ed. GEN LTC, 2022.