Inteligência Artificial

Compreensão e Análise Exploratória dos dados por meio da Estatística e da Visualização – Parte I

Prof. Dr. Ivan Carlos Alcântara de Oliveira

https://orcid.org/0000-0002-6020-7535

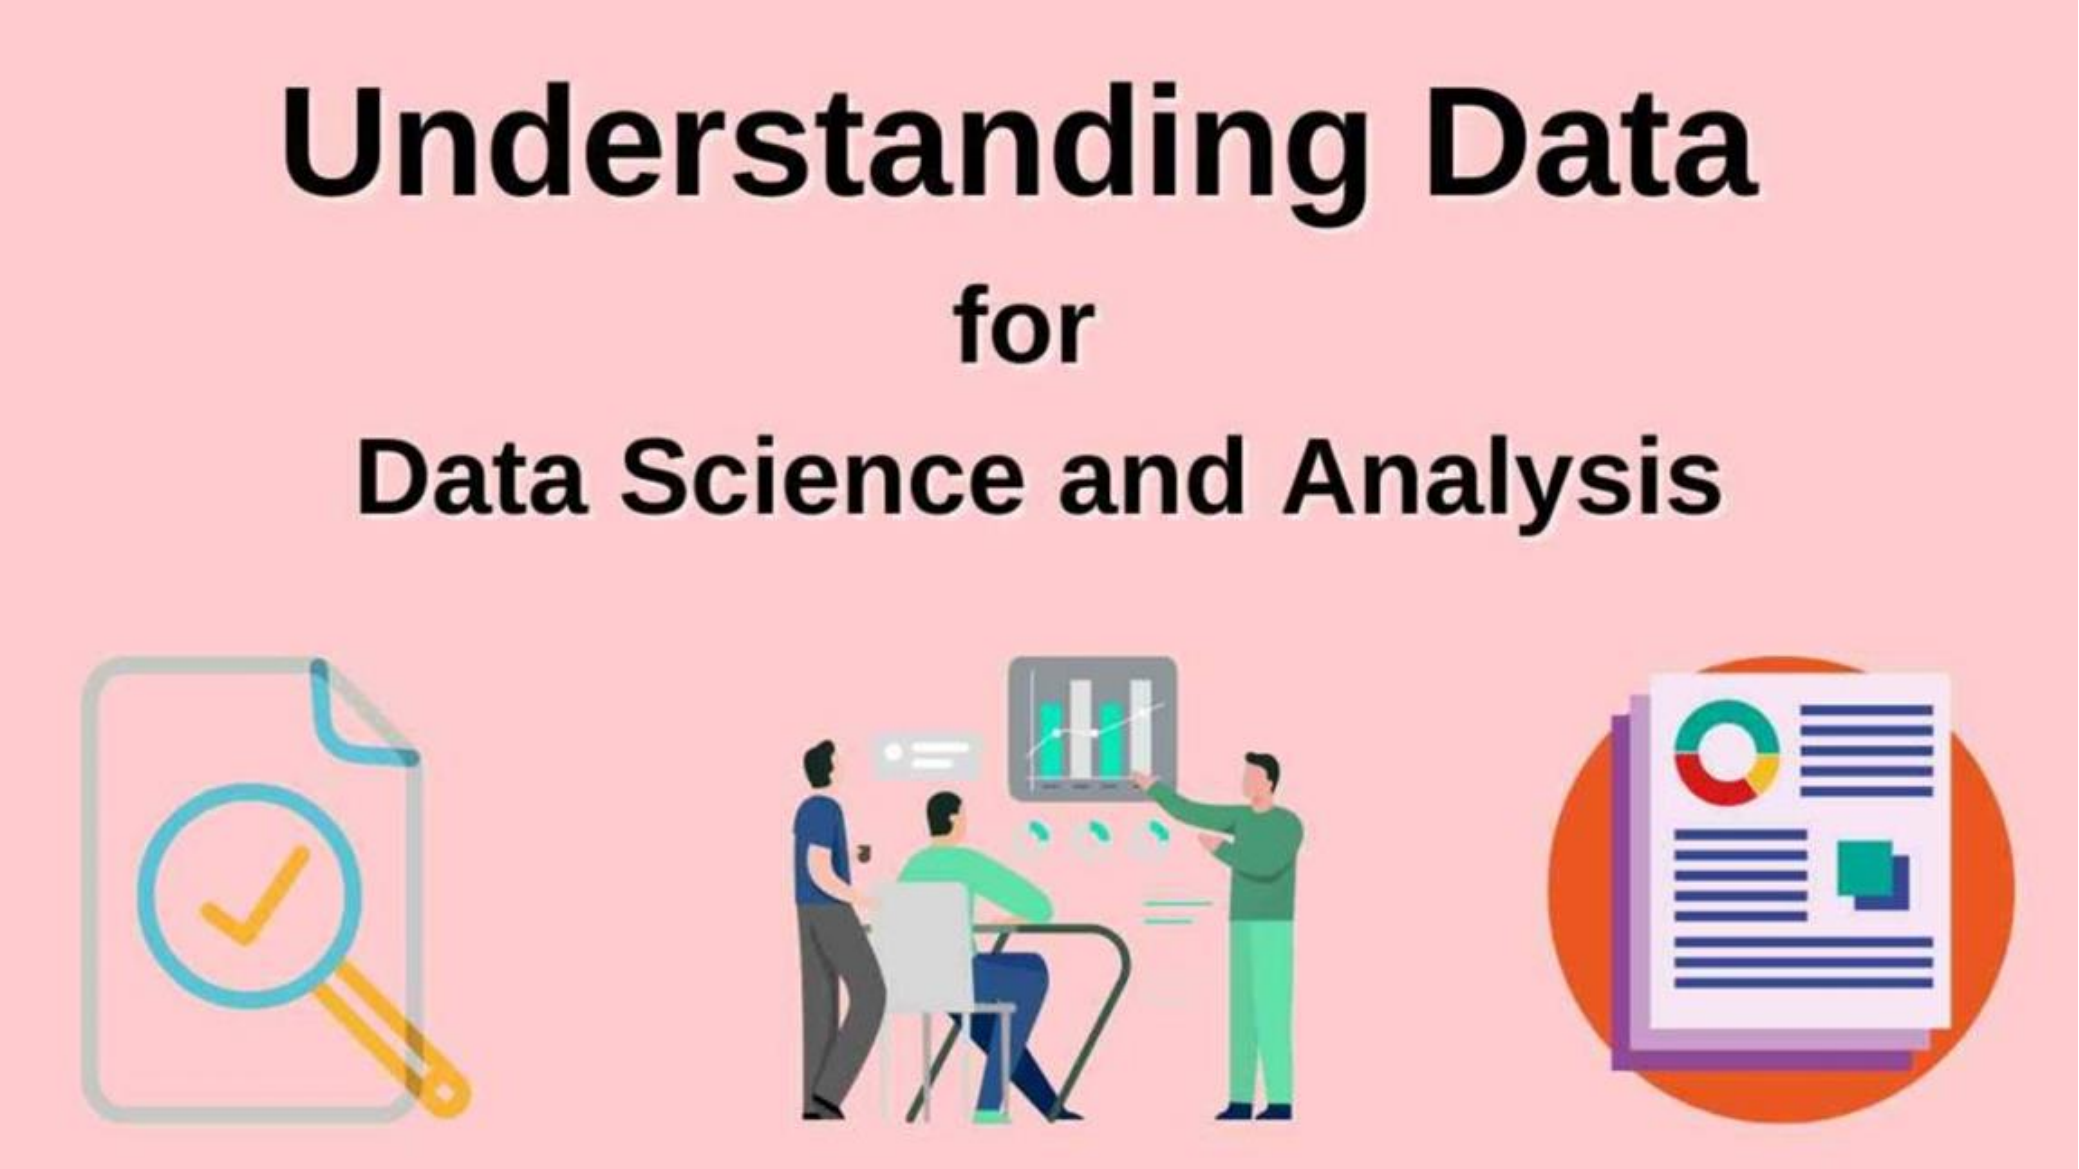

Fonte: https://analyticslearn.com/understanding-data-for-data-science#google_vignette. Data da Consulta: 01/03/2024.

Ciclo de Vida de Projeto de Data Science

CRISP-DM

- **CRISP-DM (*Cross Industry Standard Process for Data Mining* -** Processo Padrão Interindústrias para Mineração de Dados) é um processo de fases bastante aceito na indústria para representar um ciclo completo de Ciência e Análise de Dados, incluído a aplicação de modelos de Aprendizado de Máquina.

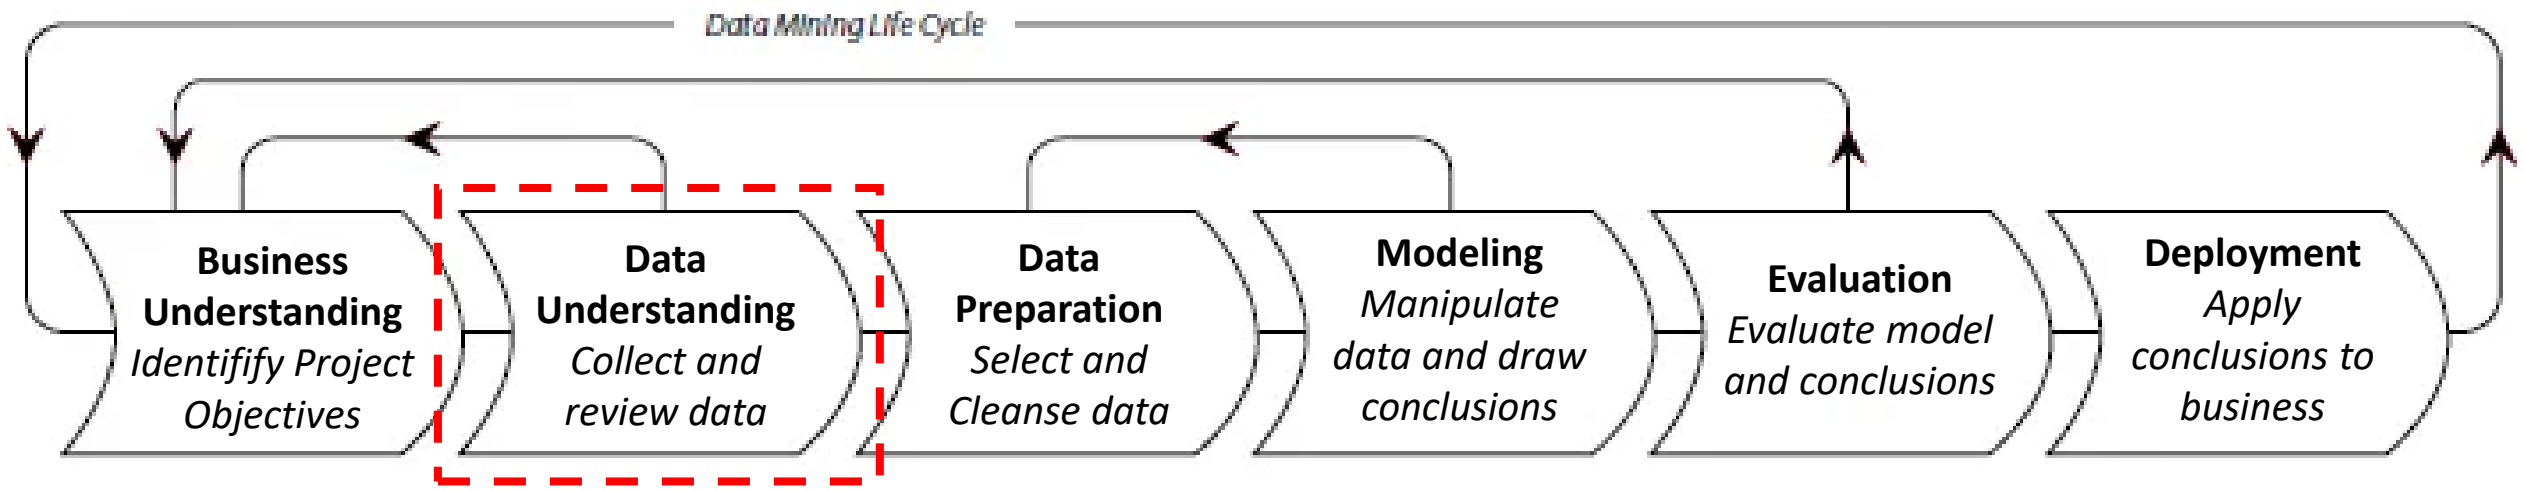

Auxiliar na Identificação	Obtenção dos dados	Pré-processamento	Seleção do modelo	Validação do modelo	Aplica solução obtida ao negócio
Compreensão	Integração	Transformação de Variáveis	Cross-Validation	Otimização	Desenvolvimento de Aplicação Analítica
Pesquisas e Estudos	Análise Exploratória	Seleção de Atributos	Métricas de performance		Geração de relatório
Reunião com Especialistas		Redução de Dimensionalidade	Otimização		Construção de Dashborads etc.
Definição dos Atributos		Amostragem			
Definição medida de erro					

Ciência de Dados

Ciclo de Vida de Projeto de *Data Science*

2. **Compreensão dos Dados**

Coletar e Entender os dados para resolver aquele problema.

Nesse processo, pode ser útil utilizar análise exploratória e elaboração de gráficos.

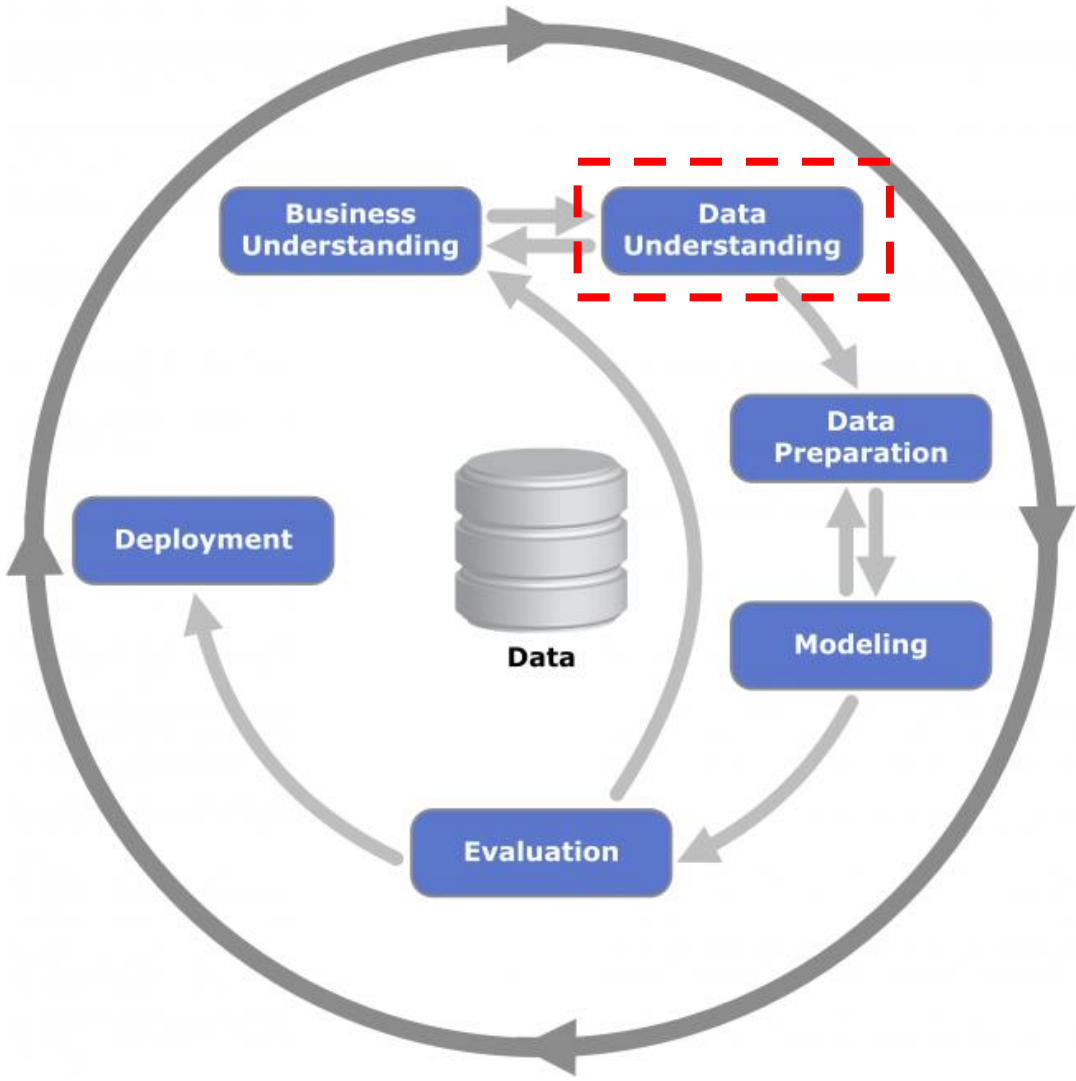

Compreensão/Análise dos Dados

Estatística

- A **análise das características** presentes em um **conjunto de dados** permite a **descoberta** de **padrões** e **tendências** que podem **fornecer informações** valiosas que ajudem a **compreender** o **processo** que **gerou os dados**.

Análise de dados

Caracterização dos dados

- Formalmente, os **dados** podem ser **representados** por uma **matriz de objetos** $\mathbf{X_n^d}$ em que **n** é o número de **objetos** e **d** é o número de **atributos de entrada** de cada objeto.

- Cada **elemento** da matriz $\mathbf{x_{ij}}$ representa o valor da **j-ésima característica** para o **i-ésimo objeto**.

- Os atributos podem ser classificados em **atributos de entrada** ou de **saída** ou **alvo**.

Análise de dados

Caracterização dos dados

- Os **atributos alvos** podem ser **discretos (1, ..., k)** indicando que temos um **problema de classificação** ou valores **numéricos contínuos** que envolvem um **problema de regressão**.

- Os **demais atributos** são denominados atributos **preditivos** ou **independentes**, por poderem ser **utilizados para prever** o valor do atributo **alvo** ou **dependente**.

- Tabelas com esse formato **são denominados tabela atributo-valor**.

- Cada atributo possui o seu **tipo** e **escala** correspondente.

Análise de dados

Caracterização dos dados – Conjunto de dados hospital com seus atributos

Candidatos a Atributos de Entrada
(candidatos a **atributos preditivos**)

Atributo alvo ou classe

Id.	Nome	Idade	Sexo	Peso	Manchas	Temp.	# Int.	Est.	Diagnóstico
4201	João	28	M	79	Concentradas	38,0	2	SP	Doente
3217	Maria	18	F	67	Inexistentes	39,5	4	MG	Doente
4039	Luiz	49	M	92	Espalhadas	38,0	2	RS	Saudável
1920	José	18	M	43	Inexistentes	38,5	8	MG	Doente
4340	Cláudia	21	F	52	Uniformes	37,6	1	PE	Saudável
2301	Ana	22	F	72	Inexistentes	38,0	3	RJ	Doente
1322	Marta	19	F	87	Espalhadas	39,0	6	AM	Doente
3027	Paulo	34	M	67	Uniformes	38,4	2	GO	Saudável

Análise de dados

Caracterização dos dados – Conjunto de dados hospital com seus atributos

- O **tipo de um atributo** refere-se ao **grau de quantização nos dados**

- A **escala** indica a **significância** relativa aos **valores**.

Análise de dados

Caracterização dos dados – Classificação

Tipo

Qualitativos

termos descritivos para relatar algo de interesse

Quantitativos

representados por valores numéricos que podem ser contados ou medidos

Escala

Ordinais

Refletem uma ordem das categorias representadas. Pode utilizar os operadores: =, ≠, <, >, ≤ e ≥

Escolaridade
Classe social
Fila
Hierarquia militar

Nominais

São apenas nomes diferentes. Não existe relação de Ordem. Pode utilizar operadores = e ≠.

Profissão
Sexo
Religião

Discretos

Contém um número finito ou infinito contável de valores.

Número de filhos
Número de carros
Qtde de acessos

Contínuos

Podem assumir um número infinito de valores . Geralmente são resultados de medidas.

Altura
Peso
Salário

Análise de dados

Caracterização dos dados – **Exemplo: conjunto de dados hospital**

- Cada **observação** corresponde a um **paciente**, sendo por isso **formado** pelos valores de **variáveis de entrada** (também chamados de **atributos preditivos**) **referentes ao paciente**.

- Além desses atributos, há um **atributo (variável) alvo** (**diagnóstico**), denominado meta ou de saída, que representa o **fenômeno de interesse** sobre o qual se deseja fazer **previsões**.

Análise de dados

Caracterização dos dados – Conjunto de dados hospital com seus atributos

Candidatos a Atributos de Entrada
(candidatos a **atributos preditivos**)

Atributo alvo ou classe

Id.	Nome	Idade	Sexo	Peso	Manchas	Temp.	# Int.	Est.	Diagnóstico
4201	João	28	M	79	Concentradas	38,0	2	SP	Doente
3217	Maria	18	F	67	Inexistentes	39,5	4	MG	Doente
4039	Luiz	49	M	92	Espalhadas	38,0	2	RS	Saudável
1920	José	18	M	43	Inexistentes	38,5	8	MG	Doente
4340	Cláudia	21	F	52	Uniformes	37,6	1	PE	Saudável
2301	Ana	22	F	72	Inexistentes	38,0	3	RJ	Doente
1322	Marta	19	F	87	Espalhadas	39,0	6	AM	Doente
3027	Paulo	34	M	67	Uniformes	38,4	2	GO	Saudável

Qual a classificação de cada um dos atributos desse conjunto?

Análise de dados

Caracterização dos dados – Conjunto de dados hospital com seus atributos

Variável (Atributo)	Tipo	Escala
Id.		
Nome		
Idade		
Sexo		
Peso		
Manchas		
Temp.		
#int.		
Est.		
Diagnóstico		

Análise de dados

Caracterização dos dados – Conjunto de dados hospital com seus atributos

Variável (Atributo)	Tipo	Escala
Id.	Qualitativo	Ordinal
Nome	Qualitativo	Nominal
Idade	Quantitativo	Discreto
Sexo	Qualitativo	Nominal
Peso	Quantitativo	Discreto
Manchas	Qualitativo	Nominal
Temp.	Quantitativo	Contínuo
#int.	Quantitativo	Discreto
Est.	Qualitativo	Nominal
Diagnóstico	Qualitativo	Nominal

Análise de dados

Exploração dos dados

- **Informações úteis** podem ser **extraída**s por meio da **análise e exploração de dados**.

- Informações obtidas pela **exploração pode**m **auxiliar**, por exemplo, na **seleção da técnica mais apropriada** para **pré-processamento** de dados **e aprendizado**.

- **Forma mais simples** de explorar um conjunto de dados é a **extração de medidas da** área **estatística descritiva**.

- A estatística descritiva **resume de forma quantitativa as principais características** de um **conjunto de dados**.

Análise de dados

Exploração dos dados – Medidas Estatísticas

- **Exemplo**: conjunto de dados de pacientes, duas medidas estatísticas podem ser calculadas: **idade média dos pacientes** e a **porcentagem** de pacientes do **sexo masculino**.

As **medidas estatísticas** permitem **capturar** informações como:

- ❑ **Frequência**;
- ❑ **Localização** ou tendência central (por ex.: média e moda);
- ❑ **Dispersão** ou **espalhamento** (por ex.: desvio padrão);
- ❑ **Distribuição** ou formato.

Análise de dados

Exploração dos dados – Medidas Estatísticas - Frequência (absoluta)

- A **frequência absoluta** mede **a quantidade de vezes que um atributo x_i assume um dado valor** em um determinado conjunto de dados (qualitativo ou quantitativo).

$$\textit{frequência}_{abs}(x_i) = \text{total vezes } x_i$$

- Por exemplo, em um conjunto de 10 dados médicos 4 pacientes estão com febre. Então, a frequência absoluta de pacientes com febre é 4.

$$\textit{frequência}_{abs}(\text{febre}) = 4$$

Análise de dados

Exploração dos dados – Medidas Estatísticas - Frequência (relativa)

- Frequência (relativa) **mede a proporção de vezes** que um **atributo assume** um dado **valor** em um determinado **conjunto de dados**.

$$frequência\ (x_i) = \frac{total\ vezes\ x_i}{n} * 100$$

Exemplo: Em um conjunto de 10 dados médicos 4 pacientes estão com febre.

Então, a **frequência** de **pacientes com febre** é **40%**.

Análise de dados

Exploração dos dados – Medidas Estatísticas - Frequência - Exemplo

Id.	Nome	Idade	Sexo	Peso	Manchas	Temp.	# Int.	Est.	Diagnóstico
4201	João	28	M	79	Concentradas	38,0	2	SP	Doente
3217	Maria	18	F	67	Inexistentes	39,5	4	MG	Doente
4039	Luiz	49	M	92	Espalhadas	38,0	2	RS	Saudável
1920	José	18	M	43	Inexistentes	38,5	8	MG	Doente
4340	Cláudia	21	F	52	Uniformes	37,6	1	PE	Saudável
2301	Ana	22	F	72	Inexistentes	38,0	3	RJ	Doente
1322	Marta	19	F	87	Espalhadas	39,0	6	AM	Doente
3027	Paulo	34	M	67	Uniformes	38,4	2	GO	Saudável

- Frequência_{abs}(Doente) = 5
- Frequência_{abs}(Saudável) = 3
- Frequência (Doente) = 62,5 %
- Frequência(Saudável) = 37,5%

Qual a frequência dos valores Doente/Saudável para a variável diagnóstico?

Análise de dados

Exploração dos dados – Medidas Estatísticas

- As medidas de
  - ❑ **Localização** ou tendência central (média),
  - ❑ **Dispersão** ou espalhamento (por ex.: desvio padrão) e
  - ❑ **Distribuição** ou formato

São geralmente **aplicas a dados numéricos** e **diferem** para os casos em que os dados apresentam apenas um atributo (**dados univariados**) ou mais de um atributo (**dados multivariados**).

Análise de dados

Exploração dos dados – Medidas Estatísticas - Dados Univariados

- Considere um **objeto x_i** com **apenas um atributo**.

- Um conjunto com **n objetos** pode ser representado por $\mathbf{x^j = \{ x_1, x_2, ..., x_n \}}$, em que cada $\mathbf{x_i}$ é representado por **um valor**.

- Em um conjunto de dados, **o mesmo valor pode aparecer mais de uma vez** em um atributo.

Análise de dados

Exploração dos dados – Medidas Estatísticas - Dados Univariados - Localidade

- **Moda** é uma das medidas de tendência central de um conjunto de dados, assim como a média ou mediana.

- **Moda** é o valor que mais aparece em um conjunto de dados.

- **Moda** será **unimodal** no caso de apresentar uma só moda e bimodal (duas modas) e **multimodal** se apresentar várias modas.

Análise de dados

Exploração dos dados – Medidas Estatísticas - Dados Univariados - Localidade

- **Distribuições bimodais ou multimodais podem indicar** que na realidade a **distribuição de frequência** se refere a **duas populações** cujas medidas foram misturadas.

- Quando todos os valores do conjunto são diferentes, diz-se que o conjunto é **amodal**.

Análise de dados

Exploração dos dados – Medidas Estatísticas - Dados Univariados - Localidade

- **Exemplo:** Os dados abaixo se referem à idade de 20 adolescentes de uma família.

  Idade: { 12, 11, 12, 13, 12, 11, 13, 12, 12, 11, 14, 13, 13, 12, 11, 12, 13, 14, 11, 14 }

- A moda desse conjunto de dados será a idade que mais aparece, ou seja:

$$M_o = 12 \text{ (que aparece 7 vezes)}$$

Análise de dados

Exploração dos dados – Medidas Estatísticas - Dados Univariados - Localidade

- Para **valores numéricos**, **medidas** muito utilizadas são **média**, **mediana** e **percentil**.

- Considerando o conjunto de **n valores numéricos** $\mathbf{x^j = \{ x_1, x_2, ..., x_n \}}$, a **média** é:

$$\bar{x}^j = \frac{1}{n}\sum_{i=1}^{n} x_i$$

Análise de dados

Exploração dos dados – Medidas Estatísticas - Dados Univariados - Localidade

- **Média** é um **bom indicador** se os **valores** estão **distribuídos simetricamente**.

- Um valor muito mais alto ou muito mais baixo (***outliers* – discrepantes / extremos**) que os demais valores do conjunto **pode gerar uma valor distorcido para a média**, que poderia mudar radicalmente se o valor for retirado.

Análise de dados

Exploração dos dados – Medidas Estatísticas - Dados Univariados - Localidade

- O **problema dos *outliers*** é **minimizado** com o uso da **mediana**.
- A mediana permite observar se a distribuição é oblíqua (assimétrica) ou se existem *outliers*.
- Para obter a **mediana** deve-se **ordenar** o conjunto de forma **crescente**, depois **aplicar**:

$$mediana\,(x^j) = \begin{cases} \frac{1}{2}(x_r + x_{r+1})\ se\ n\ for\ par\ (n = 2r) \\ x_{r+1}\ se\ n\ for\ ímpar\ (n = 2r + 1) \end{cases}$$

Análise de dados

Exploração dos dados – Medidas Estatísticas - Dados Univariados - Localidade

- Caso **n** seja **ímpar**, a **mediana** é o valor do **meio do conjunto ordenado**.

- Por exemplo:

$$\{ 17, 4, 8, 21, 4 \}$$

- Ordenando os valores:

$$\{ 4, 4, 8, 17, 21 \}$$

- Como n = 5 (ímpar), a mediana = 8, elemento do meio.

Análise de dados

Exploração dos dados – Medidas Estatísticas - Dados Univariados - Localidade

- Caso **n** seja **par**, a **mediana** é dada pela **média dos dois valores do meio**.
- Por exemplo:

$$\{ 17, 4, 8, 21, 4, 15, 13, 9 \}$$

- Ordenando os valores:

$$\{ 4, 4, 8, 9, 13, 15, 17, 21 \}$$

- Como n = 8 (par), a mediana = (9+13)/2 = 11.

Análise de dados

Exploração dos dados – Medidas Estatísticas - Dados univariados - Localidade - Exemplo

Id.	Nome	Idade	Sexo	Peso	Manchas	Temp.	# Int.	Est.	Diagnóstico
4201	João	28	M	79	Concentradas	38,0	2	SP	Doente
3217	Maria	18	F	67	Inexistentes	39,5	4	MG	Doente
4039	Luiz	49	M	92	Espalhadas	38,0	2	RS	Saudável
1920	José	18	M	43	Inexistentes	38,5	8	MG	Doente
4340	Cláudia	21	F	52	Uniformes	37,6	1	PE	Saudável
2301	Ana	22	F	72	Inexistentes	38,0	3	RJ	Doente
1322	Marta	19	F	87	Espalhadas	39,0	6	AM	Doente
3027	Paulo	34	M	67	Uniformes	38,4	2	GO	Saudável

- Média = 38,375
- Mediana = 38,2
- Moda = 38

Qual a média, mediana e a moda para a variável Temp.?

Análise de dados

Exploração dos dados – Medidas Estatísticas - Dados Univariados - Localidade – BoxPlot

- Outras medidas são os ***quartis*** e os ***percentis*** que são **utilizadas após os valores serem ordenados**.
- Os ***quartis*** **dividem os valores em quatro partes**.
- Os ***percentis*** dividem os valores em cem partes.
- Além disso, temos o **Máximo** e **Mínimo**, correspondentes ao Maior e menor valor de um conjunto.
- Uma forma de visualizar alguns desses valores é por meio de um ***boxplot***.

Análise de dados

Exploração dos dados – Medidas Estatísticas - Dados Univariados – Localidade – BoxPlot

- Boxplot, ou diagrama de caixa, **é possível obter informações sobre vários aspectos dos dados simultaneamente** como:

  - ❑ *outliers*,
  - ❑ dispersão,
  - ❑ tendências centrais e
  - ❑ simetria

Análise de dados

Exploração dos dados – Medidas Estatísticas
Dados Univariados - Localidade – BoxPlot

boxplot

- A partir de uma sequência, **os *quartis*/percentil** são:

1º Quartil (ou percentil) (Q_1) :

- ❑ valor que deixa 25% das observações à sua esquerda.

2º Quartil (Q_2 = mediana) :

- ❑ valor que deixa 50% das observações à sua esquerda.

3º Quartil (Q_3) :

- ❑ valor que deixa 75% das observações à sua esquerda.

Então: Posição do Percentil = Percentil * Tamanho da Amostra / 100

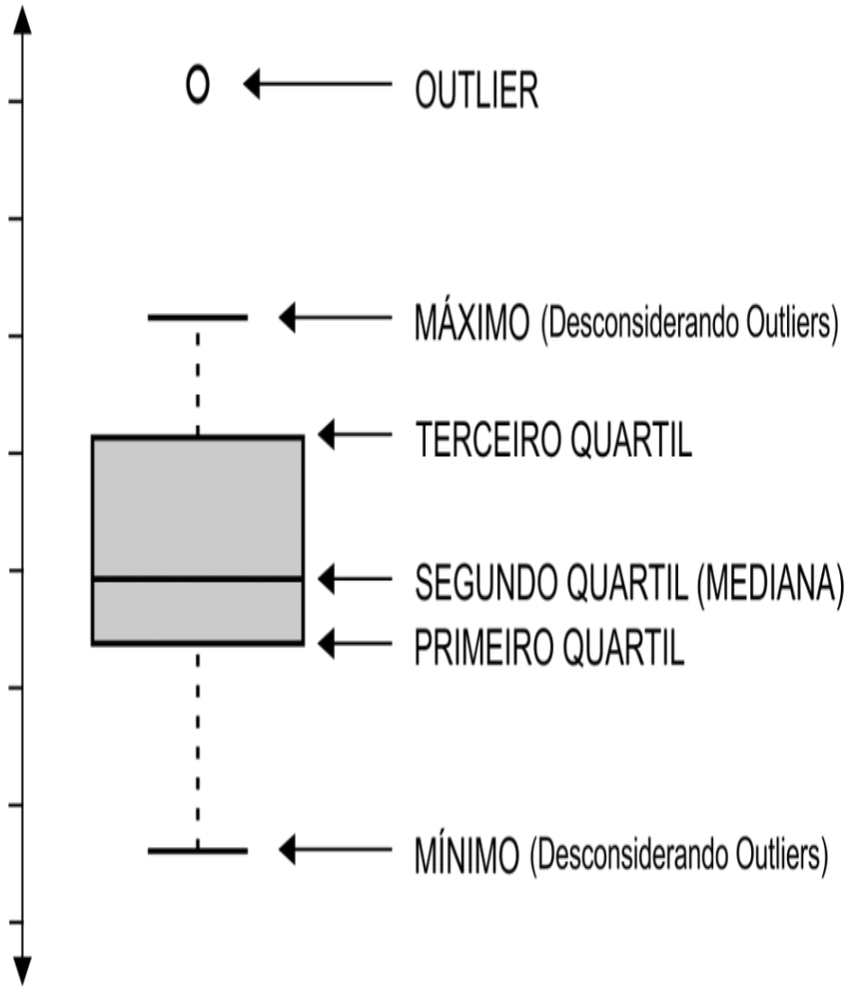

Fonte: https://operdata.com.br/blog/como-interpretar-um-boxplot/. Data da Consulta: 05/02/2021.

Análise de dados

Exploração dos dados – Medidas Estatísticas
Dados Univariados - Localidade – BoxPlot

boxplot

- **Intervalo Interquartil**
  - ❑ Amplitude interquartis (**IQ**). IQ = $Q_3 - Q_1$.
- **Amplitude Máxima (intervalo)**
  - ❑ Máximo – Mínimo.

Obs.: Caso você considere todos os dados, inclusive os *outliers*, a Amplitude deve incluir o outlier (como máximo e/ou mínimo)

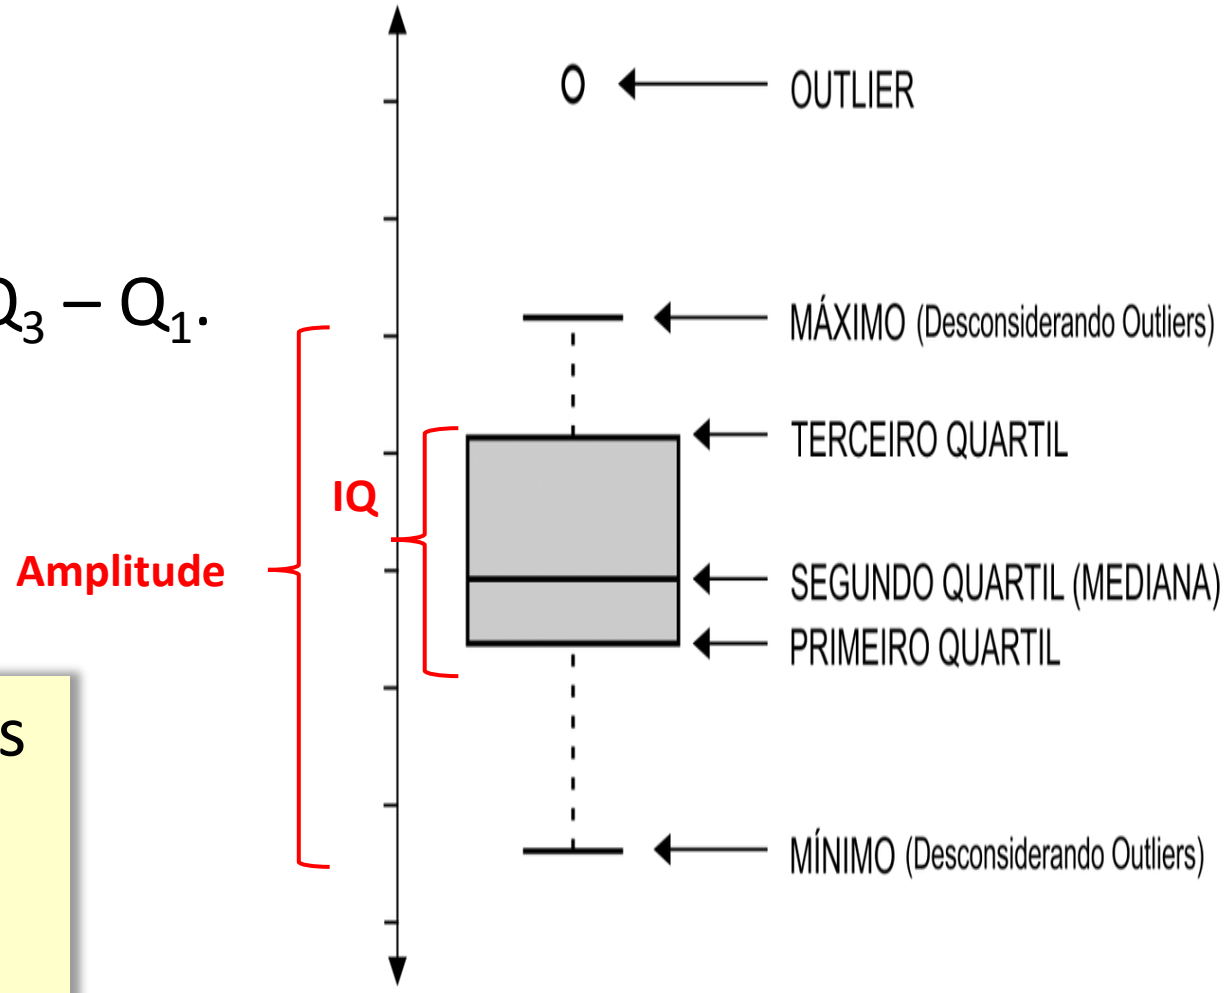

Fonte: https://operdata.com.br/blog/como-interpretar-um-boxplot/. Data da Consulta: 05/02/2021.

Análise de dados

Exploração dos dados – Medidas Estatísticas
Dados Univariados – Localidade – BoxPlot – Como interpretar

boxplot

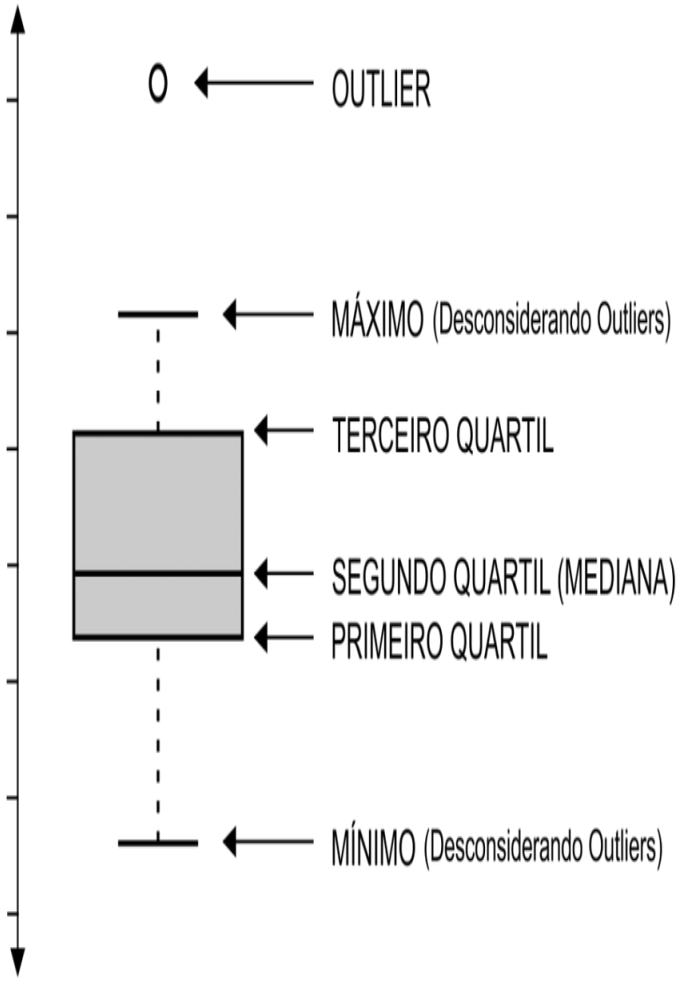

- Fornece uma **análise visual** da **posição**, **dispersão**, **simetria**, **caudas** e valores discrepantes (**outliers**) do conjunto de dados, ou seja:

❑ **Posição**: Em relação à posição dos dados, observa-se a **linha central do retângulo** (a **mediana** ou segundo quartil).

Fonte: https://operdata.com.br/blog/como-interpretar-um-boxplot/. Data da Consulta: 05/02/2021.

Análise de dados

Exploração dos dados – Medidas Estatísticas
Dados Univariados – Localidade – BoxPlot – Como interpretar

boxplot

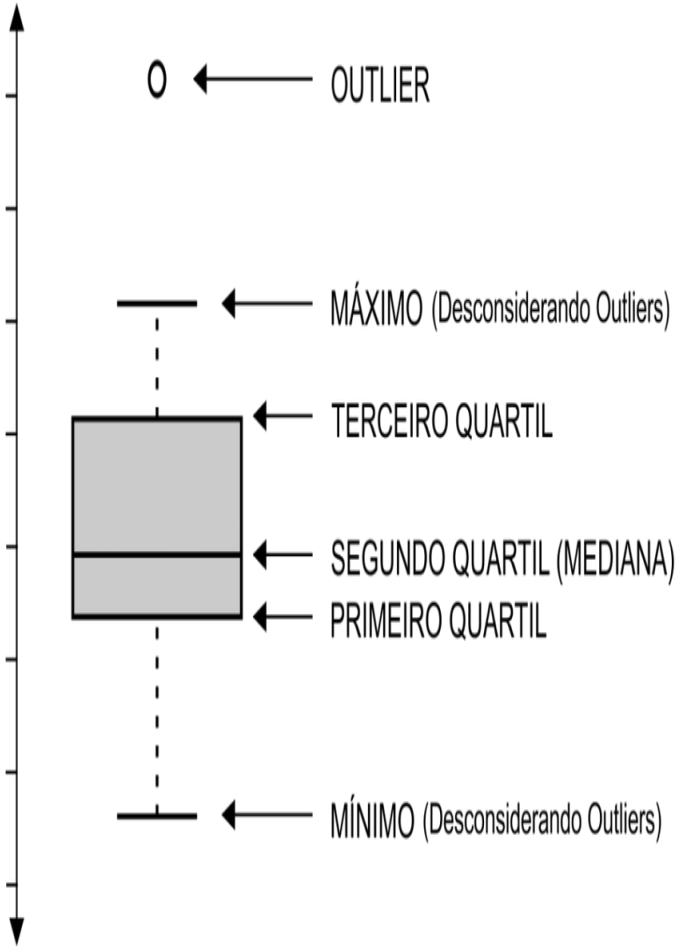

- Fornece uma **análise visual** da **posição**, **dispersão**, **simetria**, **caudas** e valores discrepantes (**outliers**) do conjunto de dados, ou seja:

  - **Dispersão**: A dispersão dos dados pode ser **representada** pelo intervalo interquartil (**IQ**), ou ainda, pela **Amplitude Máxima**.

    Embora a Amplitude Máxima seja de fácil entendimento, o **IQ** é uma **estatística mais robusta** para **medir variabilidade** uma vez que **não sofre influência de *outliers***.

Fonte: https://operdata.com.br/blog/como-interpretar-um-boxplot/. Data da Consulta: 05/02/2021.

Análise de dados

Exploração dos dados – Medidas Estatísticas
Dados Univariados – Localidade – BoxPlot – Como interpretar

boxplot

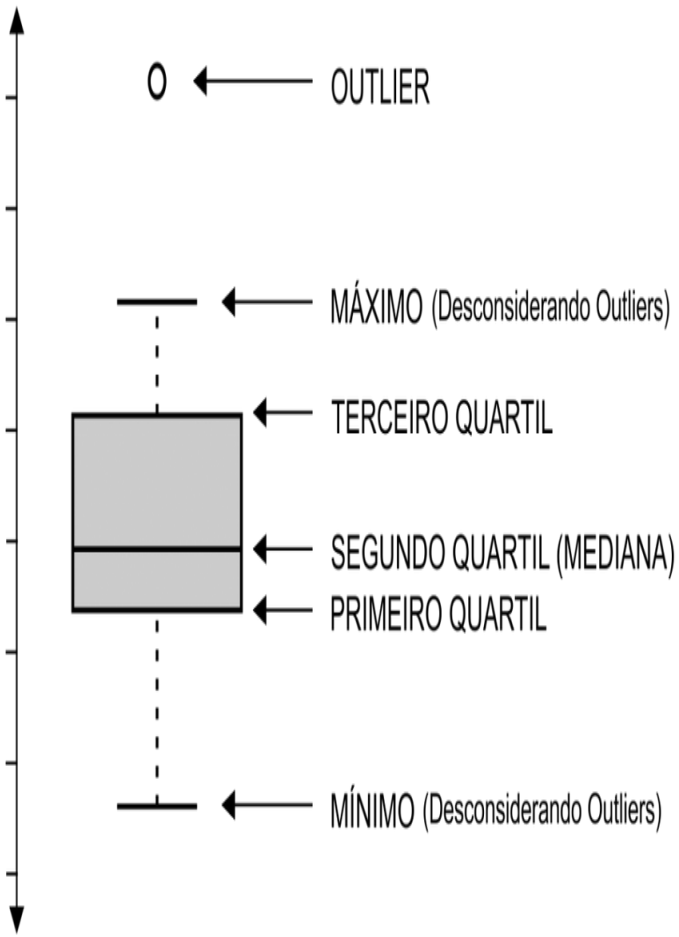

- Fornece uma **análise visual** da **posição**, **dispersão**, **simetria**, **caudas** e valores discrepantes (**outliers**) do conjunto de dados, ou seja:

❑ **Simetria**: Um conjunto de dados que tem uma **distribuição simétrica**, terá a linha da **mediana no centro do retângulo**.

Quando a linha da **mediana** está **próxima** ao **1º Quartil**, os **dados** são **assimétricos positivos** e quando a posição da linha da **mediana** é **próxima** ao **3º Quartil**, os dados são **assimétricos negativos**.

A **mediana** é a **medida de tendência central** mais **indicada** quando os **dados possuem distribuição assimétrica**, pois a média é influenciada pelos *outliers*.

Fonte: https://operdata.com.br/blog/como-interpretar-um-boxplot/. Data da Consulta: 05/02/2021.

Análise de dados

Exploração dos dados – Medidas Estatísticas
Dados Univariados – Localidade – BoxPlot – Como interpretar

boxplot

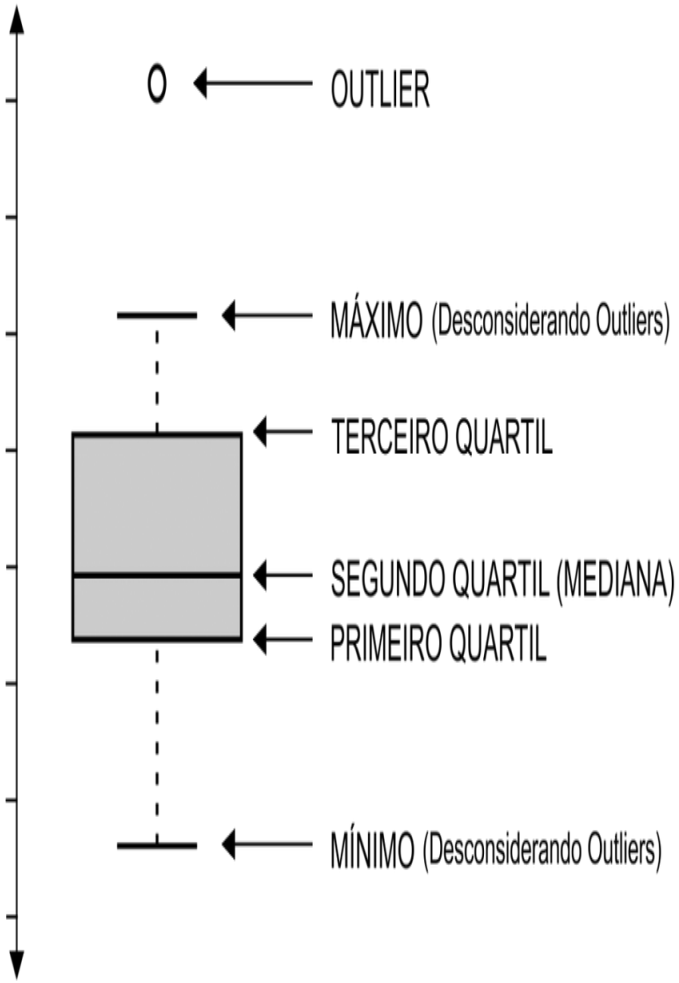

- Fornece uma **análise visual** da **posição**, **dispersão**, **simetria**, **caudas** e valores discrepantes (**outliers**) do conjunto de dados, ou seja:

  - **Caudas**: As **linhas** que vão do **retângulo até** os ***outliers*** podem **fornece**r o **comprimento das caudas da distribuição**.

Fonte: https://operdata.com.br/blog/como-interpretar-um-boxplot/. Data da Consulta: 05/02/2021.

Análise de dados

Exploração dos dados – Medidas Estatísticas
Dados Univariados – Localidade – BoxPlot – Como interpretar

boxplot

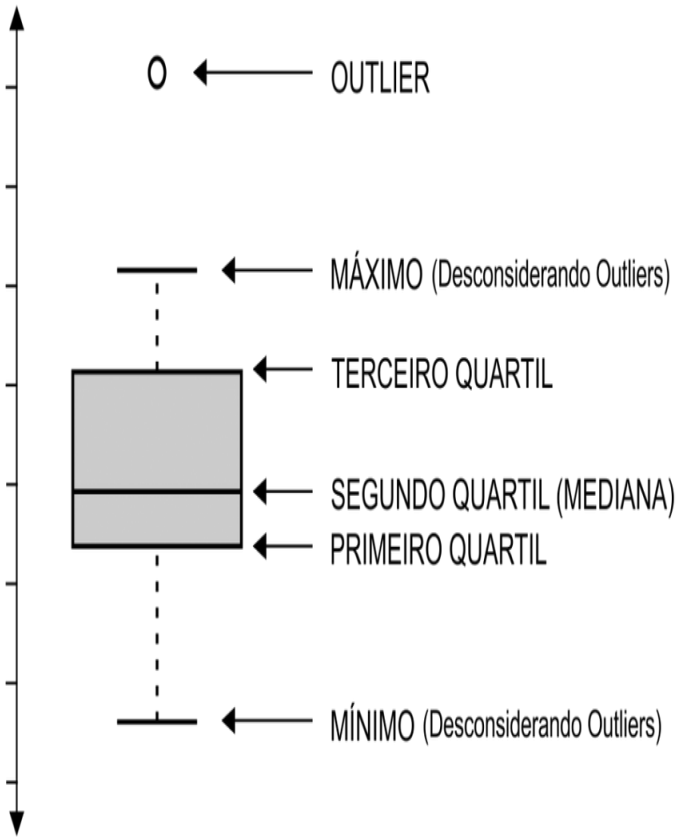

- Fornece uma **análise visual** da **posição**, **dispersão**, **simetria**, **caudas** e valores discrepantes (**outliers**) do conjunto de dados, ou seja:
  - ***Outliers***: Já os *outliers* indicam **possíveis valores discrepantes**.

    No boxplot, as observações são **consideradas *outliers* quando estão abaixo ou acima do limite de detecção de *outliers***.

Fonte: https://operdata.com.br/blog/como-interpretar-um-boxplot/. Data da Consulta: 05/02/2021.

Análise de dados

Exploração dos dados – Medidas Estatísticas
Dados Univariados – Localidade – BoxPlot – Como interpretar

boxplot

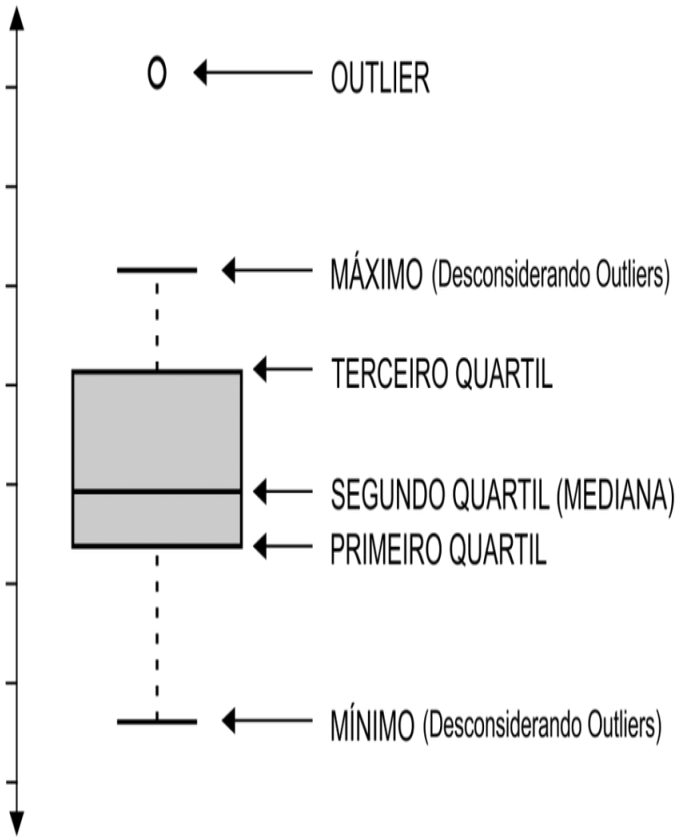

- O **limite de detecção de *outliers*** é **construído** utilizando o intervalo interquartil (**IQ**), dado pela **distância** entre o **primeiro** e o **terceiro quartil**.

  Sendo assim, os **limites inferior e superior** de **detecção de *outlier*** são dados por:

- ❑ Limite Inferior = 1º Quartil – 1,5 * (3º Quartil – 1º Quartil)
- ❑ Limite Superior = 3º Quartil + 1,5 * (3º Quartil – 1º Quartil)

Fonte: https://operdata.com.br/blog/como-interpretar-um-boxplot/. Data da Consulta: 05/02/2021.

Análise de dados

Exploração dos dados – Medidas Estatísticas
Dados Univariados - Localidade

Exemplo: Considere os n = 10 dados já ordenados:

1,9	2,0	2,1	2,5	3,0	3,1	3,3	3,7	6,6	7,7

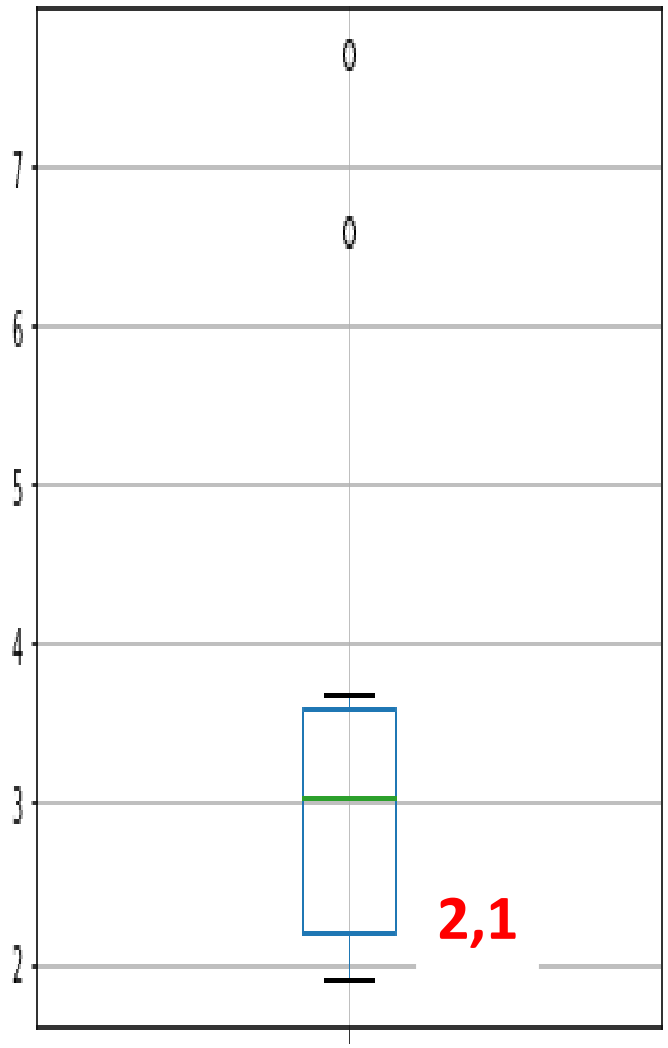

1º Quartil

- Q_1 = 25*10 / 100 = 2,5.
- Arredondando, será o 3o termo, ou seja, Q_1 = 2,1, isto é, 25% das observações têm valores inferiores a 2,1.

Lembrete: Posição do Percentil = Percentil * Tamanho da Amostra / 100

Fonte: https://operdata.com.br/blog/como-interpretar-um-boxplot/. Data da Consulta: 05/02/2021.

Análise de dados

Exploração dos dados – Medidas Estatísticas
Dados Univariados - Localidade

Exemplo: Considere os n = 10 dados já ordenados:

1,9	2,0	2,1	2,5	3,0	3,1	3,3	3,7	6,6	7,7

2º Quartil

- n é par, então, Q_2= Mediana = (3,0 + 3,1)/2 = 3,05.
- Se n fosse ímpar Q_2 seria o elemento do meio dos dados ordenados.

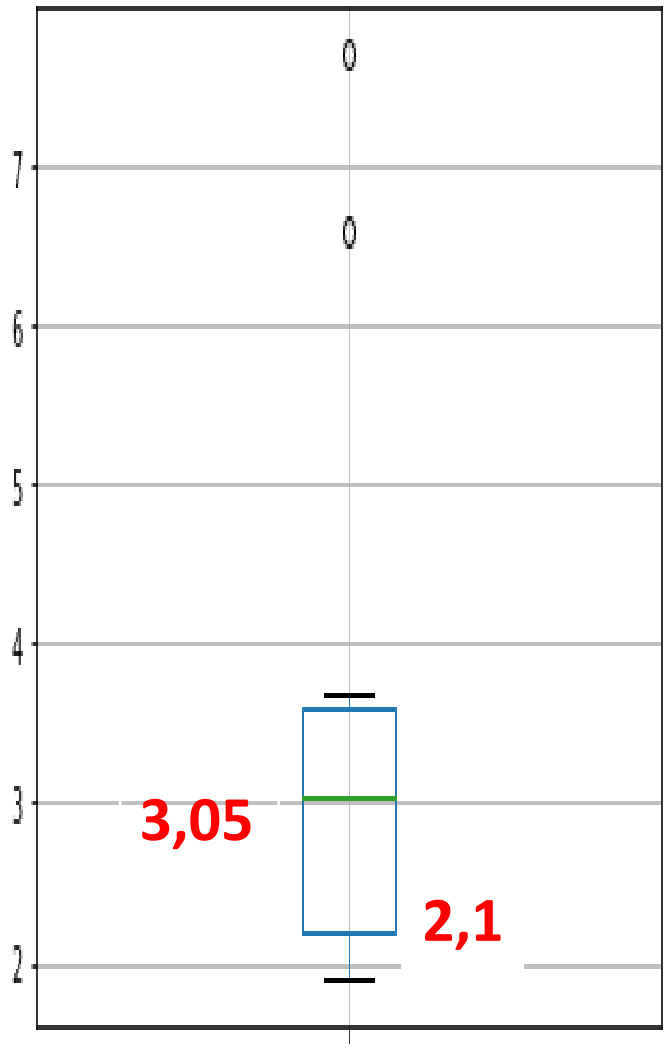

Fonte: https://operdata.com.br/blog/como-interpretar-um-boxplot/. Data da Consulta: 05/02/2021.

Análise de dados

Exploração dos dados – Medidas Estatísticas
Dados Univariados - Localidade

Exemplo: Considere os n = 10 dados já ordenados:

1,9	2,0	2,1	2,5	3,0	3,1	3,3	3,7	6,6	7,7

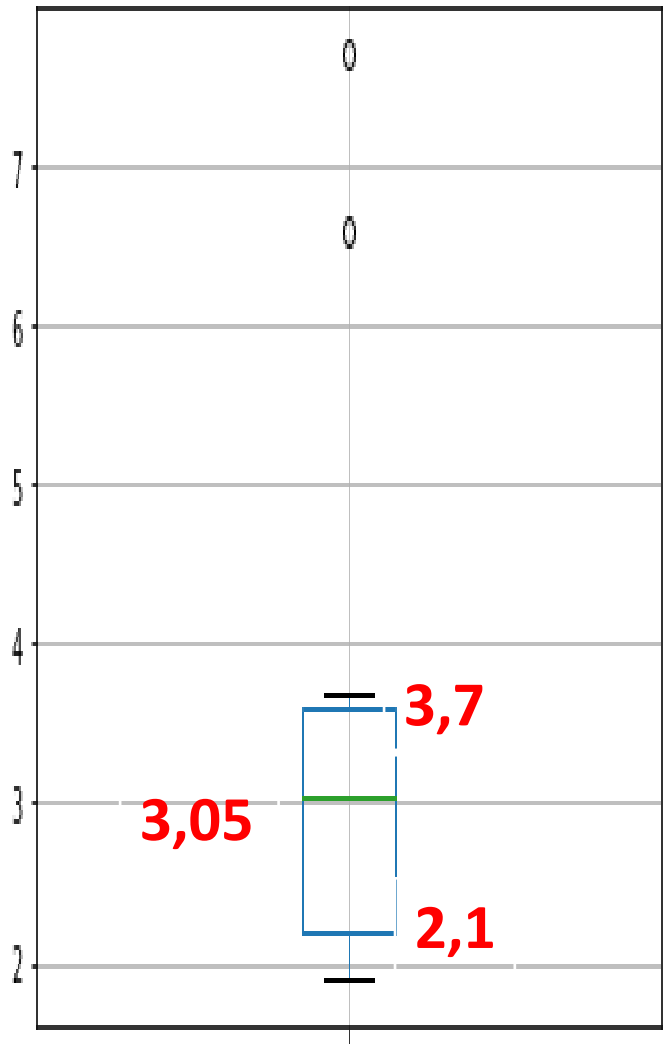

3º Quartil

- Q_3= 75*10 / 100 = 7,5.
- Arredondando, será o 8o termo, ou seja, Q_3 = 3,7, isto é, 75% das observações têm valores inferiores a 3,7.

Lembrete: Posição do Percentil = Percentil * Tamanho da Amostra / 100

Fonte: https://operdata.com.br/blog/como-interpretar-um-boxplot/. Data da Consulta: 05/02/2021.

Análise de dados

Exploração dos dados – Medidas Estatísticas
Dados Univariados - Localidade

Exemplo: Considere os n = 10 dados já ordenados:

1,9	2,0	2,1	2,5	3,0	3,1	3,3	3,7	6,6	7,7

Intervalo Interquartil (IQ)

- IQ = Q_3- Q_1 = 3,7 – 2,1 = 1,6.

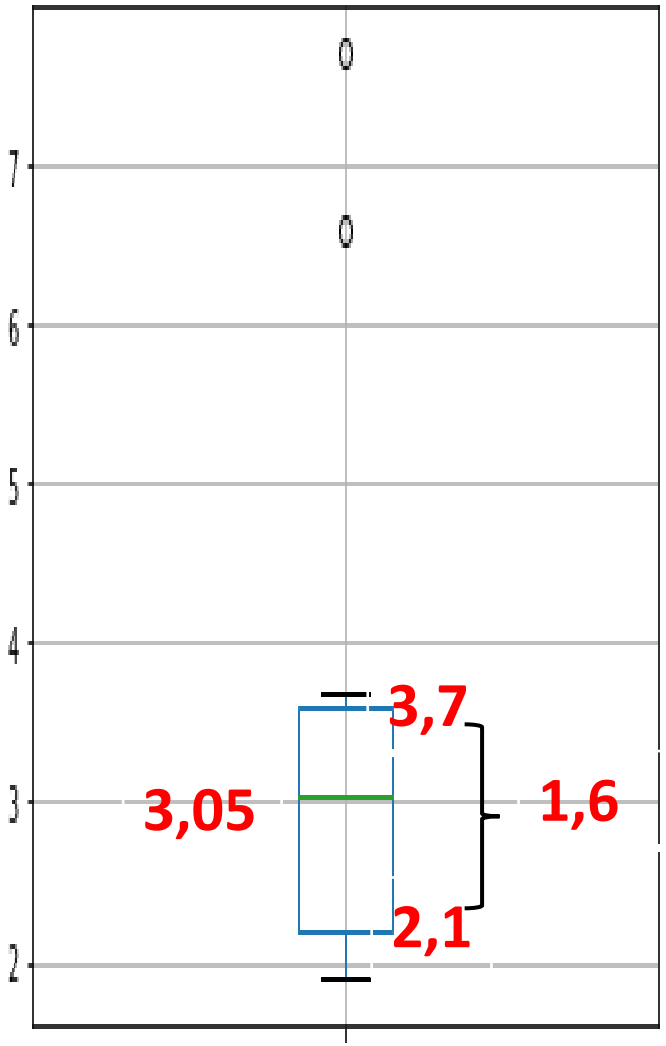

Fonte: https://operdata.com.br/blog/como-interpretar-um-boxplot/. Data da Consulta: 05/02/2021.

Análise de dados

Exploração dos dados – Medidas Estatísticas
Dados Univariados - Localidade

Exemplo: Considere os n = 10 dados já ordenados:

1,9	2,0	2,1	2,5	3,0	3,1	3,3	3,7	6,6	7,7

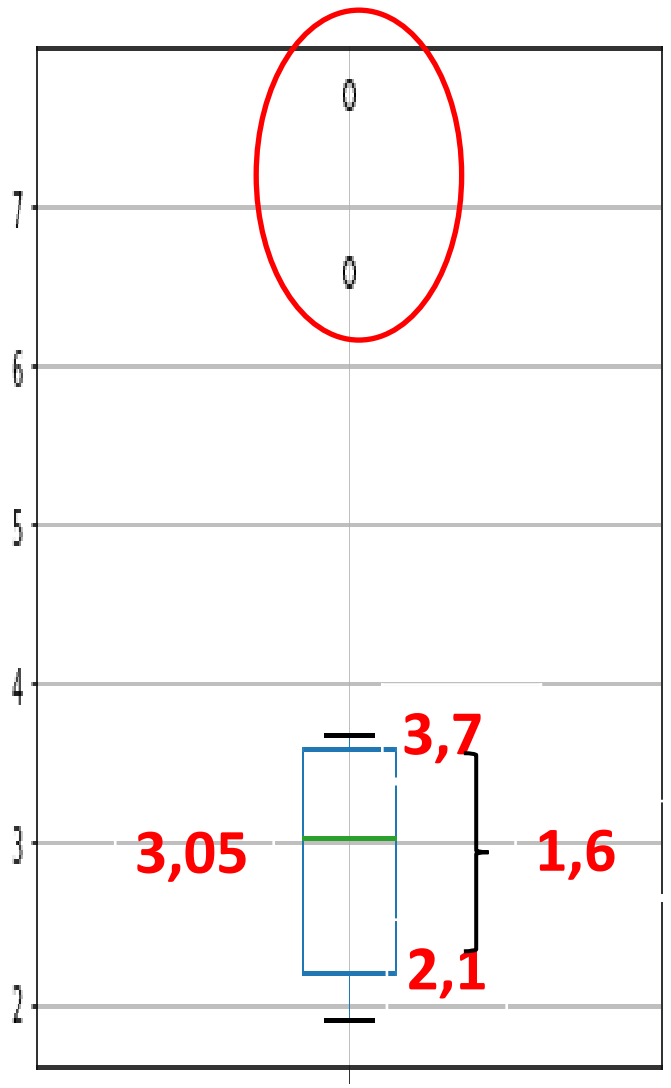

Limite Superior e Inferior

- **Limite Inferior** = 1º Quartil – 1,5 * (3º Quartil – 1º Quartil)

  = 2,1 – 1,5 * (3,7 – 2,1) = -0,3 (Não há *outliers* inferiores!)

- **Limite Superior** = 3º Quartil + 1,5 * (3º Quartil – 1º Quartil)

  = 3,7 + 1,5 * (3,7 – 2,1) = 6,1 (A partir deste valor é *outlier*!)

Fonte: https://operdata.com.br/blog/como-interpretar-um-boxplot/. Data da Consulta: 05/02/2021.

Análise de dados

Exploração dos dados – Medidas Estatísticas
Dados Univariados - Localidade

Exemplo: Considere os n = 10 dados já ordenados:

1,9	2,0	2,1	2,5	3,0	3,1	3,3	3,7	6,6	7,7

Amplitude Máxima (considerando os *outliers*)

- Amplitude Máxima =

  Máximo – Mínimo = 7,7 - 1,9 = 5,8.

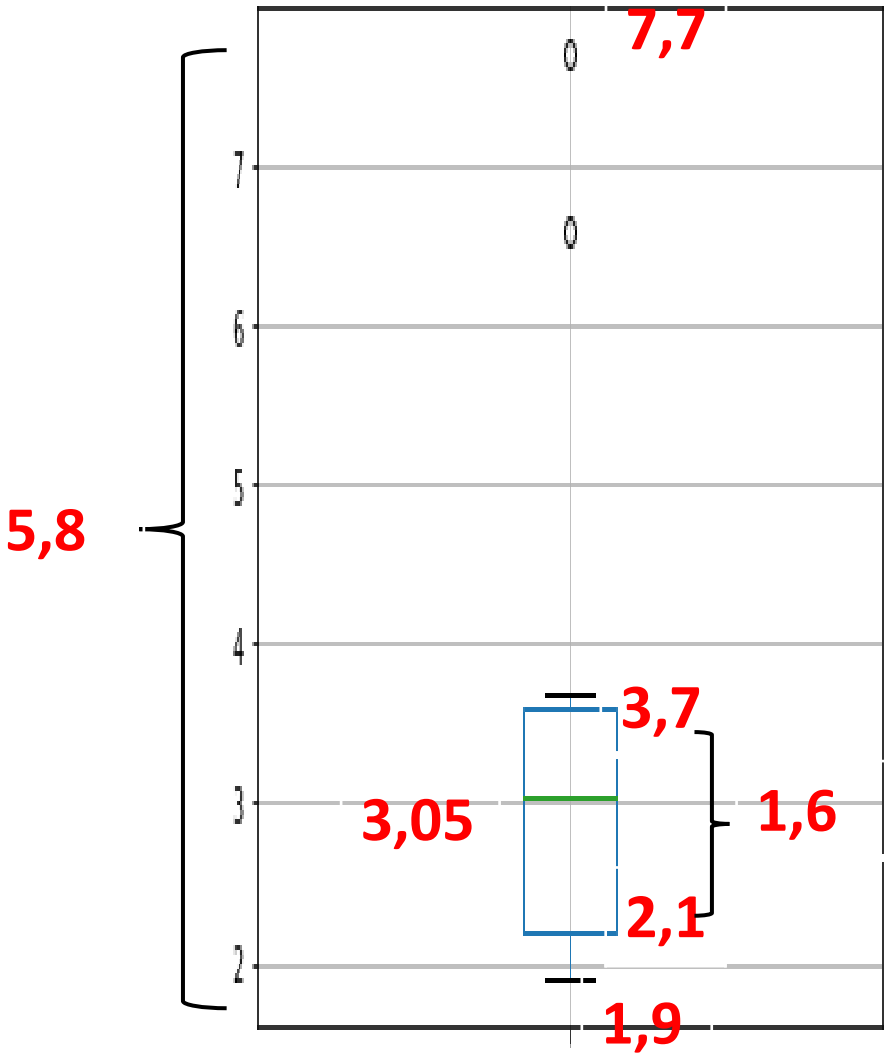

Fonte: https://operdata.com.br/blog/como-interpretar-um-boxplot/. Data da Consulta: 05/02/2021.

Análise de dados

Exploração dos dados – Medidas Estatísticas - Dados univariados - Localidade – Exe

Id.	Nome	Idade	Sexo	Peso	Manchas	Temp.	# Int.	Est.	Diagnóstico
4201	João	28	M	79	Concentradas	38,0	2	SP	Doente
3217	Maria	18	F	67	Inexistentes	39,5	4	MG	Doente
4039	Luiz	49	M	92	Espalhadas	38,0	2	RS	Saudável
1920	José	18	M	43	Inexistentes	38,5	8	MG	Doente
4340	Cláudia	21	F	52	Uniformes	37,6	1	PE	Saudável
2301	Ana	22	F	72	Inexistentes	38,0	3	RJ	Doente
1322	Marta	19	F	87	Espalhadas	39,0	6	AM	Doente
3027	Paulo	34	M	67	Uniformes	38,4	2	GO	Saudável

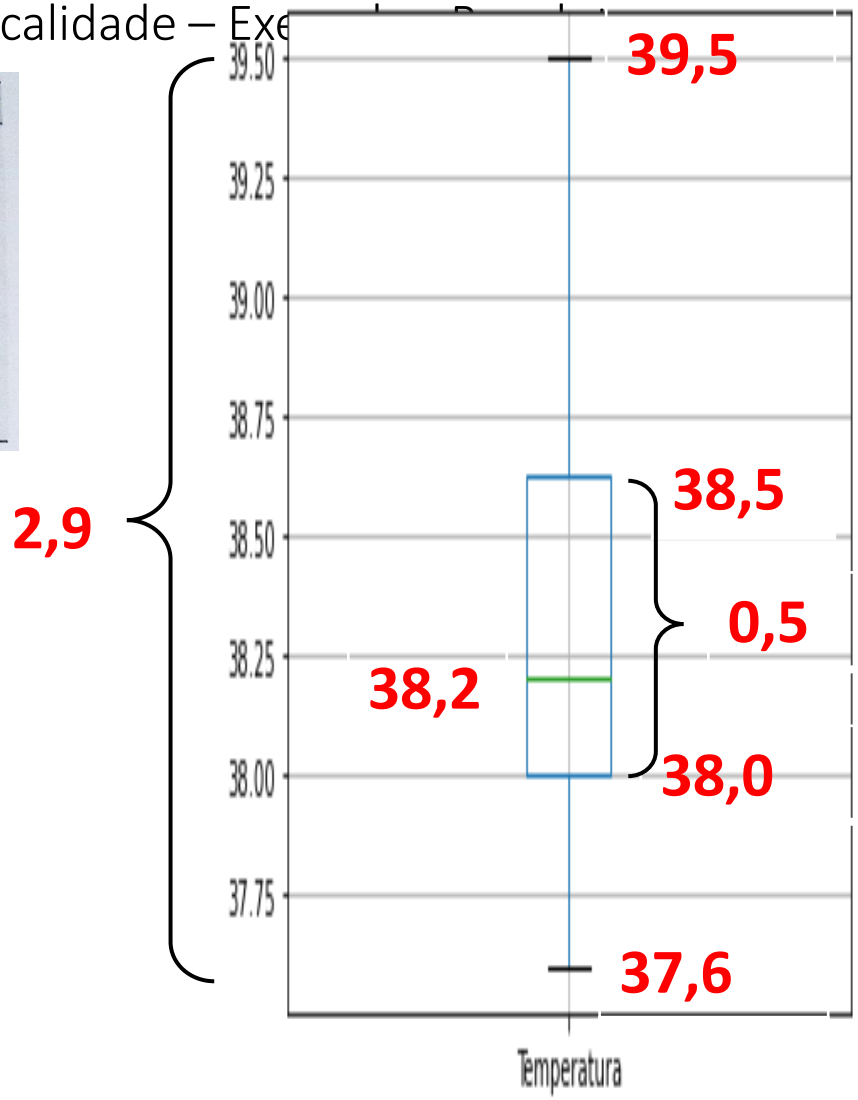

Qual o boxplot para Temp.?

Ordenando os dados:

37,6 38,0 38,0 38,0 38,4 38,5 39,0 39,5

- Q1 = 25*8 /100 = 2 = posição 2 => Q1 = 38,0
- Q2 = Mediana = (38,0 + 38,4)/ 2 = 38,2
- Q3 = 75*8 /100 = 6 = posição 6 => Q3 = 38,5
- IQ = 38,5 – 38,0 = 0,5
- Amp = 39,5 – 37,6 = 2,9
- Linf = 38 – 1,5 * (38,5 – 38,0) = 37,25
- Lsup = 38,5 + 1,5 * (38,5 – 38,0) = 39,25

Análise de dados

Exploração dos dados – Medidas Estatísticas - Dados Univariados - Espalhamento

- Medidas de espalhamento **medem a dispersão ou espalhamento** de um conjunto de valores.
- **Permite observar** se os **valores estão** amplamente **espalhados** ou relativamente **concentrados** em torno de um valor, por exemplo, a média.
- **As medidas são**:
  - ❑ **Intervalo**
  - ❑ **Variância**
  - ❑ **Desvio Padrão**

Análise de dados

Exploração dos dados – Medidas Estatísticas - Dados Univariados – Espalhamento – Intervalo (amplitude máxima)

- **Mostra** o **espalhamento máximo** entre os **valores de um conjunto**.
- Então, sejam $\mathbf{x^j = \{ x_1, x_2, ..., x_n \}}$, os valores do atributo para n objetos.
- O intervalo desse conjunto é **medido por**:

$$intervalo\,(x^j) = \max_{i=1,\ldots,n}(x_i) - \min_{i=1,\ldots,n}(x_i)$$

Análise de dados

Exploração dos dados – Medidas Estatísticas - Dados Multivariados – Espalhamento - Intervalo

- **Se** a **maioria dos valores** for **próxima de um ponto**, com um **pequeno número de valores extremos**, o intervalo **não será uma boa medida** de espalhamento dos valores.

Análise de dados

Exploração dos dados – Medidas Estatísticas - Dados Univariados – Espalhamento – Variância/Desvio Padrão

- A medida mais utilizada para avaliar o espalhamento de valores. É dada por:

$$variância(x^j) = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x}^j)^2$$

Onde:

$\bar{x}^j$ é a média dos valores de x^j .

n – 1 melhora a estimativa da variância verdadeira do que n, chamada correção de Bessel.

Análise de dados

Exploração dos dados – Medidas Estatísticas - Dados Univariados – Espalhamento – Variância/Desvio Padrão

- O desvio padrão é dado por:

$$desvio\ padrão\ (x^j) = \sqrt[2]{variância(x^j)}$$

- Indica o grau de variação de um conjunto de dados.

- Assim como a média, o valor da **variância pode ser distorcido** pela presença de ***outliers***, pois **calcula** a **diferença** entre **cada valor** e a **média**.

Análise de dados

Exploração dos dados – Medidas Estatísticas - Dados Univariados – Espalhamento – Variância/Desvio Padrão - Exemplo Geral

- Um engenheiro precisa decidir entre três modelos de máquinas de corte de alta precisão, para isso ele usa como critério o desvio padrão. A máquina que tiver menor desvio será a escolhida por ele.
- A partir dos dados de medida de corte das 3 máquinas, determine qual deve ser a escolhida pelo engenheiro.

Máquina 1 (mm) = (181.9, 180.8, 181.9, 180.2, 181.4).
Máquina 2 (mm) = (180.1, 181.8, 181.5, 181.2, 182.4).
Máquina 3 (mm) = (182.1, 183.7, 182.1, 180.2, 181.9).

1: Média= 181.24 Variância= 0,523 Desvio Padrão = 0,737

2: Média= 181.4 Variância= 0,725 Desvio Padrão = 0,851

3: Média= 182 Variância= 1,54 Desvio Padrão = 1,24

Análise de dados

Exploração dos dados – Medidas Estatísticas - Dados univariados - Localidade – Exemplo - Variância/Desvio Padrão

Id.	Nome	Idade	Sexo	Peso	Manchas	Temp.	# Int.	Est.	Diagnóstico
4201	João	28	M	79	Concentradas	38,0	2	SP	Doente
3217	Maria	18	F	67	Inexistentes	39,5	4	MG	Doente
4039	Luiz	49	M	92	Espalhadas	38,0	2	RS	Saudável
1920	José	18	M	43	Inexistentes	38,5	8	MG	Doente
4340	Cláudia	21	F	52	Uniformes	37,6	1	PE	Saudável
2301	Ana	22	F	72	Inexistentes	38,0	3	RJ	Doente
1322	Marta	19	F	87	Espalhadas	39,0	6	AM	Doente
3027	Paulo	34	M	67	Uniformes	38,4	2	GO	Saudável

- Média = 38,375
- Mediana = 38,2
- Moda = 38
- Variância: 0, 385
- Desvio Padrão = 0,62

Qual a variância e o desvio padrão para a variável Temp.?

Análise de dados

Exploração dos dados – Medidas Estatísticas - Dados Multivariados

- São **aqueles** que possuem **mais de um atributo de entrada**. Exemplo: o **conjunto de dados hospital** é multivariado.

- Nesses casos, **as medidas de localidade** podem ser **obtidas** calculando **para cada atributo separadamente**.

- Assim, a **média** para um conjunto de **objetos** com **d atributos seria**:

$$\bar{x} = (\bar{x}^1, \ldots, \bar{x}^d)$$

Análise de dados

Exploração dos dados – Medidas Estatísticas - Dados Multivariados – Covariância

- Permite **avaliar dados entre dois ou mais atributos**.

- Exemplo:

  - **atributos quantitativos**, o espalhamento de um conjunto de dados é **mais bem capturado por uma matriz de covariância**, em que **cada elemento** é a **covariância entre dois atributos**.

Análise de dados

Exploração dos dados – Medidas Estatísticas - Dados Multivariados – Covariância

- Cada elemento cov_{ij} de uma matriz de covariância Cov **mede a covariância entre os atributos x^i e x^j** e é dado por:

$$covariância(x^i, x^j) = \frac{1}{n-1} \sum_{k=1}^{n} (x_k^i - \bar{x}^i)\,(x_k^j - \bar{x}^j)$$

$\bar{x}^i$ representa o valor médio do i-ésimo atributo

x^i_k, o valor do i-ésimo atributo para o k-ésimo objeto.

Análise de dados

Exploração dos dados – Medidas Estatísticas - Dados Multivariados – Covariância

- A covariância(x^i, x^i) = variância (x^i).

- Então, a diagonal da matriz apresenta as variâncias dos atributos.

Análise de dados

Exploração dos dados – Medidas Estatísticas - Dados Multivariados – Covariância

- **A covariância entre dois atributos mede o grau com que os atributos variam juntos.**
- Um **valor próximo de 0 indica** que os atributos **não tem um relacionamento linear**.
- Um **valor positivo** indica que **os atributos são diretamente relacionados**, ou seja, quando o valor de um dos atributos aumenta, o outro também.
- **O contrário ocorre se a covariância for negativa**.

Análise de dados

Exploração dos dados – Medidas Estatísticas - Dados Multivariados – Covariância

- **É afetada pela dimensão dos atributos avaliados.**
- Assim, dois **atributos com dimensão elevada podem apresentar um valor de covariância maior** que dois atributos semelhantes entre si, mas de menor dimensão.
- Por isso, **não é possível avaliar o relacionamento entre dois atributos somente pela covariância**.

Análise de dados

Exploração dos dados – Medidas Estatísticas - Dados Multivariados – Correlação

- **A correlação elimina o problema da influência da dimensão.**
- A correlação **apresenta uma indicação** mais **clara da força da relação linear entre dois atributos.**
- A correlação é **mais utilizada** para explorar **dados multivariados**.

Análise de dados

Exploração dos dados – Medidas Estatísticas - Dados Multivariados – Correlação

- Cada elemento da **matriz de correlação tem seu valor definido por**:

$$correlação(x^i, x^j) = \frac{covariância(x^i, x^j)}{s_i s_j}$$

  - x^i é o i-ésimo atributo.
  - s_i é o desvio padrão dos valores desse atributo.

- correlação(x^i, x^i) = 1. Diagonal da matriz têm o valor 1.
- Os demais elementos têm valor entre **-1** (**correlação negativa máxima**) e **+1** (**correlação positiva máxima**).

Análise de dados

Exploração dos dados – Medidas Estatísticas - Dados Multivariados – Correlação

- Quando **dois atributos** apresentam uma **correlação positiva**, o **aumento** do valor de **um deles** é geralmente acompanhado por um **aumento** no valor **do outro**.

- Quando **dois atributos** têm **correlação negativa**, a **redução** no valor de **um deles** é geralmente acompanhada do **aumento no outro** valor (os dois atributos movem-se em direções opostas).

Análise de dados

Exploração dos dados – Medidas Estatísticas - Dados Multivariados – Correlação

Considere correlação(x, y), se o resultado for:

- **-1** indica uma forte correlação negativa: isso significa que toda vez que **x aumenta, y diminui**.
- **0** significa que **não há associação entre as duas variáveis** (x e y).
- **1** indica uma forte correlação positiva: isso significa que **y aumenta com x**.

Análise de dados

Exploração dos dados – Medidas Estatísticas - Dados Multivariados – Covariância/Correlação

Id.	Nome	Idade	Sexo	Peso	Manchas	Temp.	# Int.	Est.	Diagnóstico
4201	João	28	M	79	Concentradas	38,0	2	SP	Doente
3217	Maria	18	F	67	Inexistentes	39,5	4	MG	Doente
4039	Luiz	49	M	92	Espalhadas	38,0	2	RS	Saudável
1920	José	18	M	43	Inexistentes	38,5	8	MG	Doente
4340	Cláudia	21	F	52	Uniformes	37,6	1	PE	Saudável
2301	Ana	22	F	72	Inexistentes	38,0	3	RJ	Doente
1322	Marta	19	F	87	Espalhadas	39,0	6	AM	Doente
3027	Paulo	34	M	67	Uniformes	38,4	2	GO	Saudável

Medidas	Idade	Peso	
Média	26.125	70	
Mediana	21.5	69.5	
Moda	18	67	
Variância	116,41	282	
Desvio Padrão	10,79	16,79	
Covariância			103,71
Correlação			0,57

Qual a covariância e a correlação para as variáveis Idade e Peso?

Análise de dados

Exploração dos dados – Dados Multivariados

- A **análise de dados univariados** pode ser **facilitada** pelo **histograma**.
- A **análise dos dados multivariados** pode ser **facilitada pelo uso de recursos de visualização**.
- Um dos mais utilizados é o *scatter plot* (dispersão), que ilustra a correlação linear entre dois atributos ou três (*scatter plot* tridimensional).
- Algumas técnicas de visualização utilizadas são: *bagplot*, diagrama de *Chernoff*, *star plot* e *heatmap*.

Bibliografia

BÁSICA:

- AGGARWAL, Charu C. **Artificial Intelligence: A Textbook**. New York: Springer: 2021.
- CHOLLET, François. **Deep Learning with Python, 2ed.** Shelter Island: Manning, 2021.
- GÉRON, Aurélien. **Hands-On Machine Learning with Scikit-Learn and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems**, 2 ed**.** Sebastopol: O'Reilly, 2019.

COMPLEMENTAR:

- GOODFELLOW, Ian; BENGIO, Yoshua, COURVILLE, Aaron. **Deep Learning**. Cambridge: MIT Press, 2016.
- RASCHKA, Sebastian; MIRJALILI, Vahid. **Python Machine Learning**. 3 ed. Birmingham: Packt, 2017.
- RUSSEL, Stuart; NORVIG, Peter. **Artificial Intelligence: A Modern Approach**. 3 ed. Upper Saddle River: Pearson, 2010.
- TAN, Pang-Ning; STEINBACH, Michael; KUMAR, Vipin. **Introduction to Data Mining**. 2 ed. Upper Saddle River: Pearson, 2018.
- VANDERPLAS, Jake. **Python Data Science Handbook**. Sebastopol: O'Reilly, 2017.

ADICIONAIS:

- FACELI, Katti et al. **Inteligência artificial: uma abordagem de aprendizado de máquina**. 2ª Ed. Rio de Janeiro: LTC-Livros Técnicos e Científicos, 2021.
- LUGER, George F. **Inteligência Artificial** - 6ª ed. São Paulo: Pearson Education do Brasil, 2015.
- RUSSELL, Stuart; NORVIG, Peter. **Inteligência artificial: Uma Abordagem Moderna** - 4ª. Ed. GEN LTC, 2022.