Inteligência Artificial

Compreensão e Análise Exploratória dos dados por meio da Estatística e da Visualização – Parte II

Prof. Dr. Ivan Carlos Alcântara de Oliveira

https://orcid.org/0000-0002-6020-7535

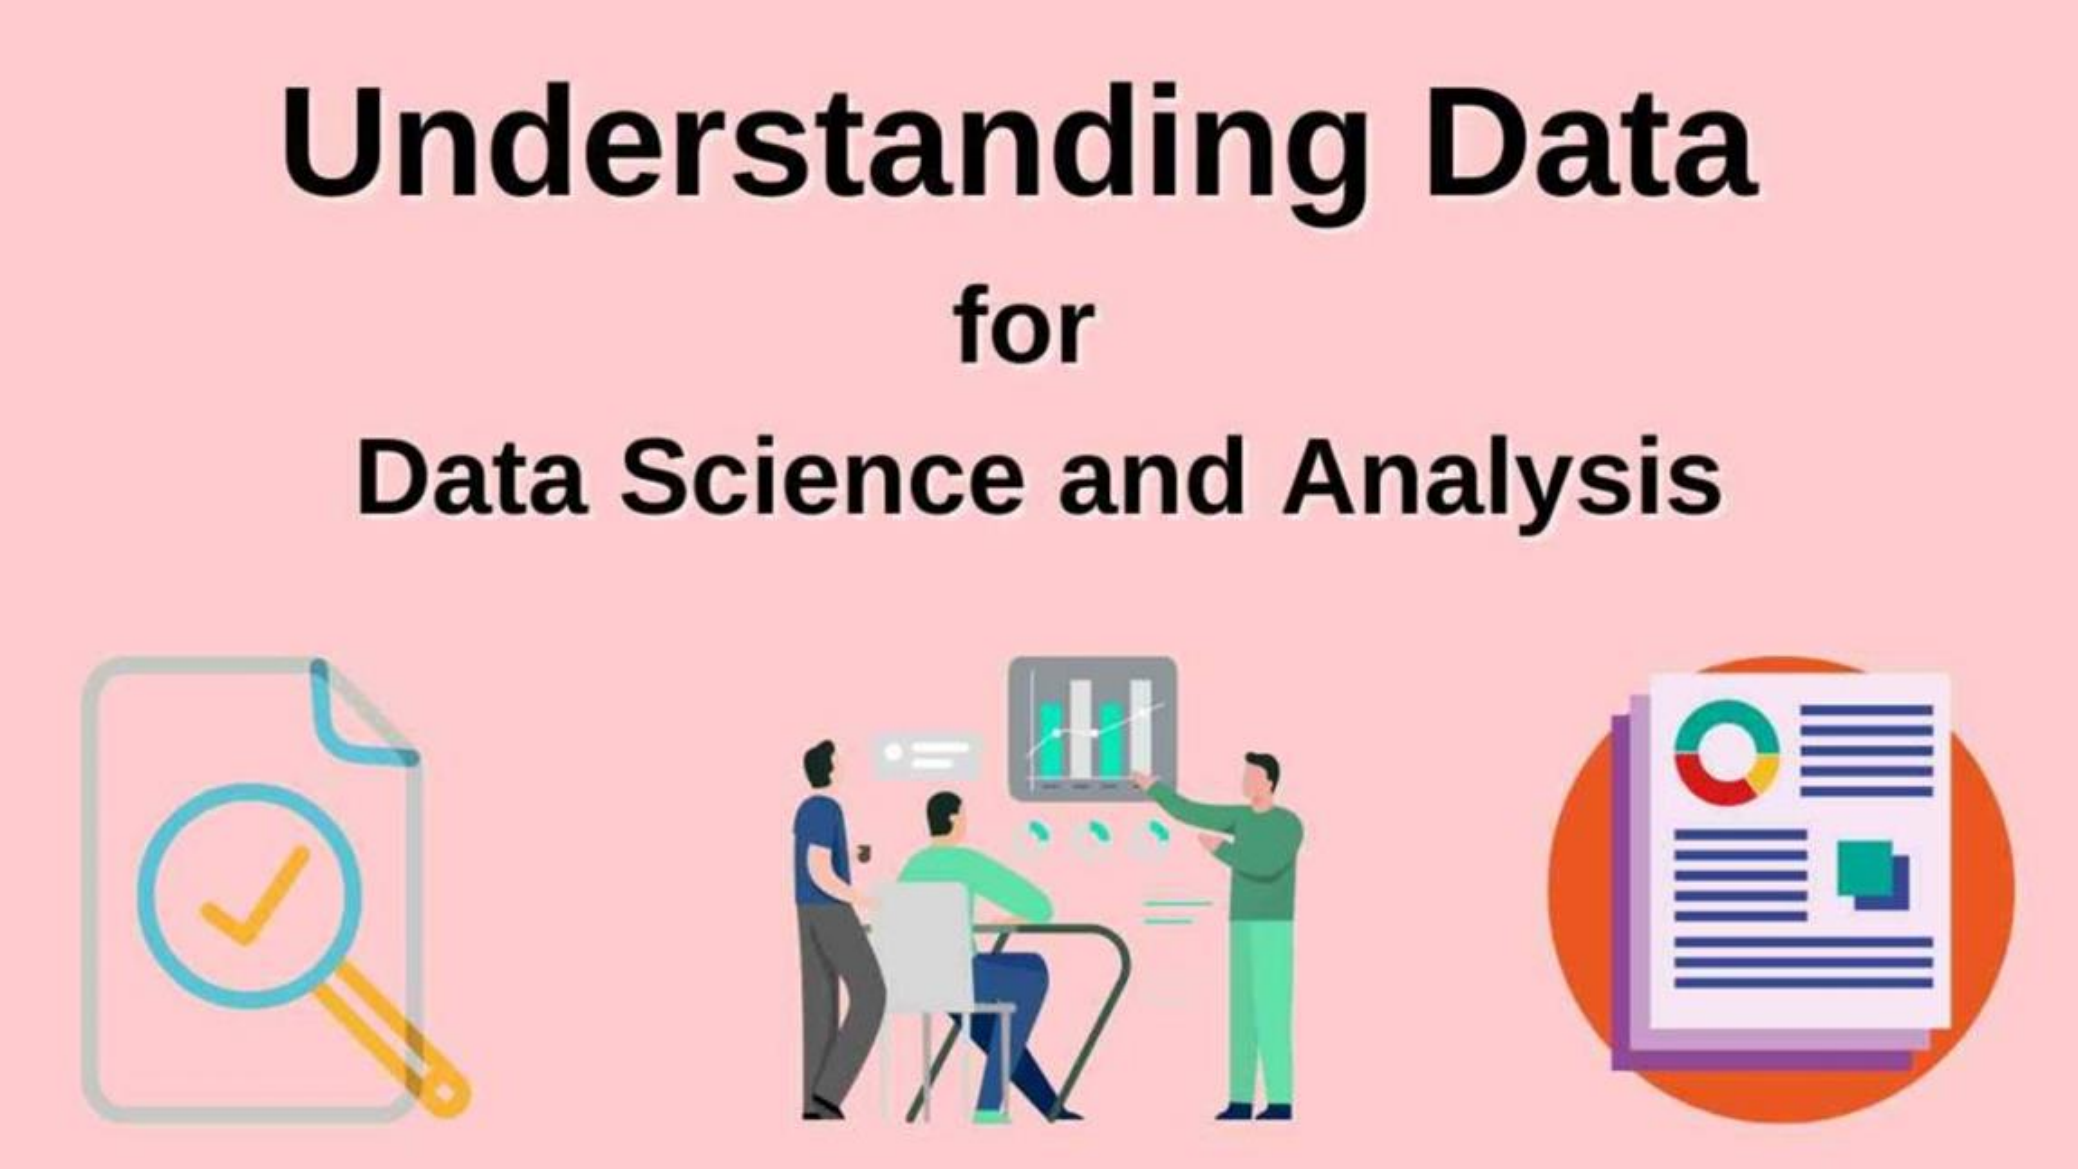

Fonte: https://analyticslearn.com/understanding-data-for-data-science#google_vignette. Data da Consulta: 01/03/2024.

Ciclo de Vida de Projeto de Data Science

CRISP-DM

- **CRISP-DM (*Cross Industry Standard Process for Data Mining* -** Processo Padrão Interindústrias para Mineração de Dados) é um processo de fases bastante aceito na indústria para representar um ciclo completo de Ciência e Análise de Dados, incluído a aplicação de modelos de Aprendizado de Máquina.

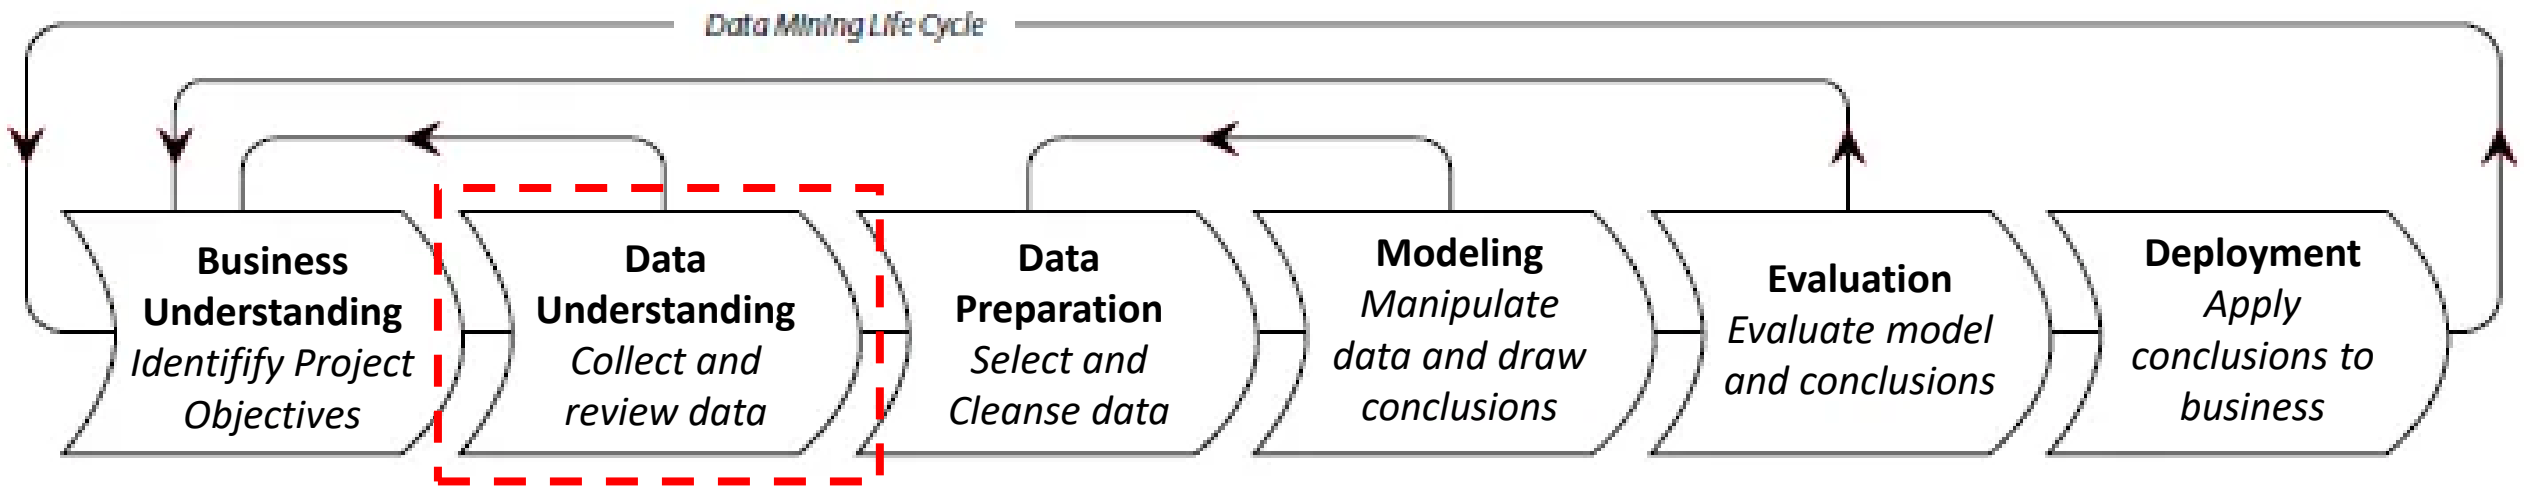

Auxiliar na Identificação	Obtenção dos dados	Pré-processamento	Seleção do modelo	Validação do modelo	Aplica solução obtida ao negócio
Compreensão	Integração	Transformação de Variáveis	Cross-Validation	Otimização	Desenvolvimento de Aplicação Analítica
Pesquisas e Estudos	Análise Exploratória	Seleção de Atributos	Métricas de performance		Geração de relatório
Reunião com Especialistas		Redução de Dimensionalidade	Otimização		Construção de Dashborads etc.
Definição dos Atributos		Amostragem			
Definição medida de erro					

Ciência de Dados

Ciclo de Vida de Projeto de *Data Science*

2. **Compreensão dos Dados**

Coletar e Entender os dados para resolver aquele problema.

Nesse processo, pode ser útil utilizar análise exploratória e elaboração de gráficos.

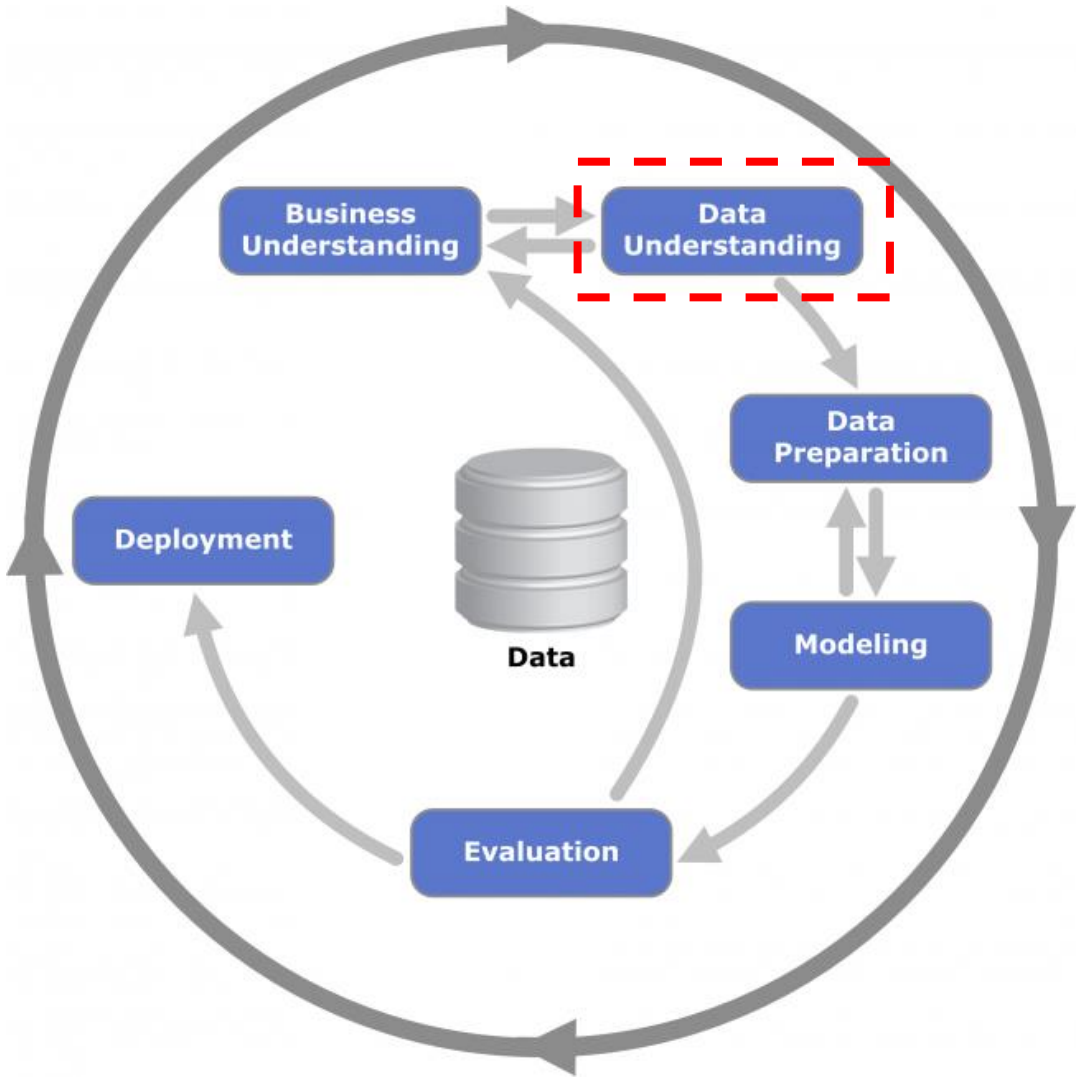

Compreensão/Análise dos Dados

Técnicas de Visualização

- Algumas técnicas de visualização úteis para compreensão e análise exploratória de dados são:

  - **Histograma**
    - Coeficiente de Assimetria (Sk)
    - Coeficiente de Curtose (Ck)

  - **Gráfico de Dispersão** (Scatter plot – bidimensional ou tridimensional)
    - Relação com a Correlação

  - ***Heat Map*** (mapa de calor)
    - Relação com a Correlação

Compreensão/Análise dos Dados

Técnicas de Visualização - Histograma

- Um histograma é um modelo de gráfico que **representa uma distribuição de frequências por meio de um agrupamento de classes**, de forma que se pode contabilizar as ocorrências dos dados em cada classe.

- Os conceitos de **Frequência Absoluta** e **Frequência Relativa são importantes** na **construção** de um histograma.

- **Possibilita visualizar** a **distribuição de medidas**, a **dispersão**, **simetria dos dados** e **tendências centrais**.

Compreensão/Análise dos Dados

Técnicas de Visualização - Histograma – Utilidade

- Para **analisar a amplitude da dispersão** em um determinado conjunto de dados;
- **Avaliar** se o conjunto de dados analisados é **simétrico**;
- Descobrir **qual** dos **valores** apresentados é o **mais comum**;
- Verificar se **há mais de um pico** no gráfico;
- Analisar se **há valores isolados** no conjunto de dados utilizado;
- **Saber se** alguns **valores tendem a estarem presentes ou ausentes**.

Fonte: https://www.ibccoaching.com.br/portal/aprenda-como-fazer-um-histograma-passo-passo/. Data da Consulta: 20 de abril de 2019.

Compreensão/Análise dos Dados

Técnicas de Visualização - Histograma - Como fazer um histograma manualmente?

1- **Ordenar os valores**

2- **Encontrar a amplitude total**: A = xmax - xmin. Assim, os intervalos devem cobrir uma faixa de, no mínimo, o valor da amplitude.

3- **Estimar o número de classes k** (**breaks** ou **bins** é similar a barras): k <= n. Onde n é a raiz quadrada do total de observações. Isso não é uma regra! Na prática deve ser menor ou igual ao total de observações.

4- **Estimar o tamanho de cada intervalo C de classe**: C = A/k

5- **Contar o número de observações que caem em cada intervalo de classe** (subintervalo), frequência.

6- **Determinar a frequência absoluta ou relativa do intervalo**.

Frequência relativa = frequência absoluta/total de observações * 100.

7- **Construir o gráfico**.

Compreensão/Análise dos Dados

Técnicas de Visualização - Histograma - Como fazer um histograma manualmente? - Exemplo

- Os seguintes dados representam o **número de acidentes diários em um complexo industrial** (colocados em ordem crescente), durante o período de **50 dias**.

dados = (18, 20, 20, 21, 22, 24, 25, 25, 26, 27, 29, 29, 30, 30, 31, 31, 32, 33, 34, 35, 36, 36, 37, 37, 37, 37, 38, 38, 38, 40, 41, 43, 44, 44, 45, 45, 45, 46, 47, 48, 49, 50, 51, 53, 54, 54, 56, 58, 62, 65)

Vamos representar o histograma desses dados?

Compreensão/Análise dos Dados

Técnicas de Visualização - Histograma - Como fazer um histograma manualmente? – Exemplo – com **10 breaks (bins)**

- 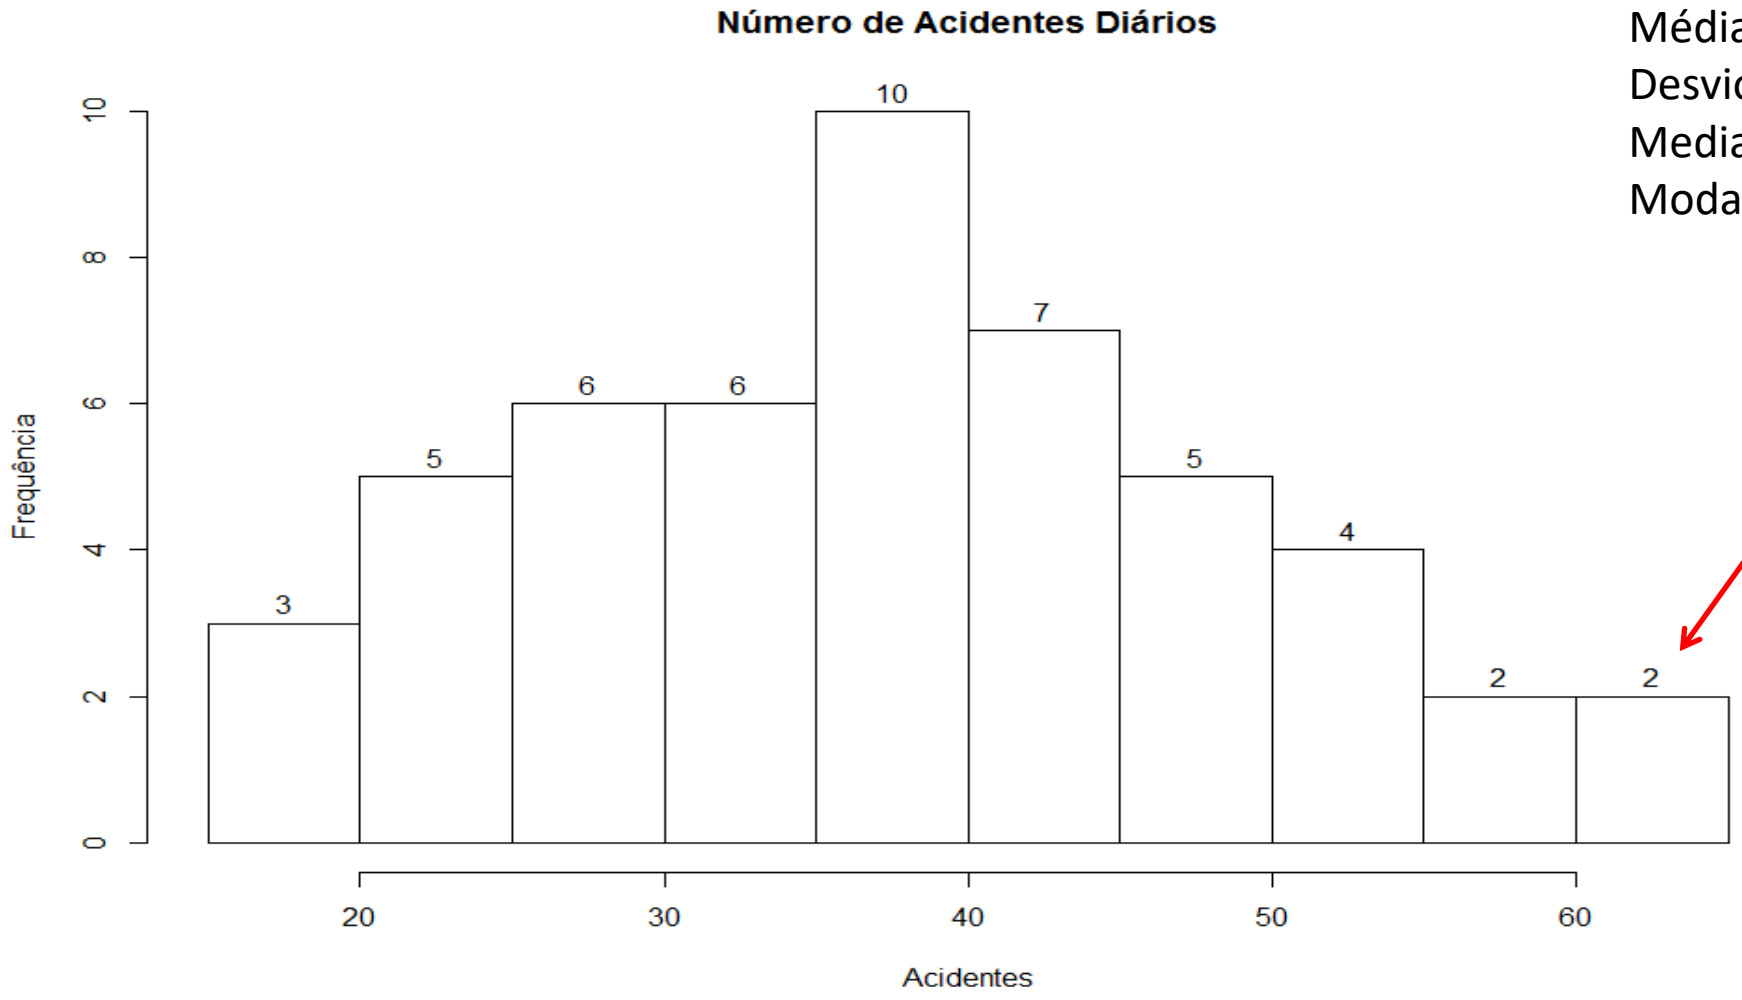

Média = 38.32
Desvio Padrão = 11.58
Mediana = 37
Moda = 37

bins ou breaks

Compreensão/Análise dos Dados

Técnicas de Visualização - Histograma - Como fazer um histograma manualmente? – Exemplo – Com **6 breaks (bins)**

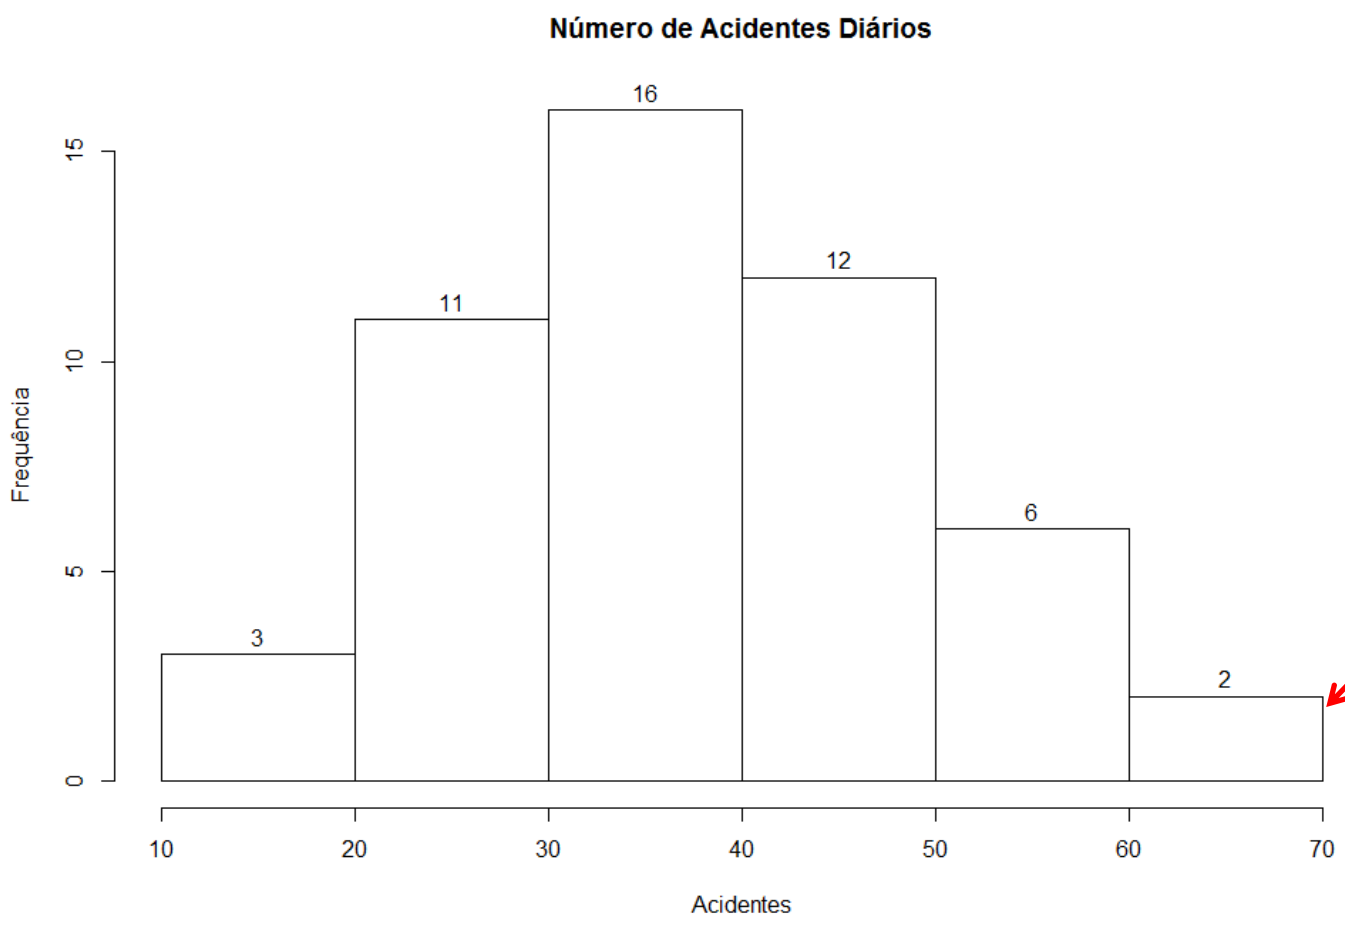

Média = 38.32
Desvio Padrão = 11.58
Mediana = 37
Moda = 37

bins

Compreensão/Análise dos Dados

Medidas de Forma – Skewness e Kurtosis

- As **medidas de assimetria (skewness)** e **curtose (kurtosis) caracterizam** a **forma e distribuição** de elementos **em torno da média**.
- Permitem compreender como os dados estão distribuídos.
- Muito importante para a Ciência de Dados, pois **de acordo com a distribuição dos dados será necessário aplicar alguma técnica para ajustar os dados antes da modelagem preditiva**.
- **Com base nos resultados dos coeficientes**, pode-se **tomar decisões de quais técnicas devem sera aplicadas aos dados** para fazer as devidas transformações e ajustes de acordo com o algoritmo de Aprendizado de Máquina que será utilizado na etapa de modelagem preditiva.

Compreensão/Análise dos Dados

Medidas de Forma – **Skewness** e Kurtosis

- **Skewness** é uma **medida da assimetria da distribuição de probabilidade de uma variável aleatória** de valor real **sobre a sua media**.
- O **valor da assimetria** pode ser **positivo**, **negativo** ou **indefinido**.
- Em uma **distribuiçao normal perfeita**, as **caudas de cada lado** da curva **são imagens espelhadas exatas uma da outra**.

Distribuição Simétrica

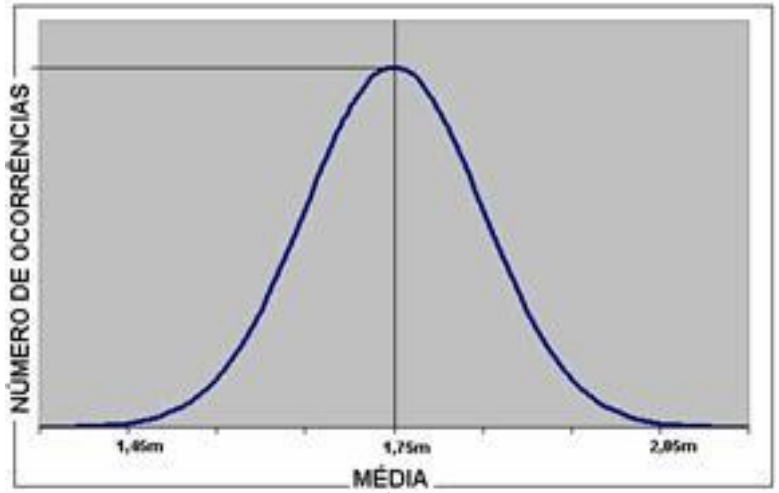

Mediana

Moda

Compreensão/Análise dos Dados

Medidas de Forma – **Skewness** e Kurtosis

- **Assimetria positiva:** quando a **distribuição é inclinada para a direita**, a **cauda no lado direito** da curva é **maior que a cauda no lado esquerdo**, e a **media é maior que a moda**.

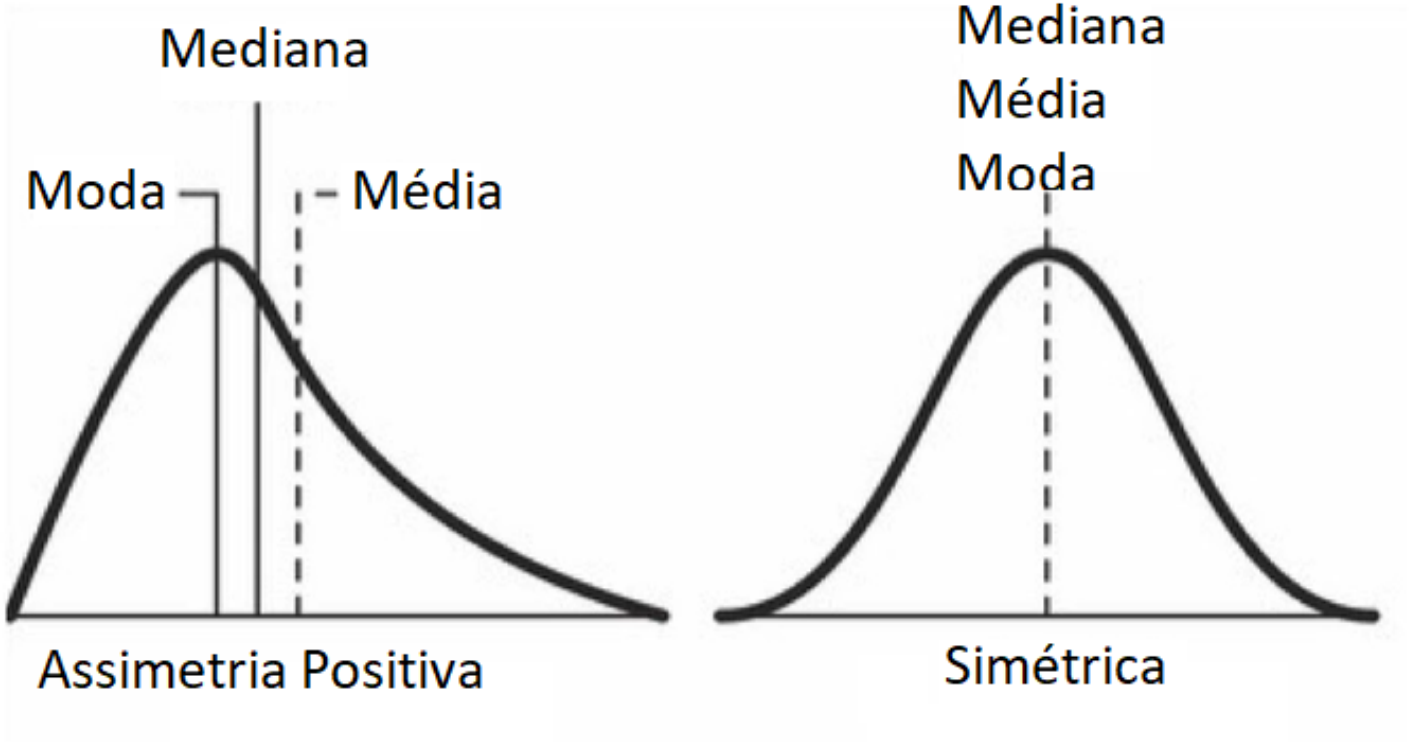

Compreensão/Análise dos Dados

Medidas de Forma – **Skewness** e Kurtosis

- **Assimetria negativa**: quando uma **distribuição** é **inclinada para a esquerda**, a **cauda do lado esquerdo** da curva é **maior que a cauda do lado direito**, e a **media** é **menor que** a **moda**.

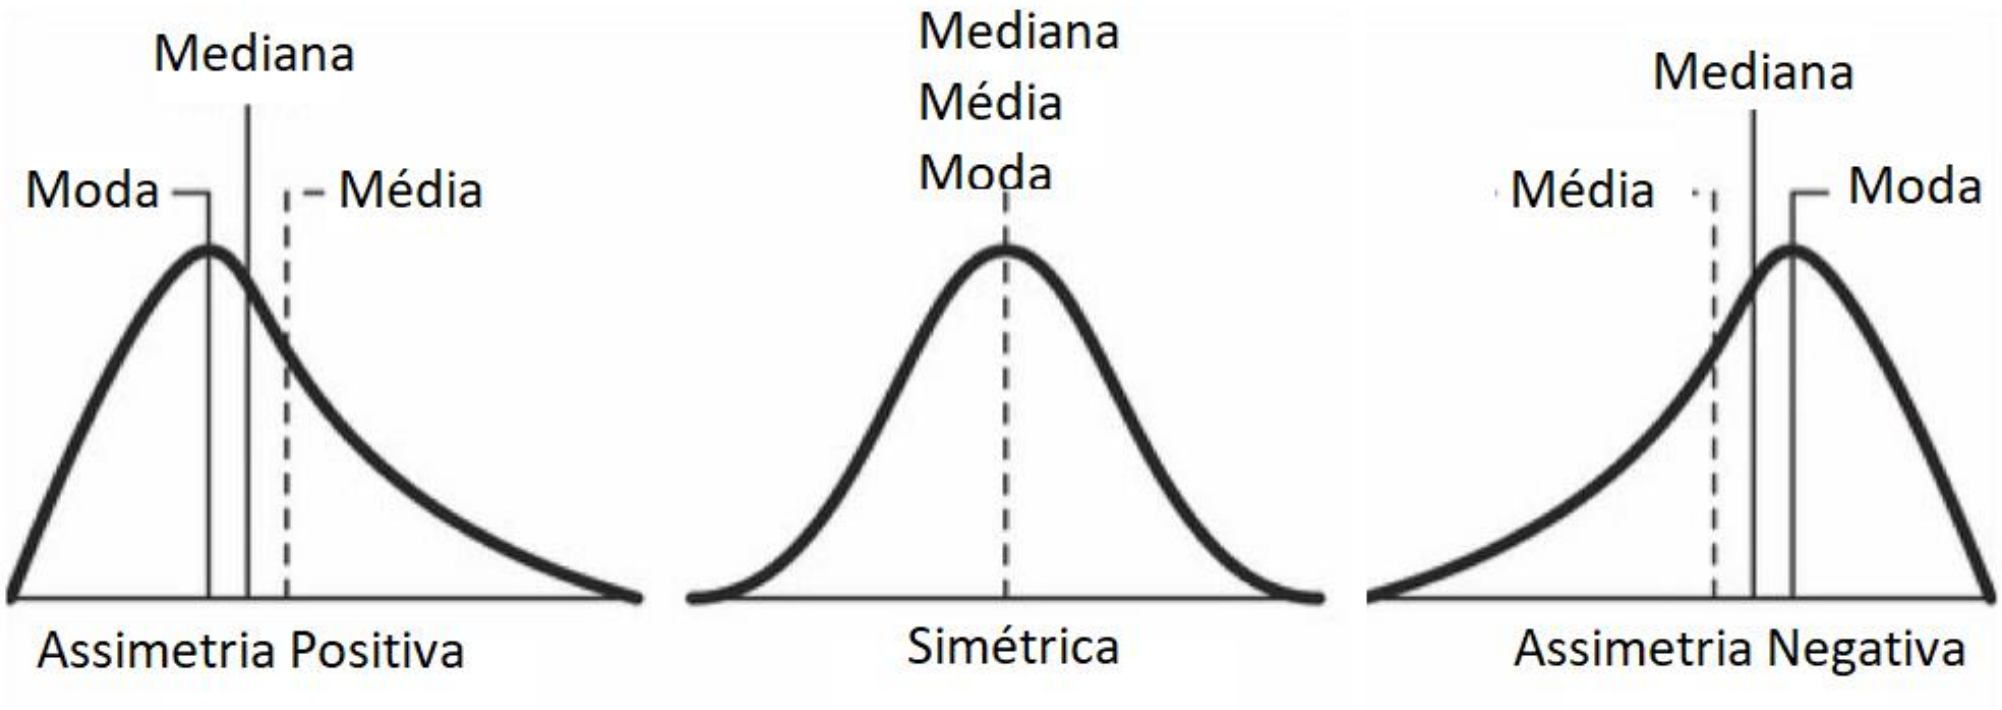

Compreensão/Análise dos Dados

Medidas de Forma – Skewness e Kurtosis

- **Se** identificado que a distribuição **tem assimetria positiva** ou negativa, **talvez** seja necessário a**plicar alguma técnica estatística** para trazer os dados **para uma distribuição simétrica**.

- Pois, alguns **algoritmos de Aprendizado de máquina exigem** que isso seja feito.

Compreensão/Análise dos Dados

Medidas de Forma – **Skewness** e Kurtosis

- Seja uma variável (atributo) $x = (x_1, x_2, \ldots, x_n)$

- Para calcular o **coeficiente de assimetria (*Skewness*)**, pode-se utilizar qualquer das **duas fórmulas** abaixo:

$$Moda\ Skewness(x) = Primeiro\ Coeficiente\ de\ Skewness(x) = \frac{Média(x) - Moda(x)}{Desvio\ padrão(x)}$$

$$Mediana\ Skewness(x) = Segundo\ Coeficiente\ de\ Skewness(x) = \frac{3 * (Média(x) - Mediana(x))}{Desvio\ padrão(x)}$$

Compreensão/Análise dos Dados

Técnicas de Visualização - Histograma - Coeficiente de Assimetria ou Skewness (Sk)

- No **coeficiente de assimetria** ou **Skewness** (Sk), a direção da assimetria é dada pelo sinal. Então:
  - **Sk = 0**: **nenhuma assimetria**.
  - **Sk < 0**: **assimetria negativa**.
  - **Sk > 0**: **assimetria positiva**.
- O coeficiente compara a distribuição da amostra com uma distribuição normal. Quanto maior o valor, mais a distribuição difere de uma distribuição normal.

Compreensão/Análise dos Dados

Técnicas de Visualização - Histograma - **Coeficiente de Assimetria ou Skewness (Sk)**

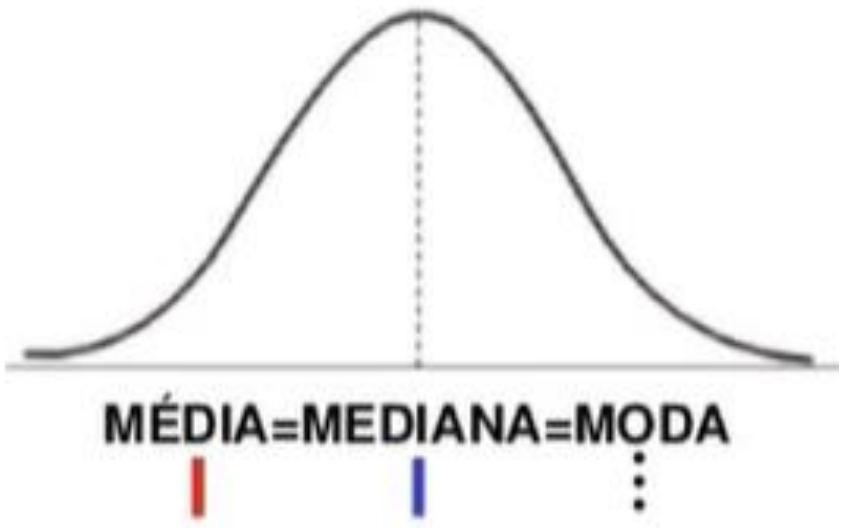

Distribuição
Simétrica

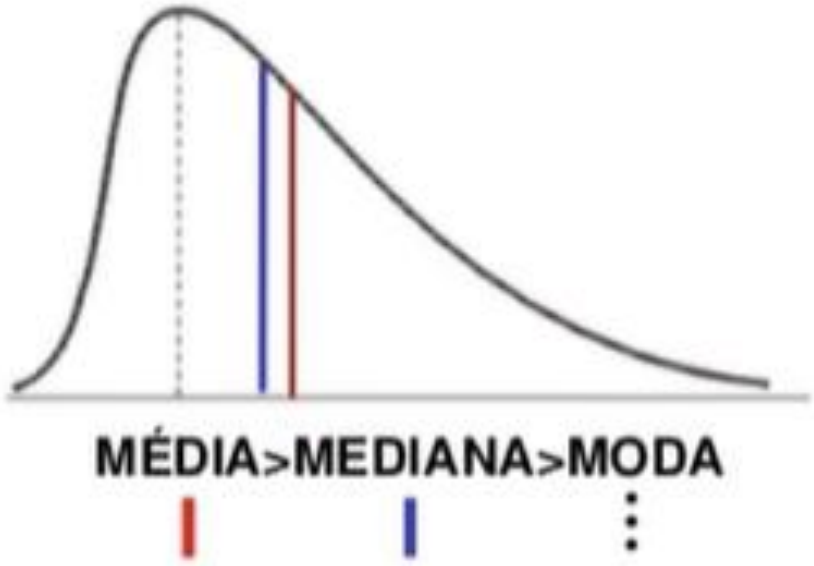

Distribuição Assimétrica
Positiva ou à direita

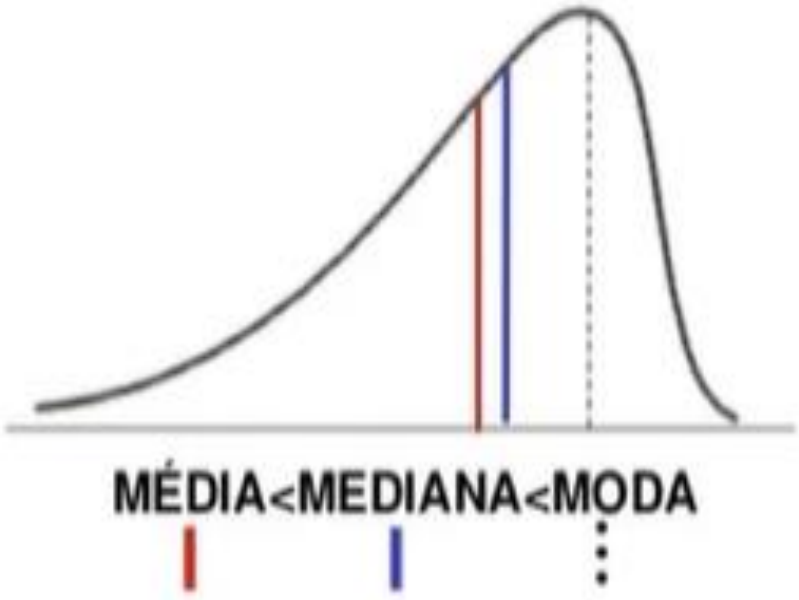

Distribuição Assimétrica
Negativa ou à esquerda

Compreensão/Análise dos Dados

Técnicas de Visualização - **Histograma** - Coeficiente de Assimetria ou Skewness (Sk) - Exemplo

- Os seguintes dados representam o **número de acidentes diários em um complexo industrial** (colocados em ordem crescente), durante o período de **50 dias**.

dados = (18, 20, 20, 21, 22, 24, 25, 25, 26, 27, 29, 29, 30, 30, 31, 31, 32, 33, 34, 35, 36, 36, 37, 37, 37, 37, 38, 38, 38, 40, 41, 43, 44, 44, 45, 45, 45, 46, 47, 48, 49, 50, 51, 53, 54, 54, 56, 58, 62, 65).

- Vamos representar o histograma desses dados e ver coeficiente de assimetria?

Compreensão/Análise dos Dados

Técnicas de Visualização - Histograma – Coeficiente de Assimetria ou Skewness (Sk)

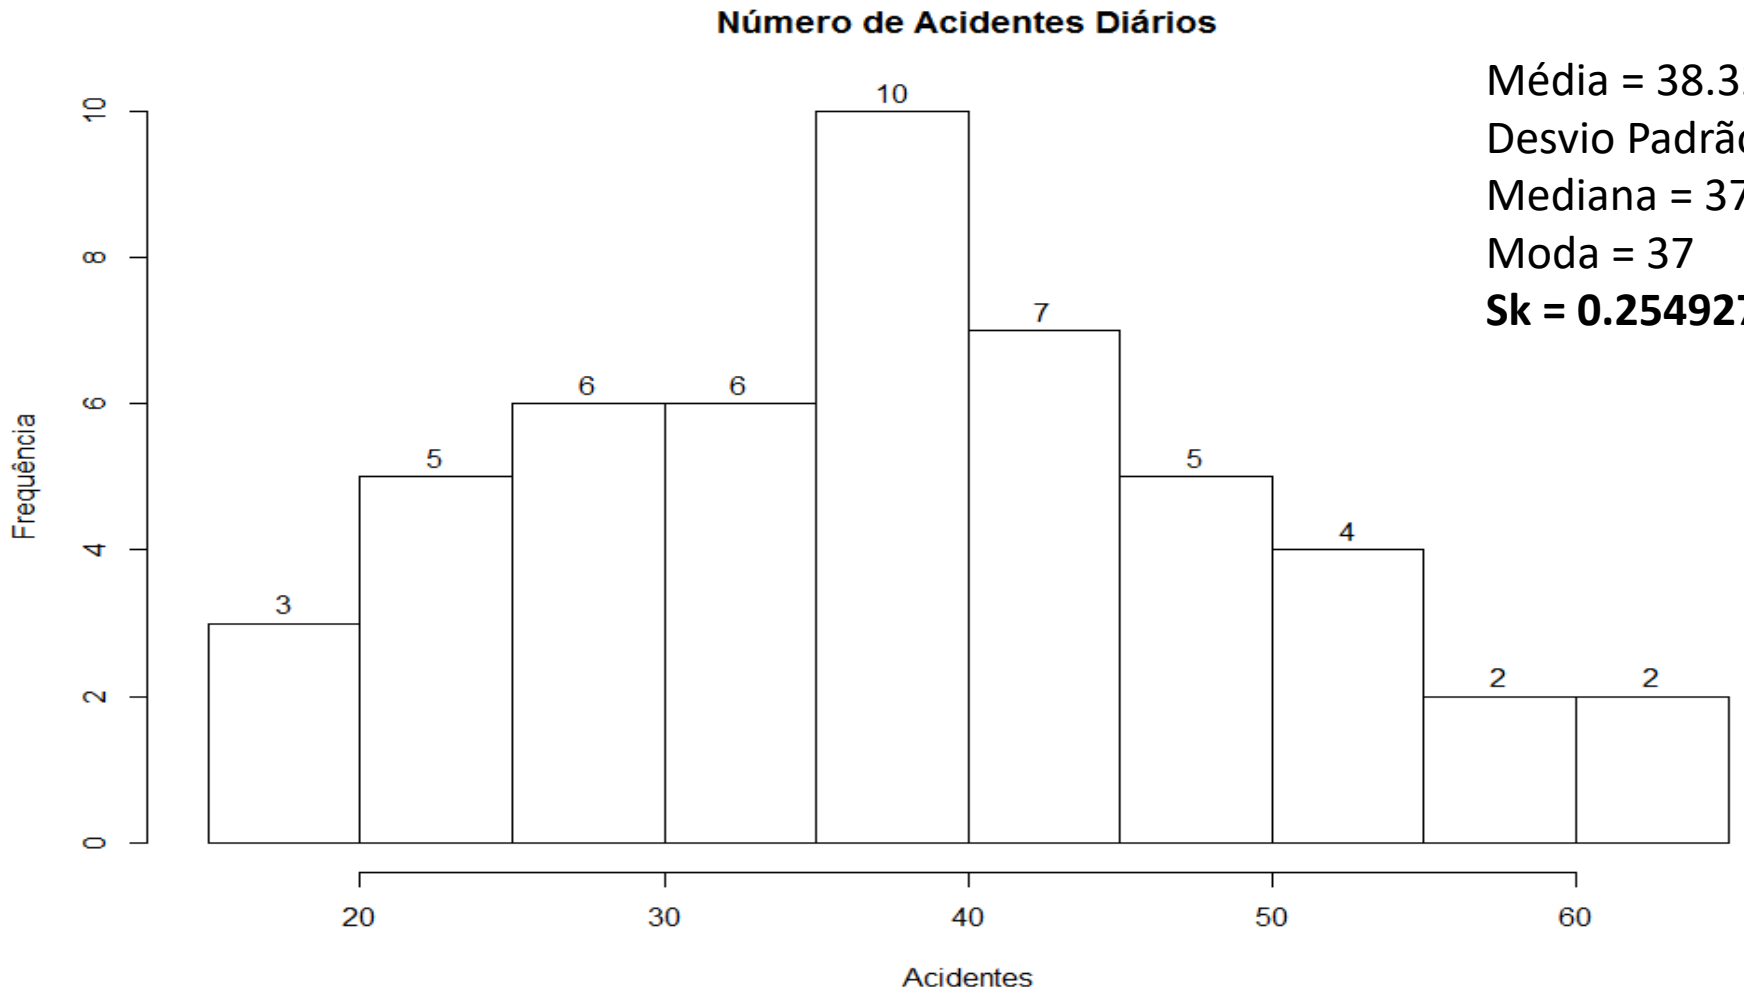

Média = 38.32
Desvio Padrão = 11.58
Mediana = 37
Moda = 37
Sk = 0.2549279

Compreensão/Análise dos Dados

Técnicas de Visualização - Histograma - Coeficiente de Assimetria ou Skewness (Sk)

- Como o coeficiente de assimetria é maior que 0 (**Sk > 0**), diz-se que a curva apresenta **assimetria positiva** e **a cauda do lado direito** da função **tem densidade de probabilidade maior** que no lado esquerdo.

  - Média (38.32) > Mediana (37) = Moda (37)

Compreensão/Análise dos Dados

Técnicas de Visualização - Histograma - Coeficiente de Curtose ou Kurtosis (Ck)

- Um dos **coeficiente**s mais **utilizado**s **para medir o grau de achatamento** ou **curtose de uma distribuição** é o coeficiente percentílico de curtose, ou simplesmente coeficiente de curtose (k), **calculado a partir do intervalo interquartil dos percentis de ordem 10 e 90**.

- É exatamente o contrário do Skewness.

- **Indica o achatamento da curva**, **mais ou menos achatada em relação à curva normal**.

Compreensão/Análise dos Dados

Técnicas de Visualização - Histograma - Coeficiente de Curtose ou Kurtosis (Ck)

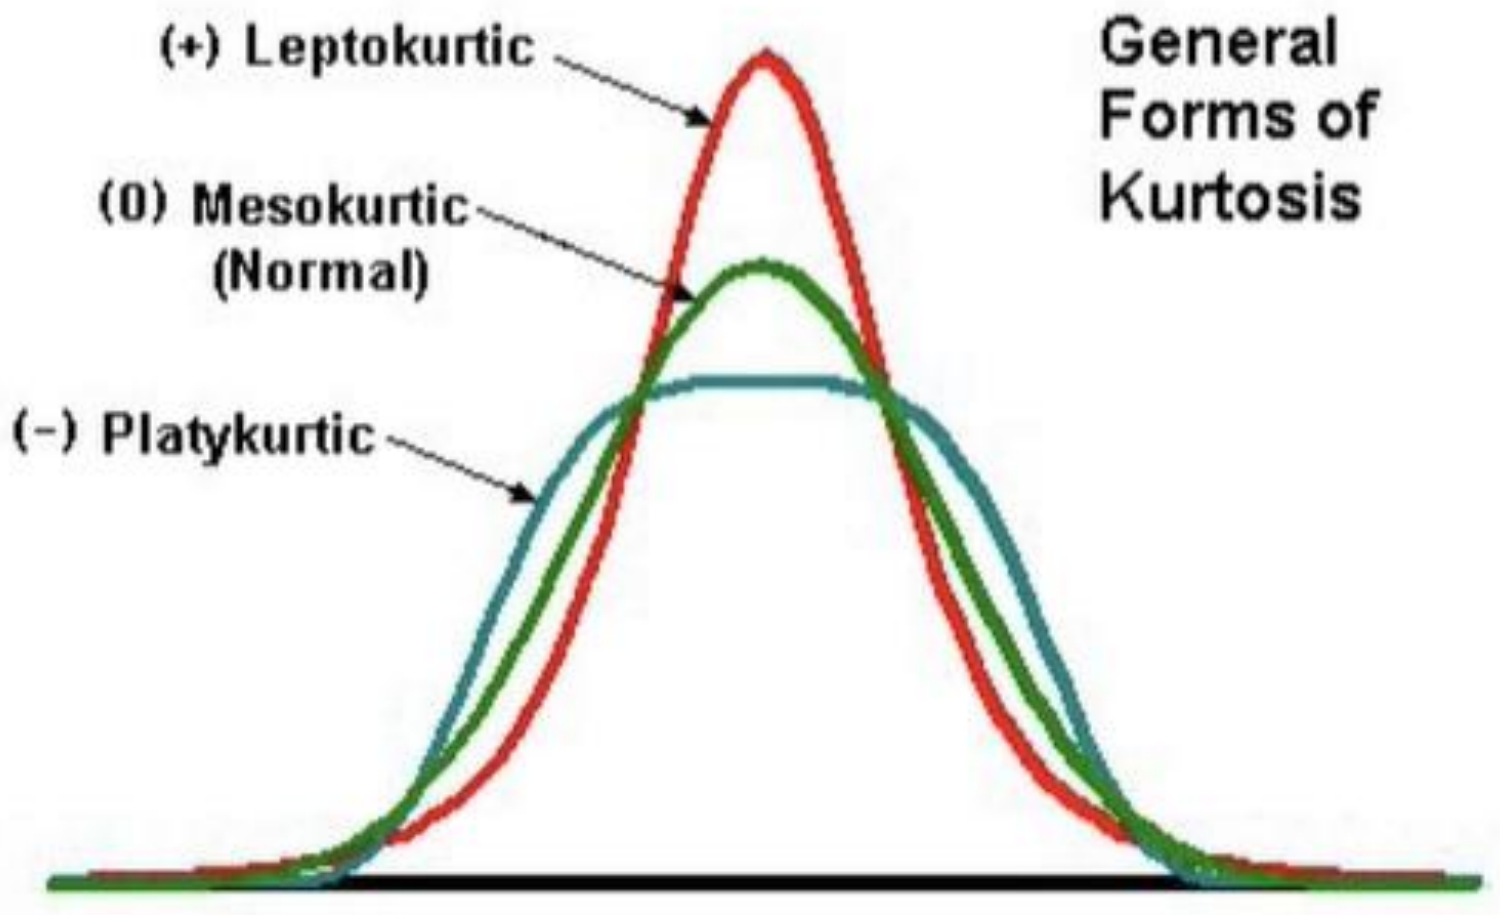

Compreensão/Análise dos Dados

Técnicas de Visualização - Histograma - Coeficiente de Curtose ou Kurtosis (Ck)

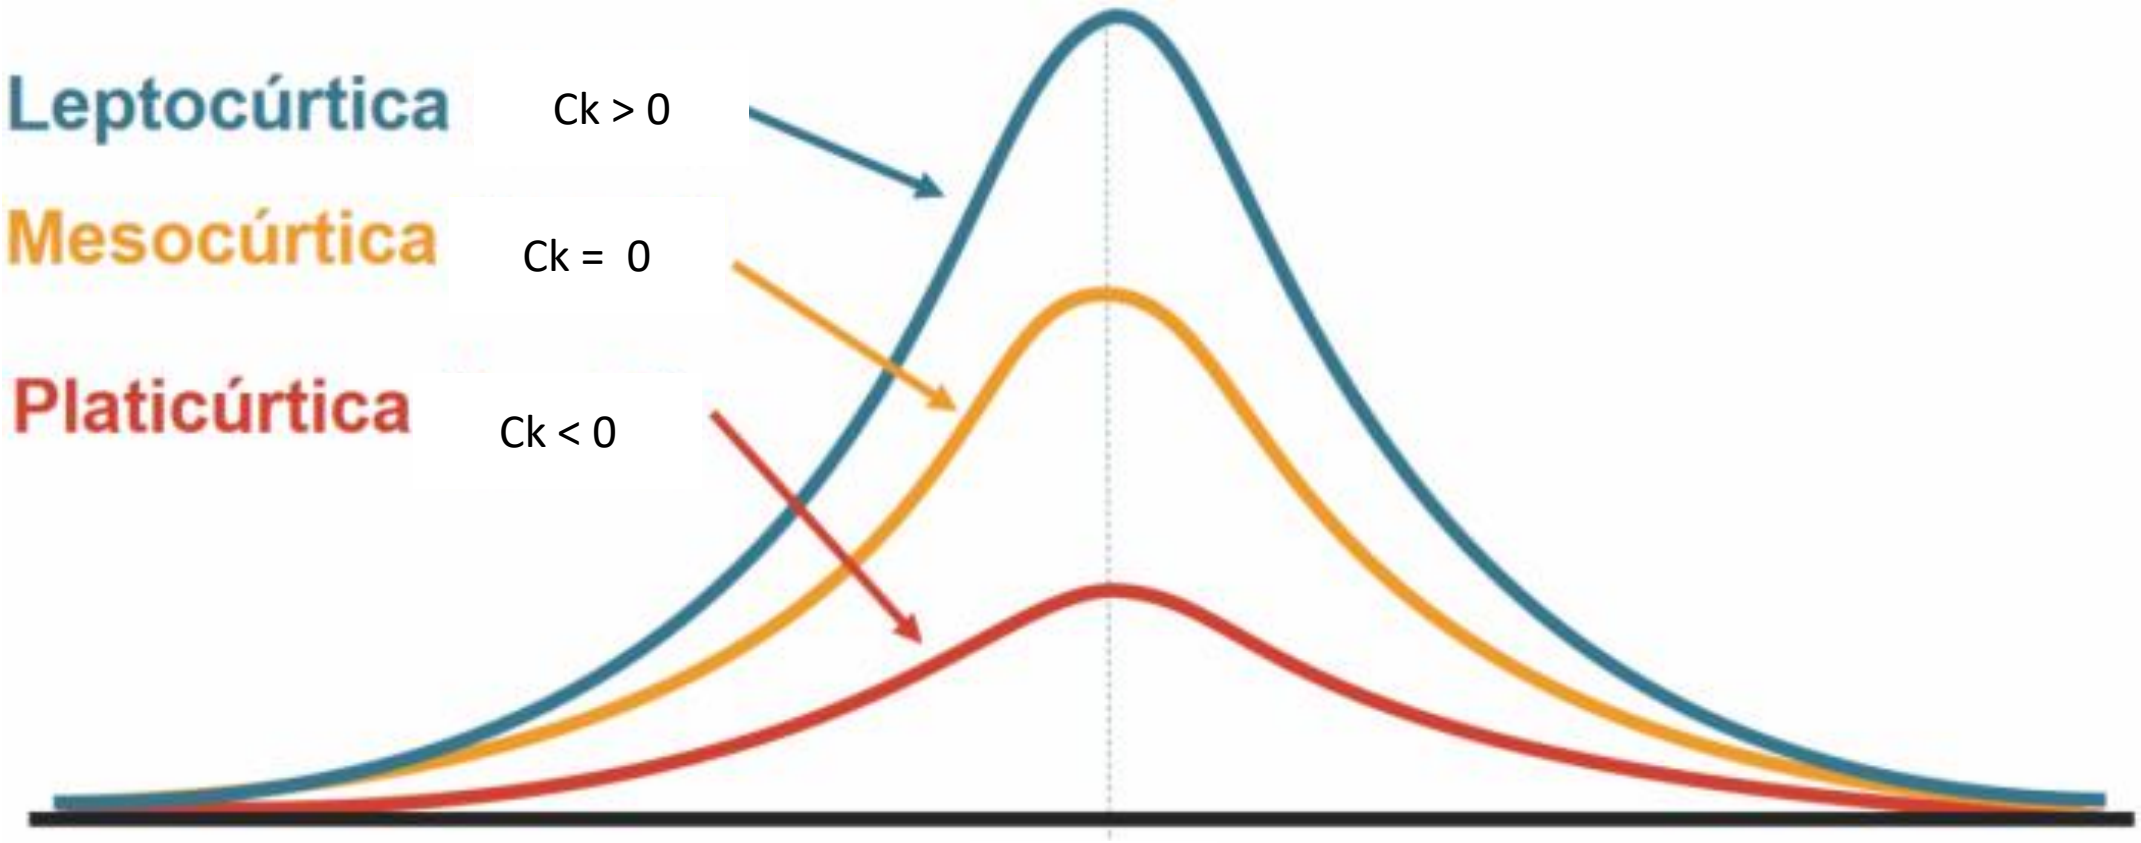

Compreensão/Análise dos Dados

Técnicas de Visualização - Histograma - Coeficiente de Curtose ou Kurtosis (Ck)

- **Mesocúrtica**: quando a forma da distribuição **não é nem muito achatada e nem muito alongada**, com uma **aparência semelhante à da curva normal**.

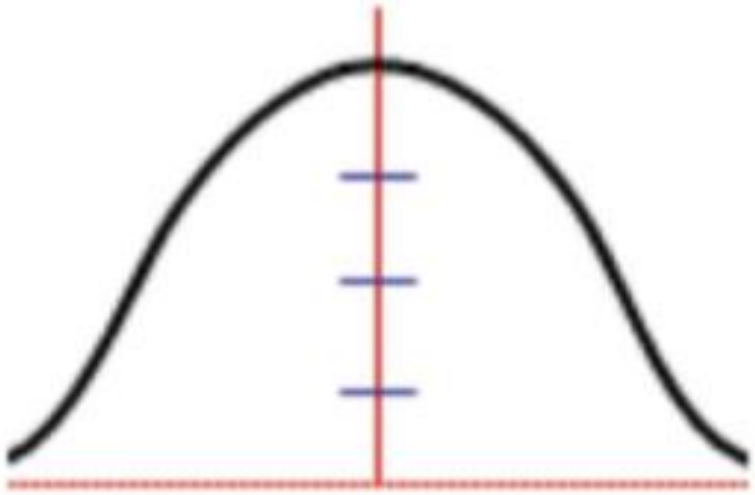

Mesocúrtica

Compreensão/Análise dos Dados

Técnicas de Visualização - Histograma - Coeficiente de Curtose ou Kurtosis (Ck)

- **Platicúrtica**: quando a **distribuição** apresenta uma curva de frequências **mais achatada que a normal**.

- Apresenta uma **medica de curtose menor que** a distribuição **normal**.

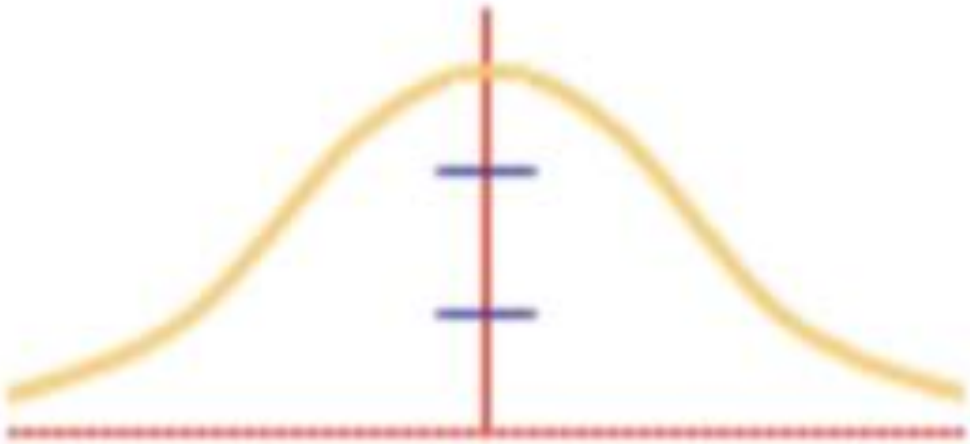

Platicúrtica

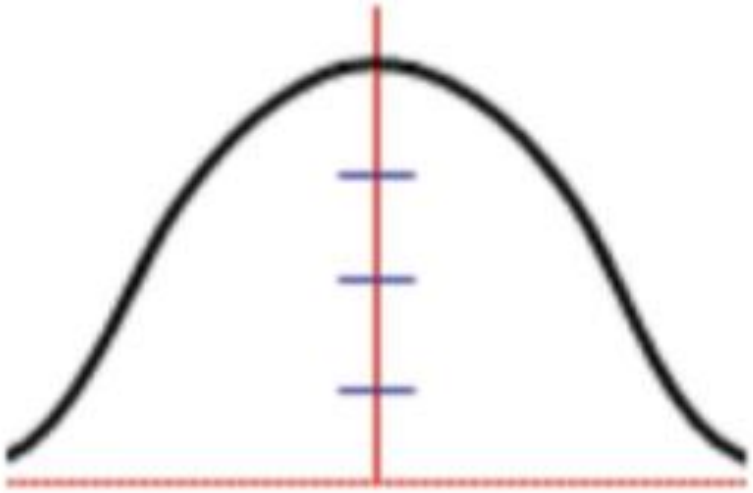

Normal

Compreensão/Análise dos Dados

Técnicas de Visualização - Histograma - Coeficiente de Curtose ou Kurtosis (Ck)

- **Leptocúrtica**: quando a **distribuição** apresenta uma curva de frequências **mais alongada que** a curva **normal**.
- Apresenta uma **medica de curtose maior que** a distribuição **normal**.

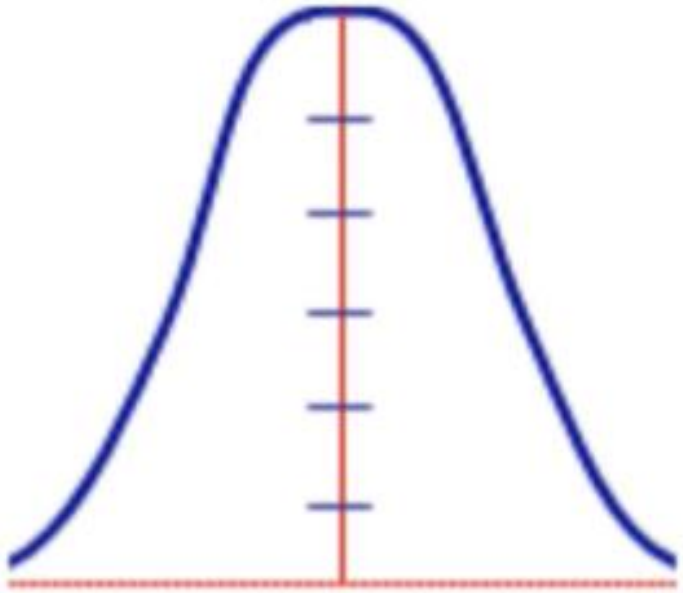

Leptocúrtica

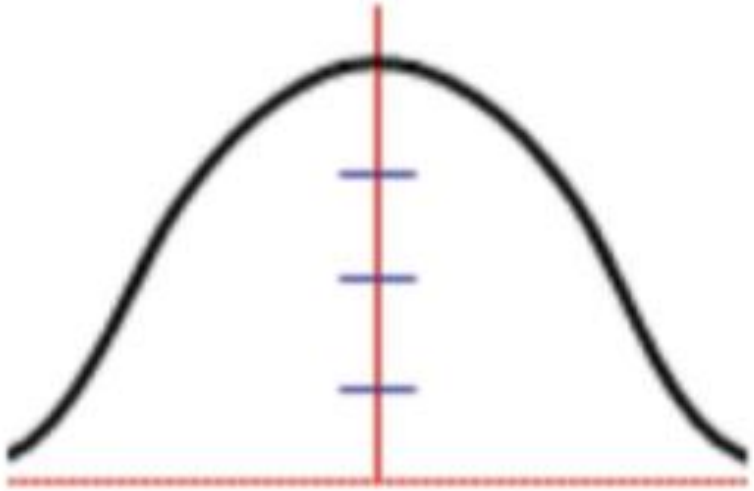

Normal

Compreensão/Análise dos Dados

Técnicas de Visualização - Histograma - Coeficiente de Curtose ou Kurtosis (Ck)

- **Cálculo da *Kurtosis* K:**

$$K = \frac{\frac{1}{2}\left(Q_3 - Q_1\right)}{P_{90} - P_{10}} - 0{,}263$$

Compreensão/Análise dos Dados

Técnicas de Visualização - Histograma - Coeficiente de Curtose ou Kurtosis (Ck)

- Valor da *Kurtosis* K:
  - **K = 0,263. Dizemos que a** Curtose é Mesocúrtica.
  - **K < 0,263**: **Dizemos que a** Curtose é Platicúrtica. (**Histograma mais achatado**)
  - **K > 0,263**: **Dizemos que** a Curtose é Leptocúrtica. (**Histograma menos achatado**)

- **Algumas técnicas de Aprendizado de Máquina esperam** que os dados estejam conforme uma **distribuição normal** de probabilidade.

Compreensão/Análise dos Dados

Técnicas de Visualização - Histograma - Coeficiente de Curtose ou Kurtosis (Ck) - Exemplo

- Os seguintes dados representam o **número de acidentes diários em um complexo industrial** (colocados em ordem crescente), durante o período de **50 dias**.

  dados = (18, 20, 20, 21, 22, 24, 25, 25, 26, 27, 29, 29, 30, 30, 31, 31, 32, 33, 34, 35, 36, 36, 37, 37, 37, 37, 38, 38, 38, 40, 41, 43, 44, 44, 45, 45, 45, 46, 47, 48, 49, 50, 51, 53, 54, 54, 56, 58, 62, 65)

- Vamos representar o histograma desses dados e ver o coeficiente de Curtose?

Compreensão/Análise dos Dados

Técnicas de Visualização - Histograma – Coeficiente de Curtose ou kurtosis – (Ck) - Exemplo

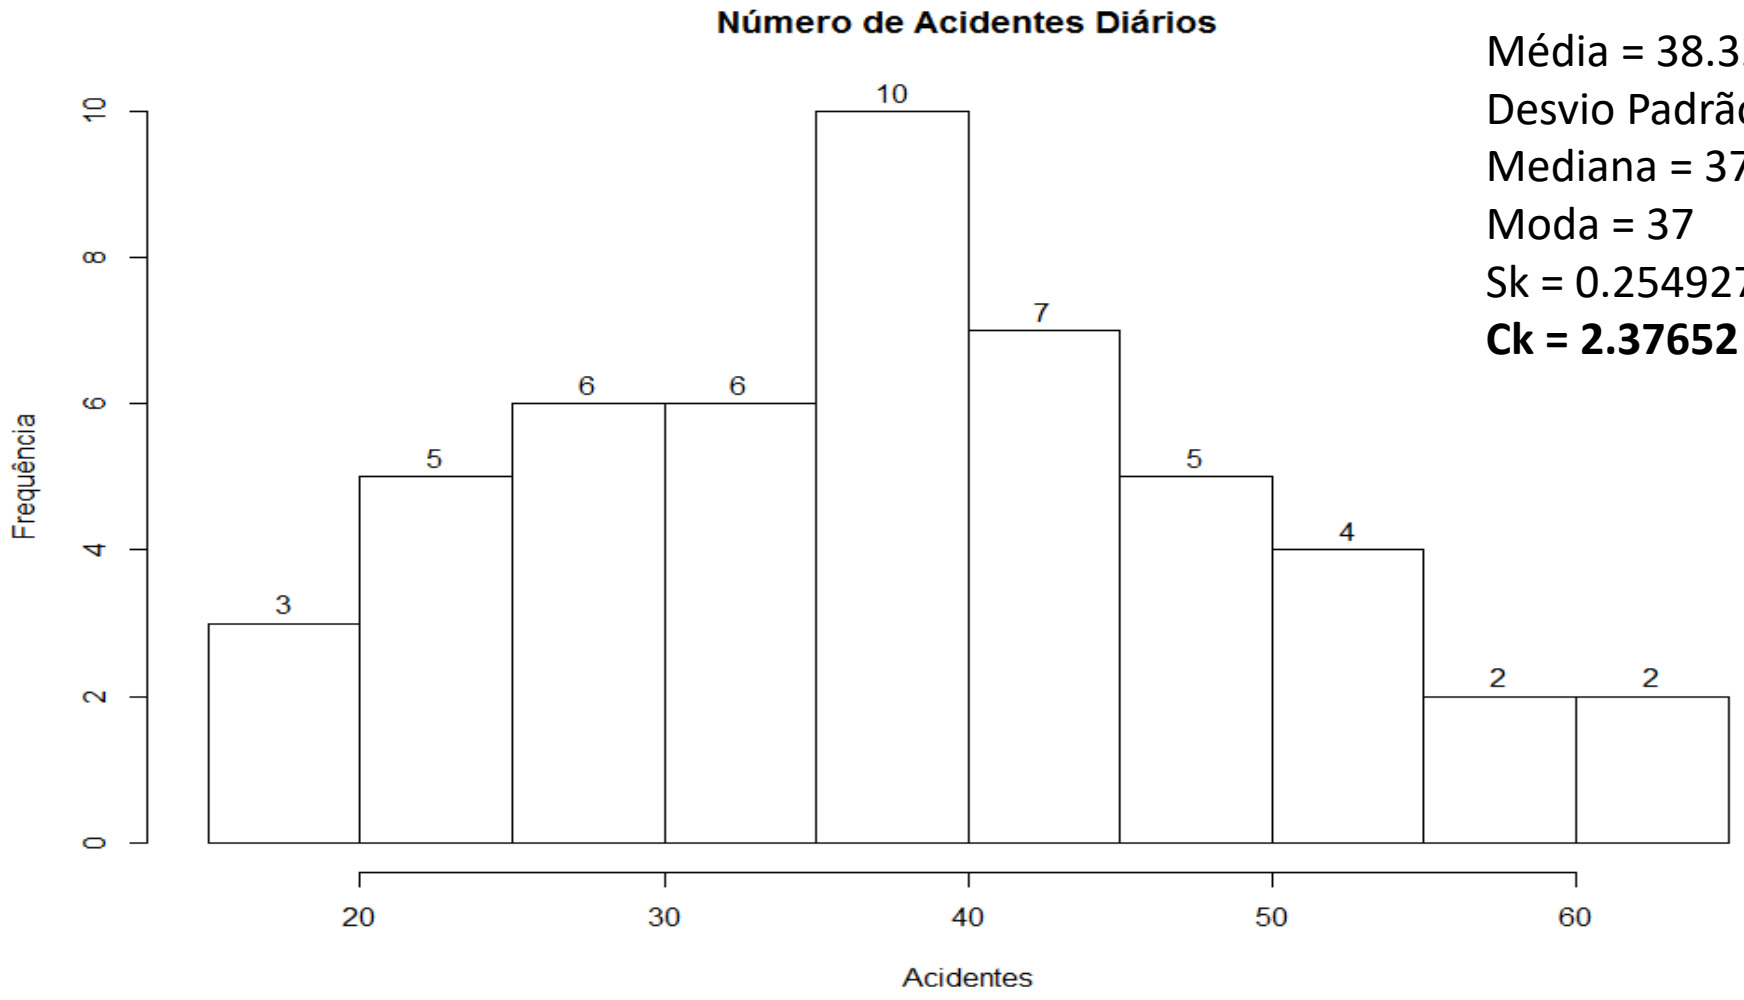

Média = 38.32
Desvio Padrão = 11.58
Mediana = 37
Moda = 37
Sk = 0.2549279
Ck = 2.37652

Compreensão/Análise dos Dados

Técnicas de Visualização - Histograma - Coeficiente de Curtose ou Kurtosis (Ck) - Exemplo

- O coeficiente de curtose é igual a 2.37652. Logo, como o valor de **Ck > 0,263**, a curva é Leptocúrtica (**Histograma menos achatado**).

Compreensão/Análise dos Dados

Técnicas de Visualização - Histograma – Coeficiente de Curtose e Assimetria – outro Exemplo (Sk e Ck)

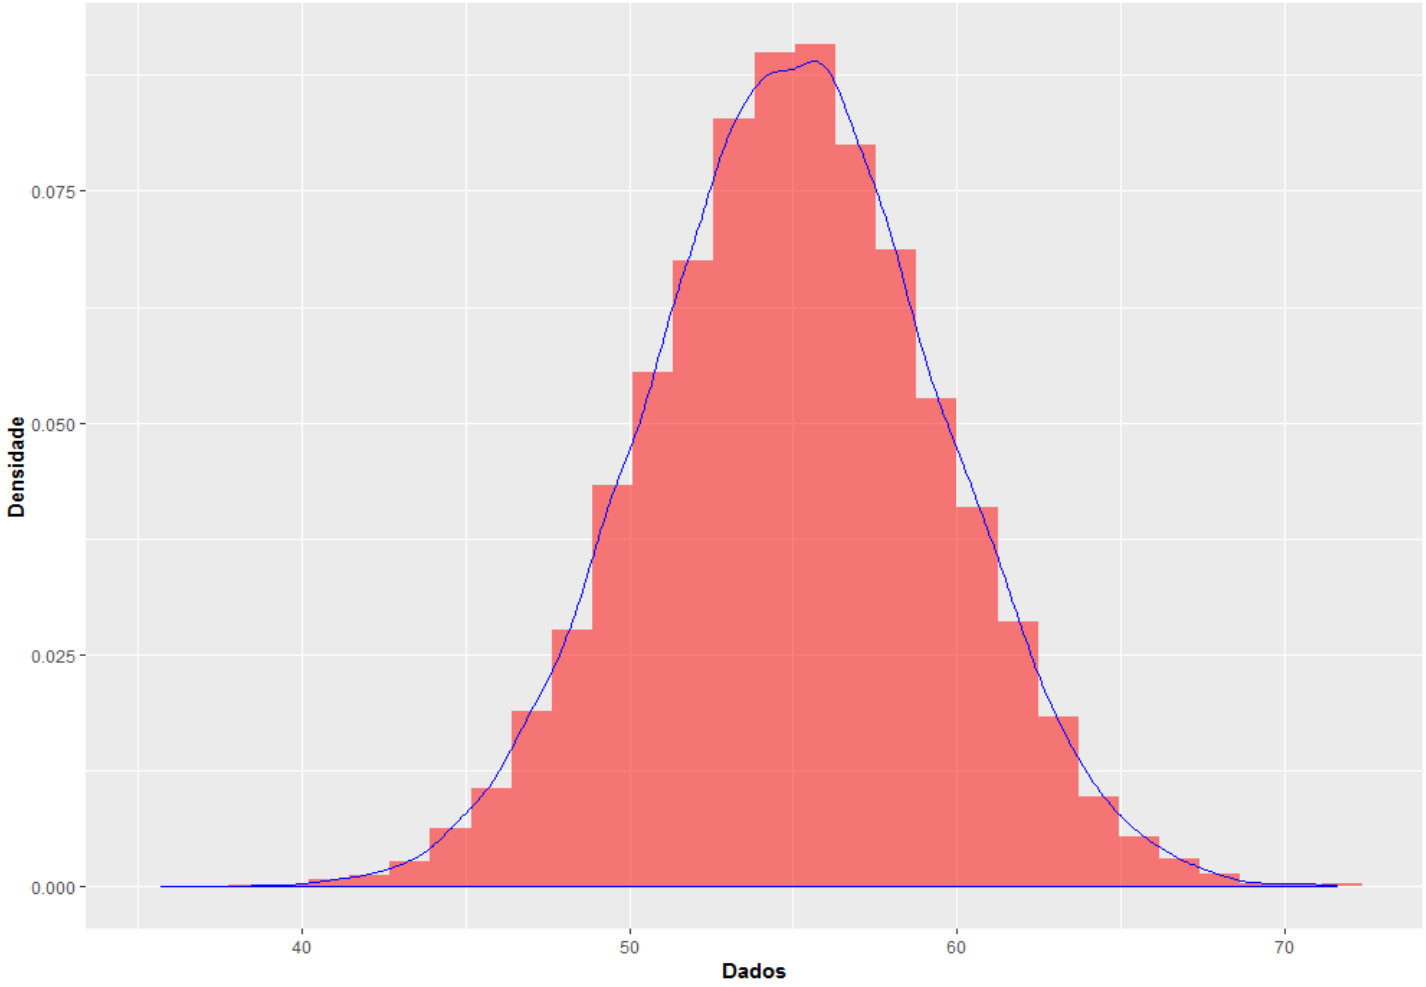

Sk = -0.0002620382
Ck = 3.017509

Compreensão/Análise dos Dados

Discussão Geral

1º **Temos que descrever o formato dos dados** (estatística descritiva) **para** depois **decidir quais técnicas aplicar para ajustar, transformar**, **limpar** os dados, etc. (ou seja, realizar o *data wrangling* ou *pré-processamento* ou *data munging*).

2º Começar a **fazer uso do aprendizado de máquina** depois que os dados estiverem devidamente explorados e processados.

Compreensão/Análise dos Dados

Técnicas de Visualização - Gráfico de Dispersão ou *Scatter plot*

- Também chamado de *scatter plot* é um diagrama matemático.

- Utiliza coordenadas cartesianas para exibir os valores dos atributos de um banco de dados e são apresentados como uma coleção de pontos com um valor no eixo horizontal e outro na vertical.

- Por meio deste gráfico bidimensional, **é possível perceber se existe algum tipo de relação entre duas variáveis**.

Compreensão/Análise dos Dados

Técnicas de Visualização - Gráfico de Dispersão ou *Scatter plot* – Média do nível do Mar por Ano

Melhor Reta que se ajusta aos dados

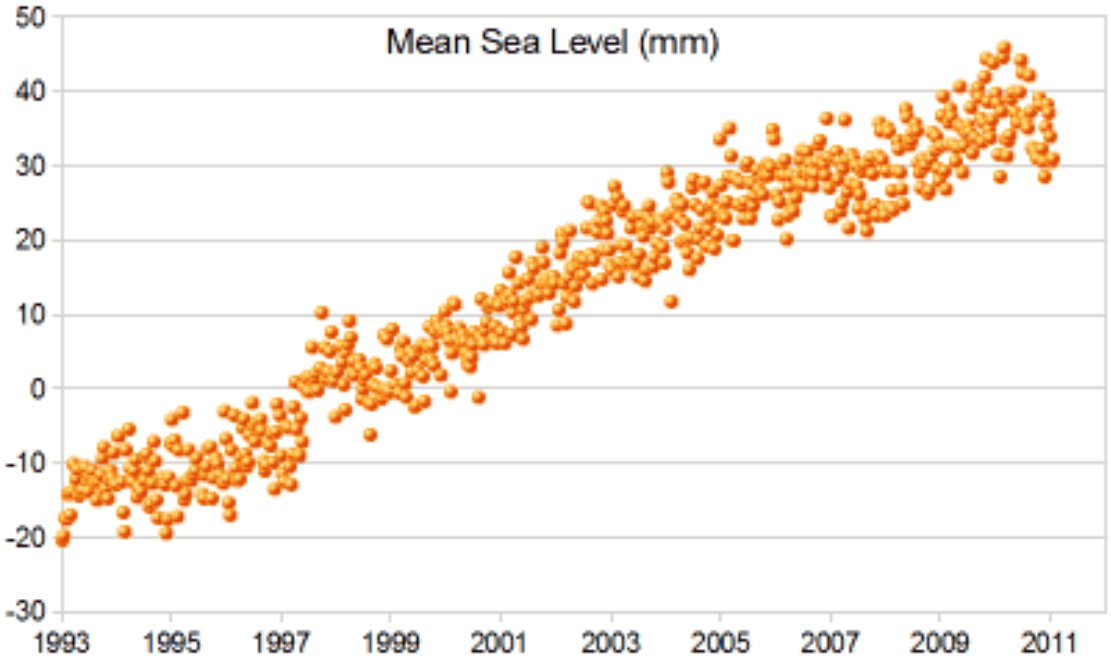

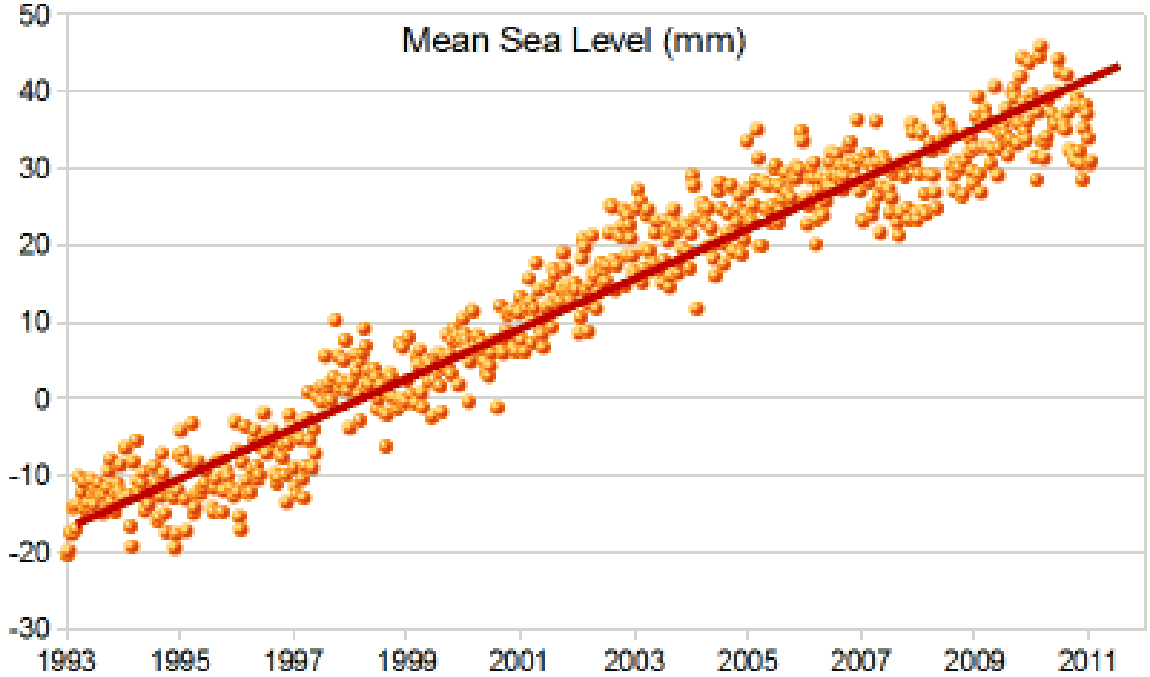

Compreensão/Análise dos Dados

Técnicas de Visualização - Gráfico de Dispersão ou *Scatter plot* – Vendas dependendo da Temperatura

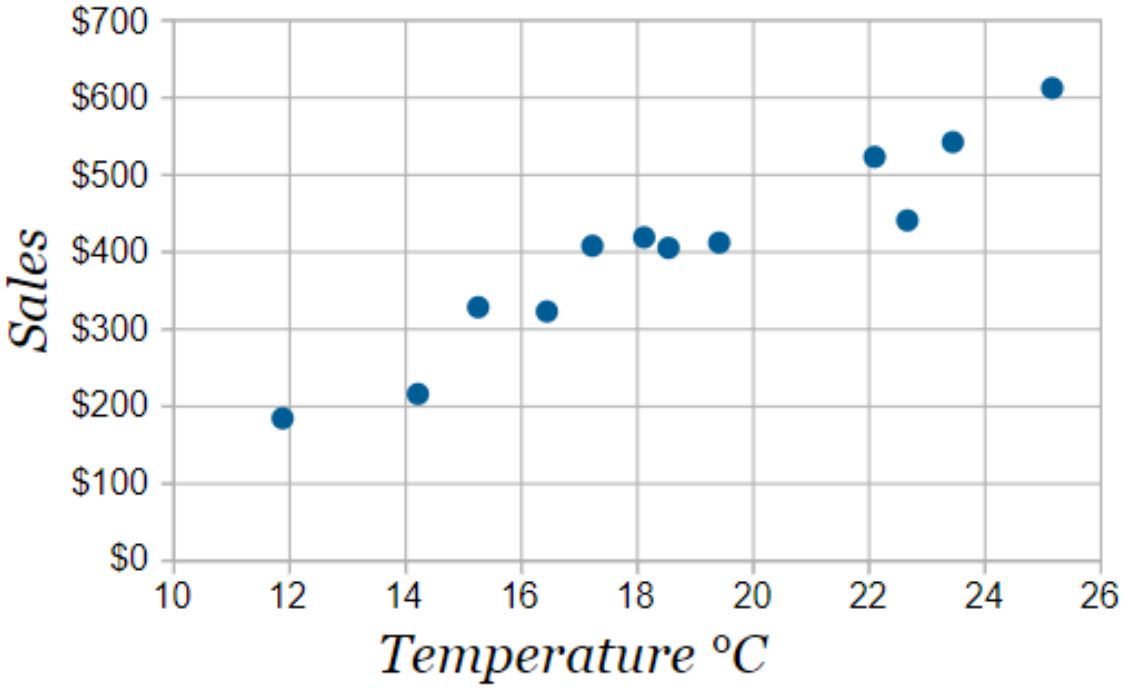

Melhor Reta que se ajusta aos dados

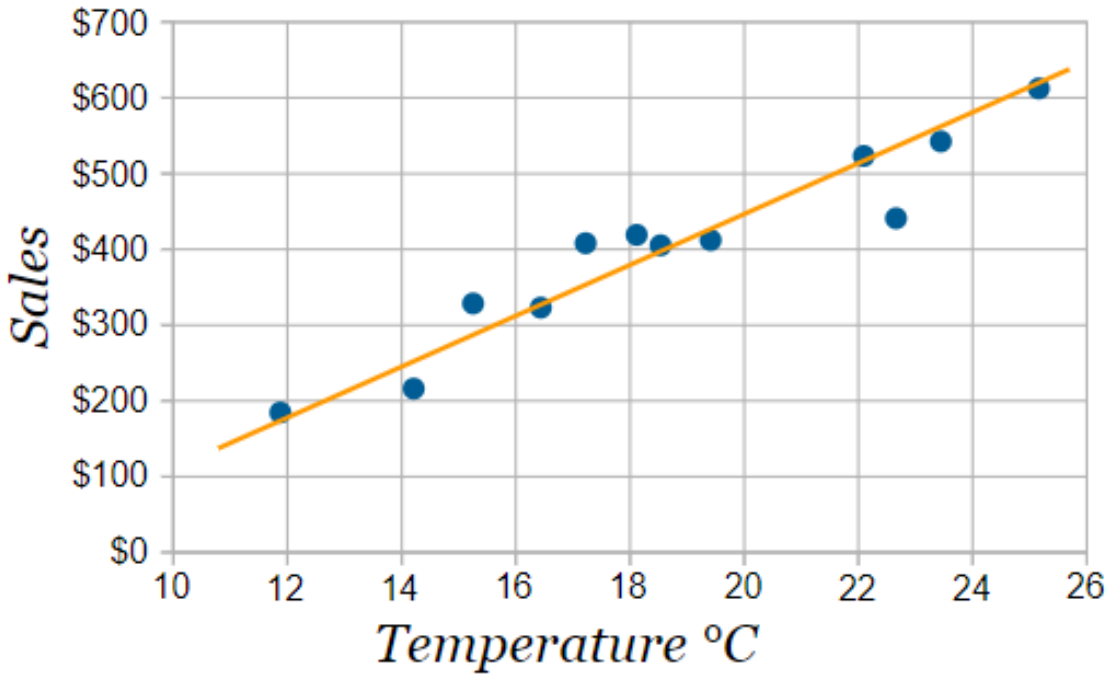

Compreensão/Análise dos Dados

Técnicas de Visualização - Gráfico de Dispersão ou *Scatter plot* - relação com a Correlação

- Até o momento vimos as medidas de dispersão (o quanto os **dados** estão **distantes em relação à media**) e de forma (que **ajudam a identificar** a forma de **distribuição dos dados**).
- Em algumas situações vamos querer analisar **além dessas medidas**, verificar a **relação entre duas ou mais variáveis** (atributos), para isso calculamos o **coeficiente de correlação**.
- Esse coeficiente é **utilizado com frequência** durante a fase de **análise exploratória dos dados**.
- **Permite determinar** o **quão fortemente os pares de variáveis estão relacionados**, ou seja, extrair a força da relação entre elas.

Compreensão/Análise dos Dados

Técnicas de Visualização - Gráfico de Dispersão ou *Scatter plot* - relação com a Correlação

- A palavra correlação é constituída por Co (que significa juntos) e relação.

- Quando os **dois conjuntos de dados estão fortemente ligados**, é possível dizer que eles tem uma **alta correlação**.

- A **correlação é positiva quando os valores** (atributos – variáveis) **aumentam juntos**; e

- A **correlação é negativa quando um valor** (atributo – variável) **diminui e o outro aumenta**.

Compreensão/Análise dos Dados

Técnicas de Visualização - Gráfico de Dispersão ou *Scatter plot* - relação com a Correlação

- **O principal resultado de uma correlação** é chamado de **coeficiente de correlação** (ou “r).

- O seu **valor varia de -1.0 a +1.0**.

- Quanto **mais próximo de +1 ou -1**, **mais as duas variáveis estão relacionadas**.

Compreensão/Análise dos Dados

Técnicas de Visualização - Gráfico de Dispersão ou *Scatter plot* - relação com a Correlação

Considere duas variáveis x e y e a **correlação(x, y)**, se o resultado for:

- **Próximo de -1** indica uma forte correlação negativa: isso significa que **toda vez que x aumenta, y diminui, ou seja, as variáveis movem-se em sentidos opostos**.
- **Próximo de 0** significa que **não há associação entre as duas variáveis** (x e y).
- **Próximo de 1** indica uma forte correlação positiva: isso significa que **y aumenta com x, ou seja, as duas variáveis movem-se no mesmo sentido**. Se uma variável aumenta a outra aumenta, se uma diminui a outra diminui.

Compreensão/Análise dos Dados

Técnicas de Visualização - Gráfico de Dispersão ou *Scatter plot* - relação com a Correlação

Perfeita Correlação Positiva

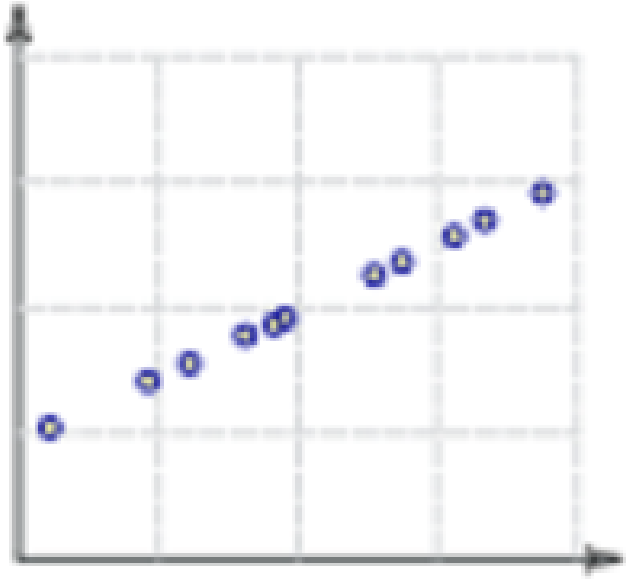

1

Alta Correlação Positiva

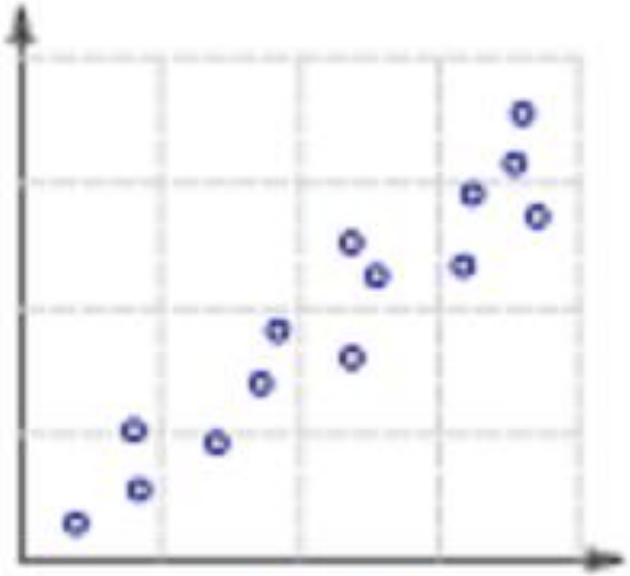

0.9

Baixa Correlação Positiva

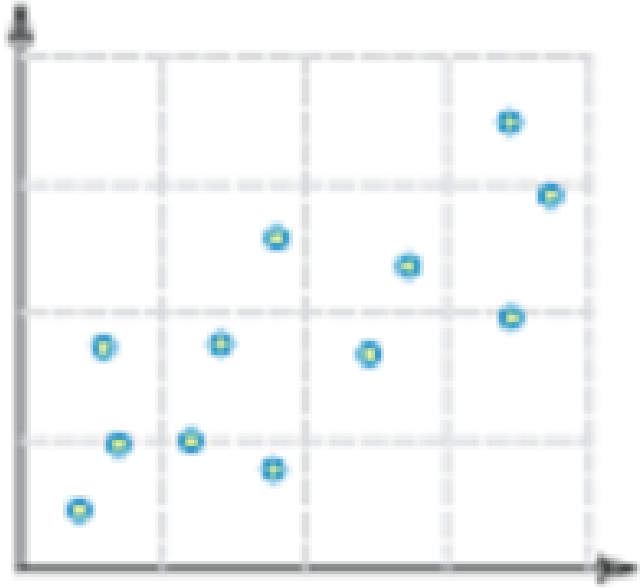

0.5

Compreensão/Análise dos Dados

Técnicas de Visualização - Gráfico de Dispersão ou *Scatter plot* - relação com a Correlação

Nenhuma Correlação

Compreensão/Análise dos Dados

Técnicas de Visualização - Gráfico de Dispersão ou *Scatter plot* - relação com a Correlação

Baixa Correlação Negativa

-0.5

Alta Correlação Negativa

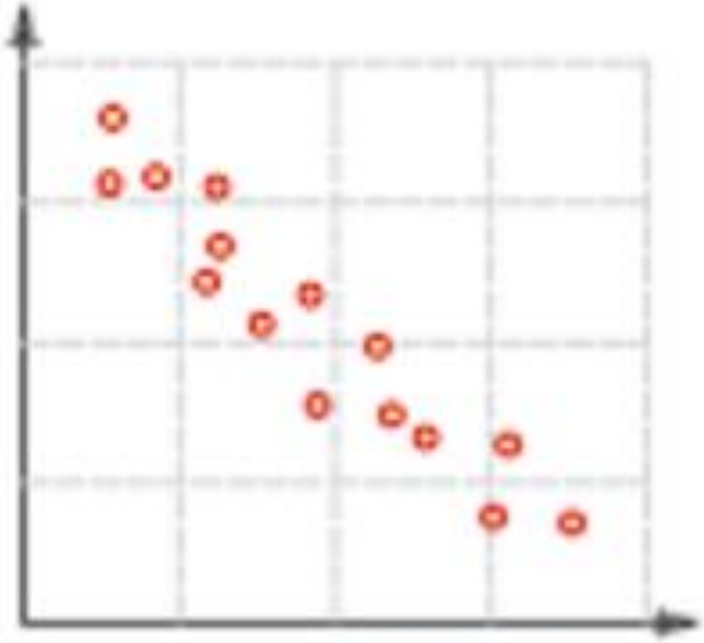

-0.9

Perfeita Correlação Negativa

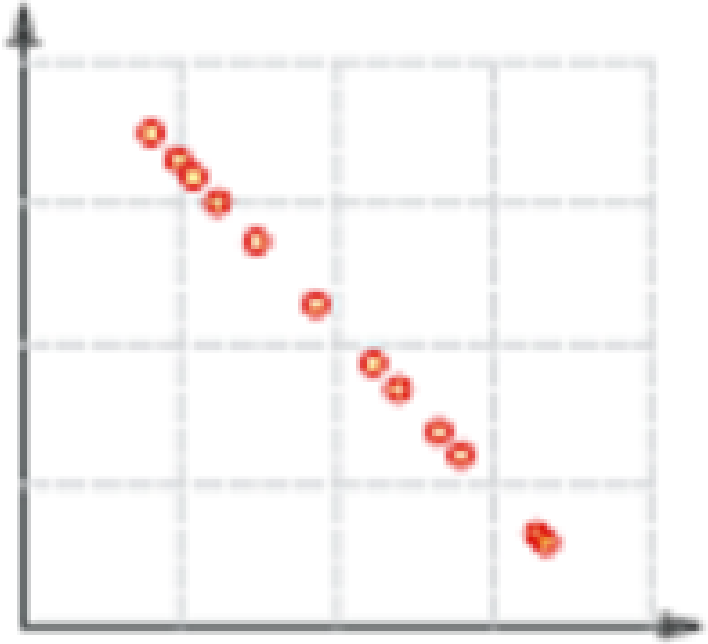

-1

Compreensão/Análise dos Dados

Técnicas de Visualização - Gráfico de Dispersão ou *Scatter plot* - relação com a Correlação

- **Com base nas correlações** obtidas entre as **variáveis (atributos)** de um ***dataset***.

- **Tomaremos decisões** sobre **quais variáveis** irão **entrar no modelo preditivo**.

Compreensão/Análise dos Dados

Técnicas de Visualização - Gráfico de Dispersão ou *Scatter plot* - relação com a Correlação

- Cada elemento da **matriz de correlação tem seu valor definido por**:

$$correlação(x^i, x^j) = \frac{covariância(x^i, x^j)}{s_i s_j}$$

  - x^i é o i-ésimo atributo.
  - s_i é o desvio padrão dos valores desse atributo.

- correlação(x^i, x^i) = 1. Diagonal da matriz têm o valor 1.
- Os demais elementos têm valor entre **-1** (**correlação negativa máxima**) e **+1** (**correlação positiva máxima**).

Compreensão/Análise dos Dados

Técnicas de Visualização - Gráfico de Dispersão ou *Scatter plot* - relação com a Correlação

- Cada elemento cov_{ij} de uma matriz de covariância Cov **mede a covariância entre os atributos x^i e x^j** e é dado por:

$$covariância(x^i, x^j) = \frac{1}{n-1} \sum_{k=1}^{n} (x_k^i - \bar{x}^i)\,(x_k^j - \bar{x}^j)$$

$\bar{x}^i$ representa o valor médio do i-ésimo atributo

x^i_k, o valor do i-ésimo atributo para o k-ésimo objeto.

Compreensão/Análise dos Dados

Técnicas de Visualização - Gráfico de Dispersão ou *Scatter plot* - relação com a Correlação

- O desvio padrão é dado por:

$$desvio\ padrão\ (x^j) = \sqrt[2]{variância(x^j)}$$

- Indica o grau de variação de um conjunto de dados.

- Assim como a média, o valor da **variância pode ser distorcido** pela presença de ***outliers***, pois **calcula** a **diferença** entre **cada valor** e a **média**.

Compreensão/Análise dos Dados

Técnicas de Visualização - Gráfico de Dispersão ou *Scatter plot* - relação com a Correlação

- A medida mais utilizada para avaliar o espalhamento de valores. É dada por:

$$variância(x^j) = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x}^j)^2$$

Onde:

$\bar{x}^j$ é a média dos valores de x^j .

n – 1 melhora a estimativa da variância verdadeira do que n, chamada correção de Bessel.

Compreensão/Análise dos Dados

Técnicas de Visualização - Gráfico de Dispersão ou *Scatter plot 3D* – Exemplo

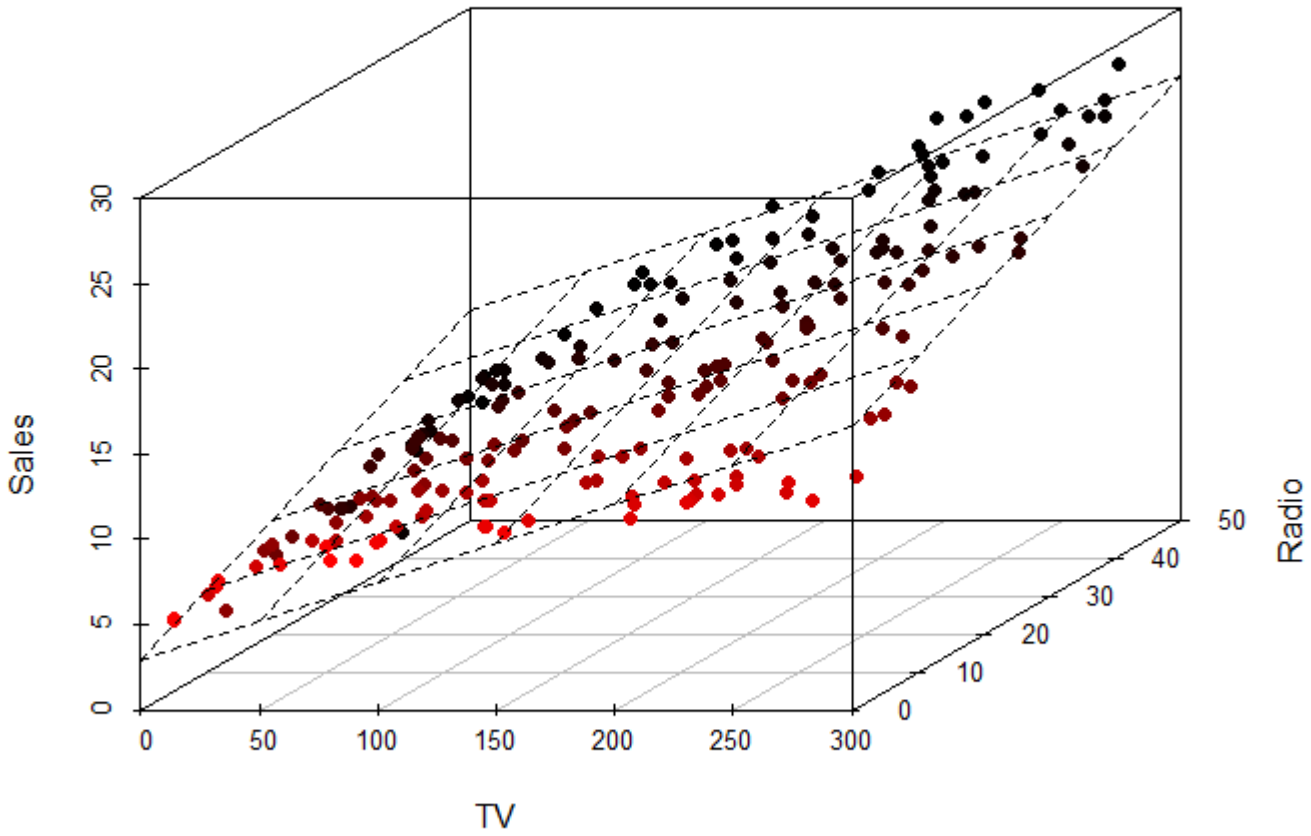

Compreensão/Análise dos Dados

Técnicas de Visualização - *Heat Map* (Mapa de Calor)

- ***Heatmap***: ou (mapa de calor) é um **mosaico retangular de uma matriz de dados** com árvores de *clusters* anexadas às suas margens.

- ❑ Dados mais relacionados – cor mais forte;
- ❑ Dados menos relacionados – cor mais clara.

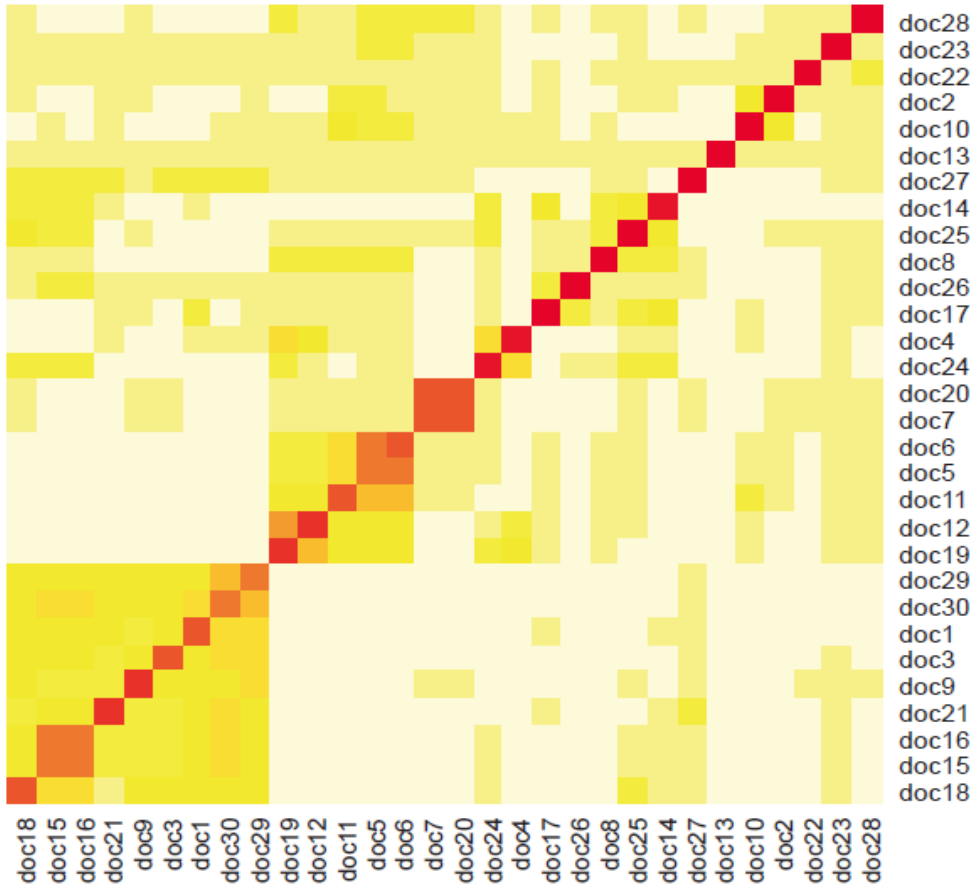

Compreensão/Análise dos Dados

Técnicas de Visualização - *Heat Map* (Mapa de Calor)

- Dentro de uma **área de exibição relativamente compacta**, **facilita a inspeção da estrutura do conjunto** de linhas, colunas e juntas.

- **Matrizes** de dados moderadamente **grandes** (várias linhas / colunas) **podem ser exibidas** efetivamente em um **monitor colorido de alta resolução**.

Compreensão/Análise dos Dados

Técnicas de Visualização - *Heat Map* (Mapa de Calor) – relação com Correlação

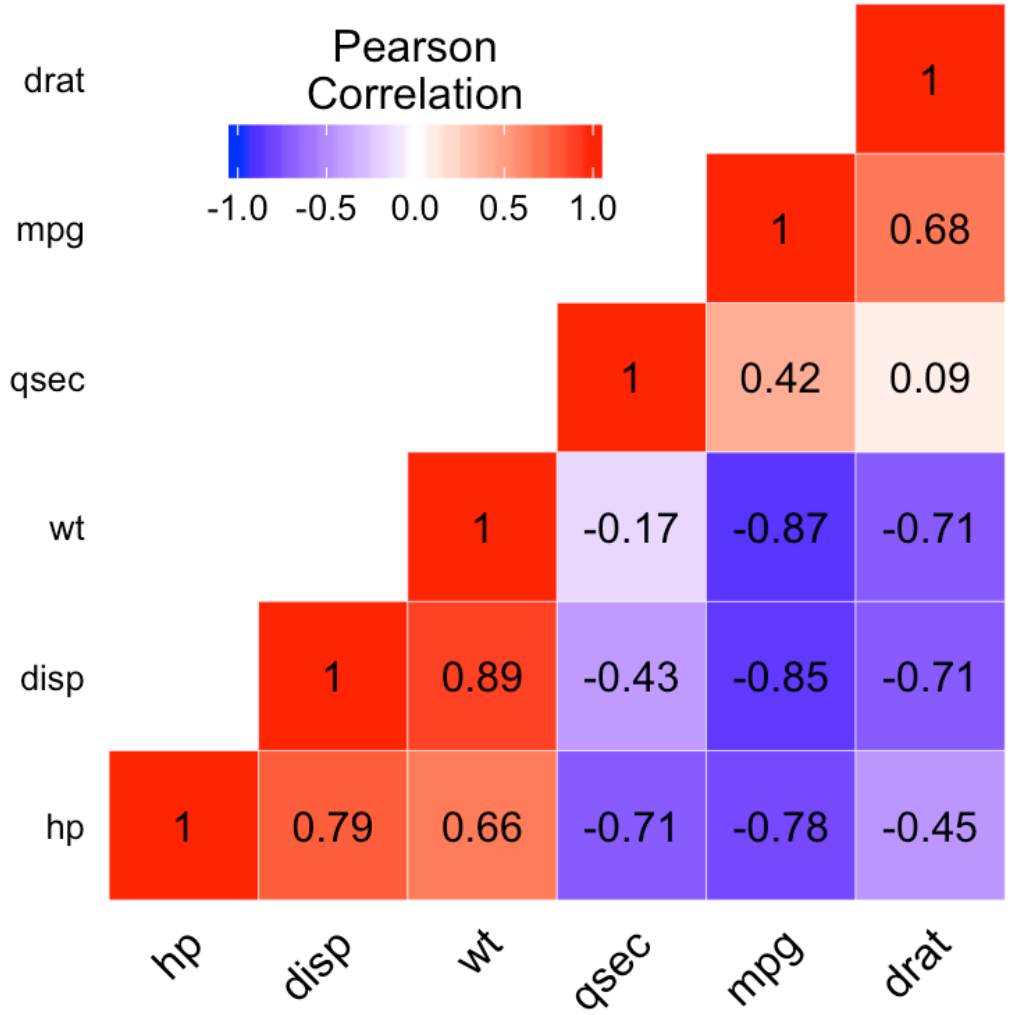

Compreensão/Análise dos Dados

Técnicas de Visualização - *Heat Map* (Mapa de Calor) – relação com Correlação

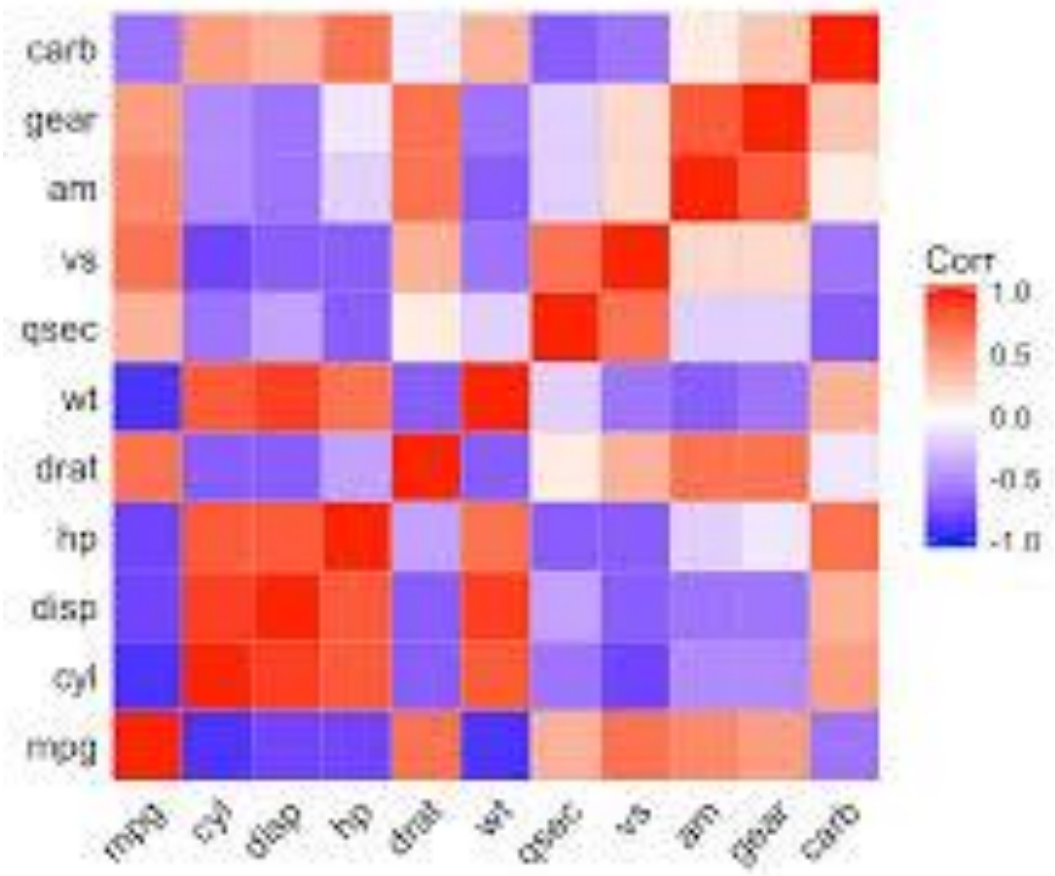

Compreensão/Análise dos Dados

Técnicas de Visualização - *Heat Map* (Mapa de Calor) – Dataset Boston Houses - http://www.cs.toronto.edu/~delve/data/boston/bostonDetail.html

- Este conjunto de dados contém informações coletadas pelo Serviço de Recenseamento dos EUA sobre **habitação na área de Boston**.
- Ele foi obtido do arquivo StatLib (http://lib.stat.cmu.edu/datasets/boston) e tem sido usado extensivamente na literatura.
- O **conjunto de dados é pequeno** em tamanho, com apenas 506 casos.
- Os dados foram originalmente publicados por Harrison, D. e Rubinfeld, D.L. "Preços hedônicos e a demanda por ar limpo", J. Environ. Economics & Management, volume 5, 81-102, 1978.
- O **nome** deste conjunto de dados é simplesmente **boston**.
- **Atributos Alvo**: nox = nível de óxido nitroso; e **preço = valor em $1000 de uma casa ocupada pelo dono**.

Compreensão/Análise dos Dados

Técnicas de Visualização - *Heat Map* (Mapa de Calor) – Dataset Boston Houses - http://www.cs.toronto.edu/~delve/data/boston/bostonDetail.html

1. CRIM: Taxa de criminalidade per capita por cidade
2. ZN: Proporção de terrenos residenciais destinados a lotes com mais de 25.000 pés quadrados
3. INDUS: proporção de acres não residenciais por cidade
4. CHAS: Variável fictícia de Charles River (= 1 se o setor contiver rio; 0 caso contrário)
5. NOX: Concentração de óxidos nítricos (partes por 10 milhões)
6. RM: número médio de quartos por habitação
7. AGE: proporção de unidades ocupadas pelo proprietário construídas antes de 1940.
8. DIS: distâncias ponderadas para cinco centros de emprego de Boston
9. **RAD: índice de acessibilidade a rodovias radiais**
10. **TAX: taxa de imposto predial de valor integral por 10.000**
11. **PTRATIO: relação aluno-professor por cidade**
12. **B: 1000 (Bk - 0,63) ^ 2 onde Bk é a proporção de negros por cidade**
13. LSTAT: % menor estado da população
14. TARGET: valor médio de casas ocupadas pelo dono em $1000's.

Compreensão/Análise dos Dados

Técnicas de Visualização - *Heat Map* (Mapa de Calor) – relação com Correlação – Valor da Correlação

	CRIM	ZN	INDUS	CHAS	NOX	RM	AGE \
CRIM	1.000000	-0.199458	0.404471	-0.055295	0.417521	-0.219940	0.350784
ZN	-0.199458	1.000000	-0.533828	-0.042697	-0.516604	0.311991	-0.569537
INDUS	0.404471	-0.533828	1.000000	0.062938	0.763651	-0.391676	0.644779
CHAS	-0.055295	-0.042697	0.062938	1.000000	0.091203	0.091251	0.086518
NOX	0.417521	-0.516604	0.763651	0.091203	1.000000	-0.302188	0.731470
RM	-0.219940	0.311991	-0.391676	0.091251	-0.302188	1.000000	-0.240265
AGE	0.350784	-0.569537	0.644779	0.086518	0.731470	-0.240265	1.000000
DIS	-0.377904	0.664408	-0.708027	-0.099176	-0.769230	0.205246	-0.747881
RAD	0.622029	-0.311948	0.595129	-0.007368	0.611441	-0.209847	0.456022
TAX	0.579564	-0.314563	0.720760	-0.035587	0.668023	-0.292048	0.506456
PTRATIO	0.288250	-0.391679	0.383248	-0.121515	0.188933	-0.355501	0.261515
B	-0.377365	0.175520	-0.356977	0.048788	-0.380051	0.128069	-0.273534
LSTAT	0.452220	-0.412995	0.603800	-0.053929	0.590879	-0.613808	0.602339

	DIS	RAD	TAX	PTRATIO	B	LSTAT
CRIM	-0.377904	0.622029	0.579564	0.288250	-0.377365	0.452220
ZN	0.664408	-0.311948	-0.314563	-0.391679	0.175520	-0.412995
INDUS	-0.708027	0.595129	0.720760	0.383248	-0.356977	0.603800
CHAS	-0.099176	-0.007368	-0.035587	-0.121515	0.048788	-0.053929
NOX	-0.769230	0.611441	0.668023	0.188933	-0.380051	0.590879
RM	0.205246	-0.209847	-0.292048	-0.355501	0.128069	-0.613808
AGE	-0.747881	0.456022	0.506456	0.261515	-0.273534	0.602339
DIS	1.000000	-0.494588	-0.534432	-0.232471	0.291512	-0.496996
RAD	-0.494588	1.000000	0.910228	0.464741	-0.444413	0.488676
TAX	-0.534432	0.910228	1.000000	0.460853	-0.441808	0.543993
PTRATIO	-0.232471	0.464741	0.460853	1.000000	-0.177383	0.374044
B	0.291512	-0.444413	-0.441808	-0.177383	1.000000	-0.366087
LSTAT	-0.496996	0.488676	0.543993	0.374044	-0.366087	1.000000

Compreensão/Análise dos Dados

Técnicas de Visualização - *Heat Map* (Mapa de Calor) – relação com Correlação

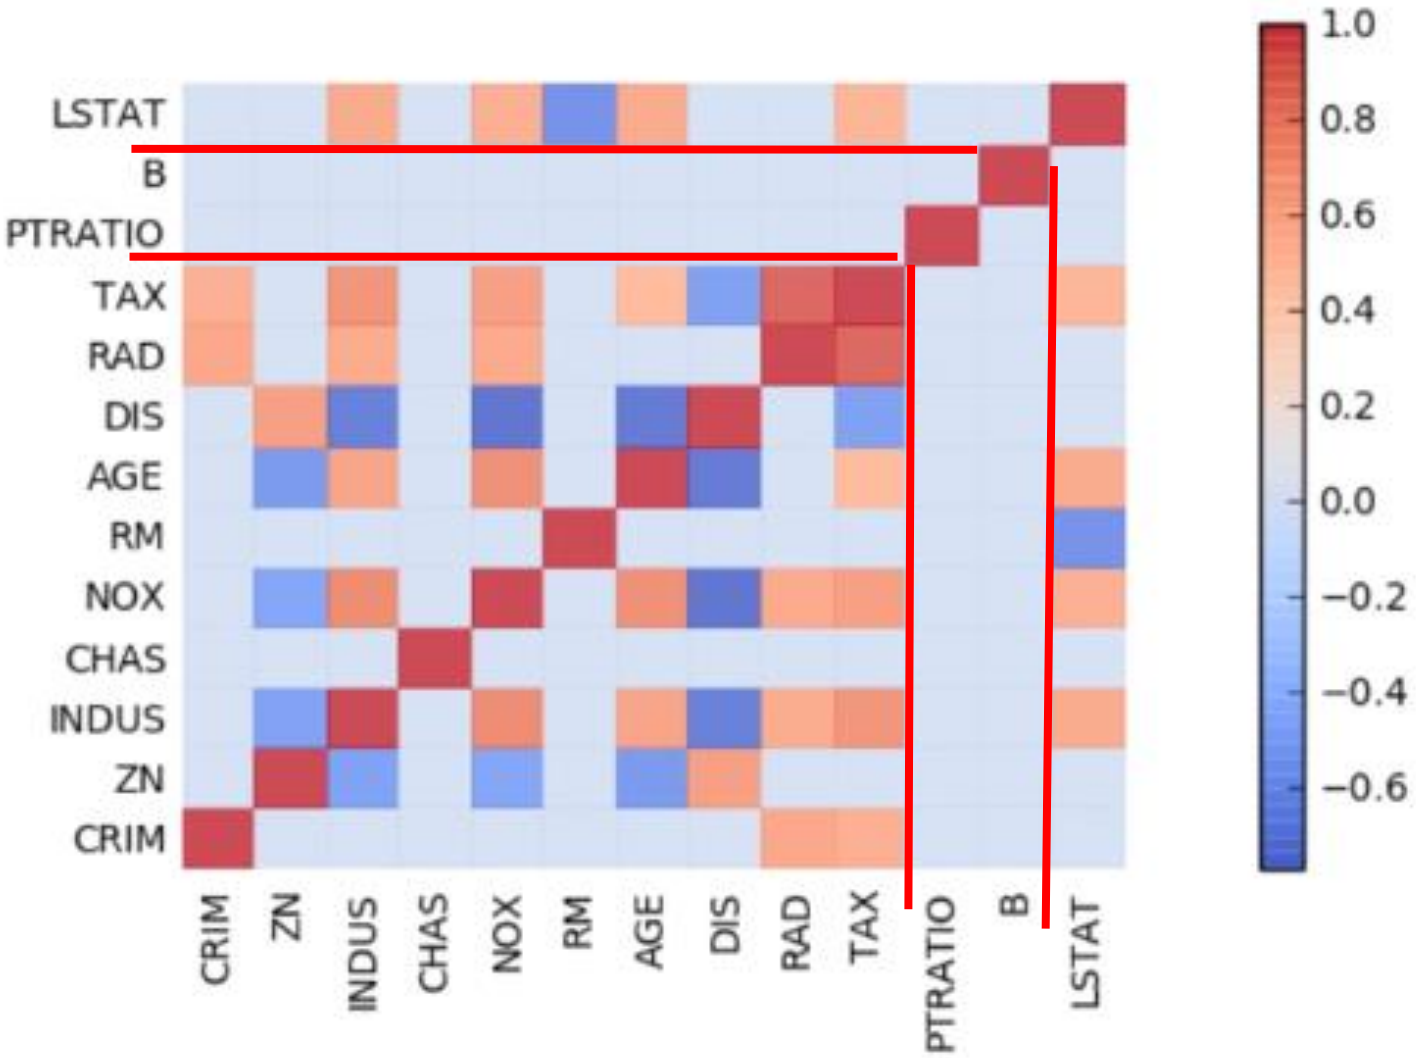

Duas **variáveis B e PTRATIO** estão com linhas-colunas em **azul claro indicando** que elas **não tem muita relevância para o modelo** ou pelo menos que elas não tem correlação com as outras variáveis.

Talvez sejam variáveis que indicam um outro tipo de informação, não tem relevância para o **que se pretende predizer** e **podem ser removidas**.

Compreensão/Análise dos Dados

Técnicas de Visualização - *Heat Map* (Mapa de Calor) – relação com Correlação

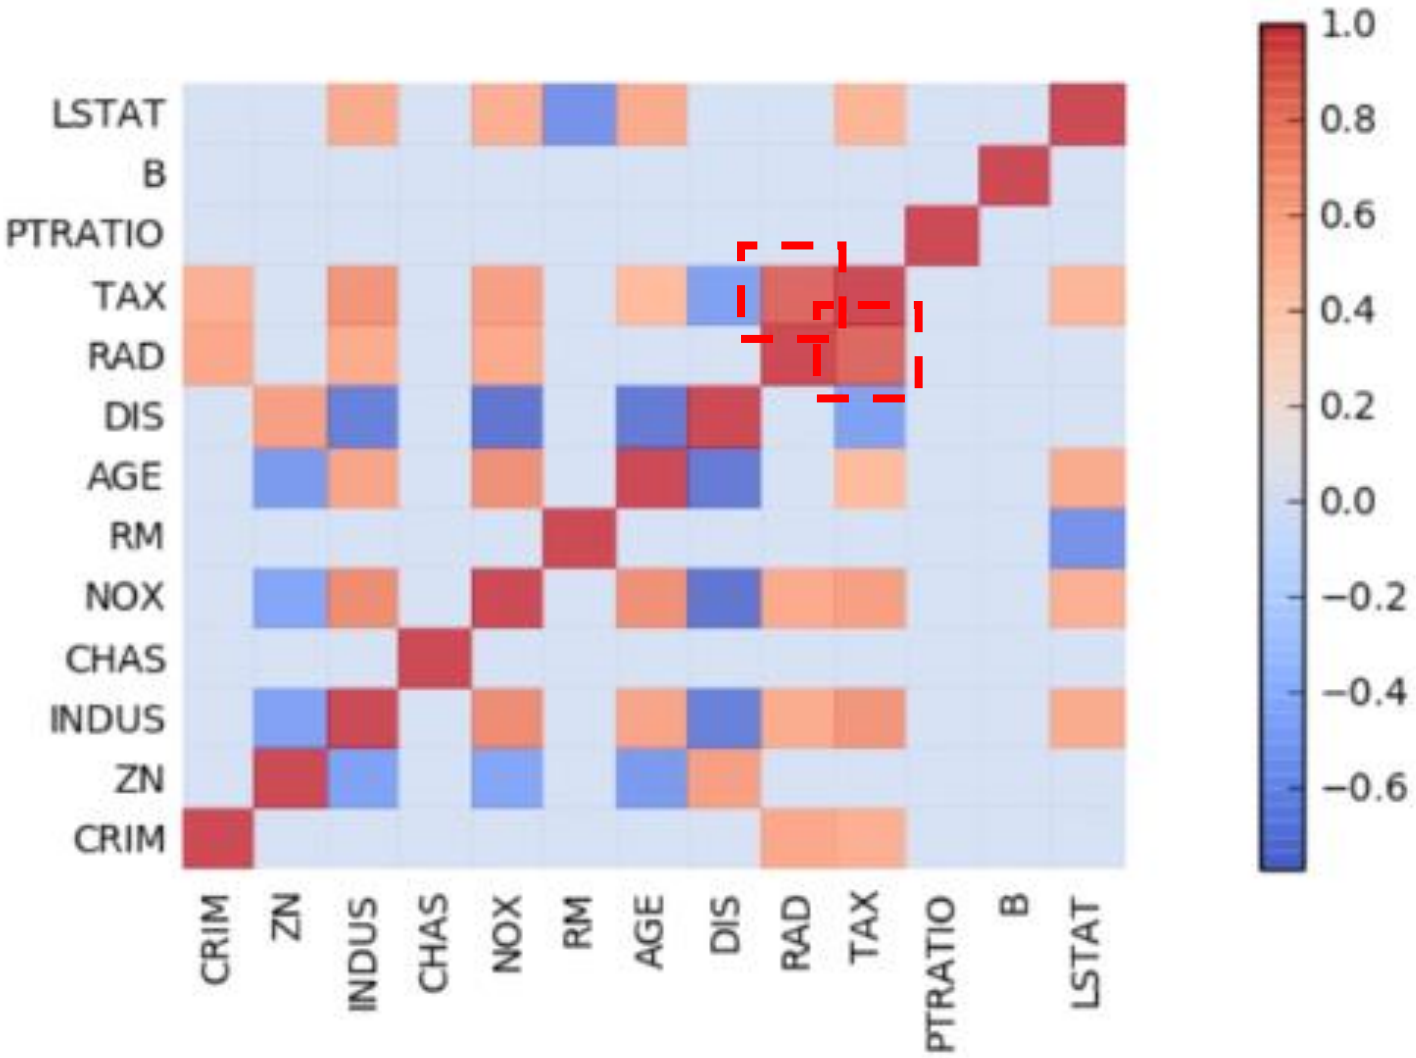

Duas **variáveis TAX e RAD** apresentam uma **alta correlação positiva**.

Isso indica que **essas variáveis são colineares**, **ou seja**, são dois atributos do *dataset* que **representam o mesmo tipo de informação** (apresenta o que chamamos de variância compartilhada).

Embora, elas possam ter dados diferentes, representam o mesmo tipo de informação.

Compreensão/Análise dos Dados

Técnicas de Visualização - *Heat Map* (Mapa de Calor) – relação com Correlação

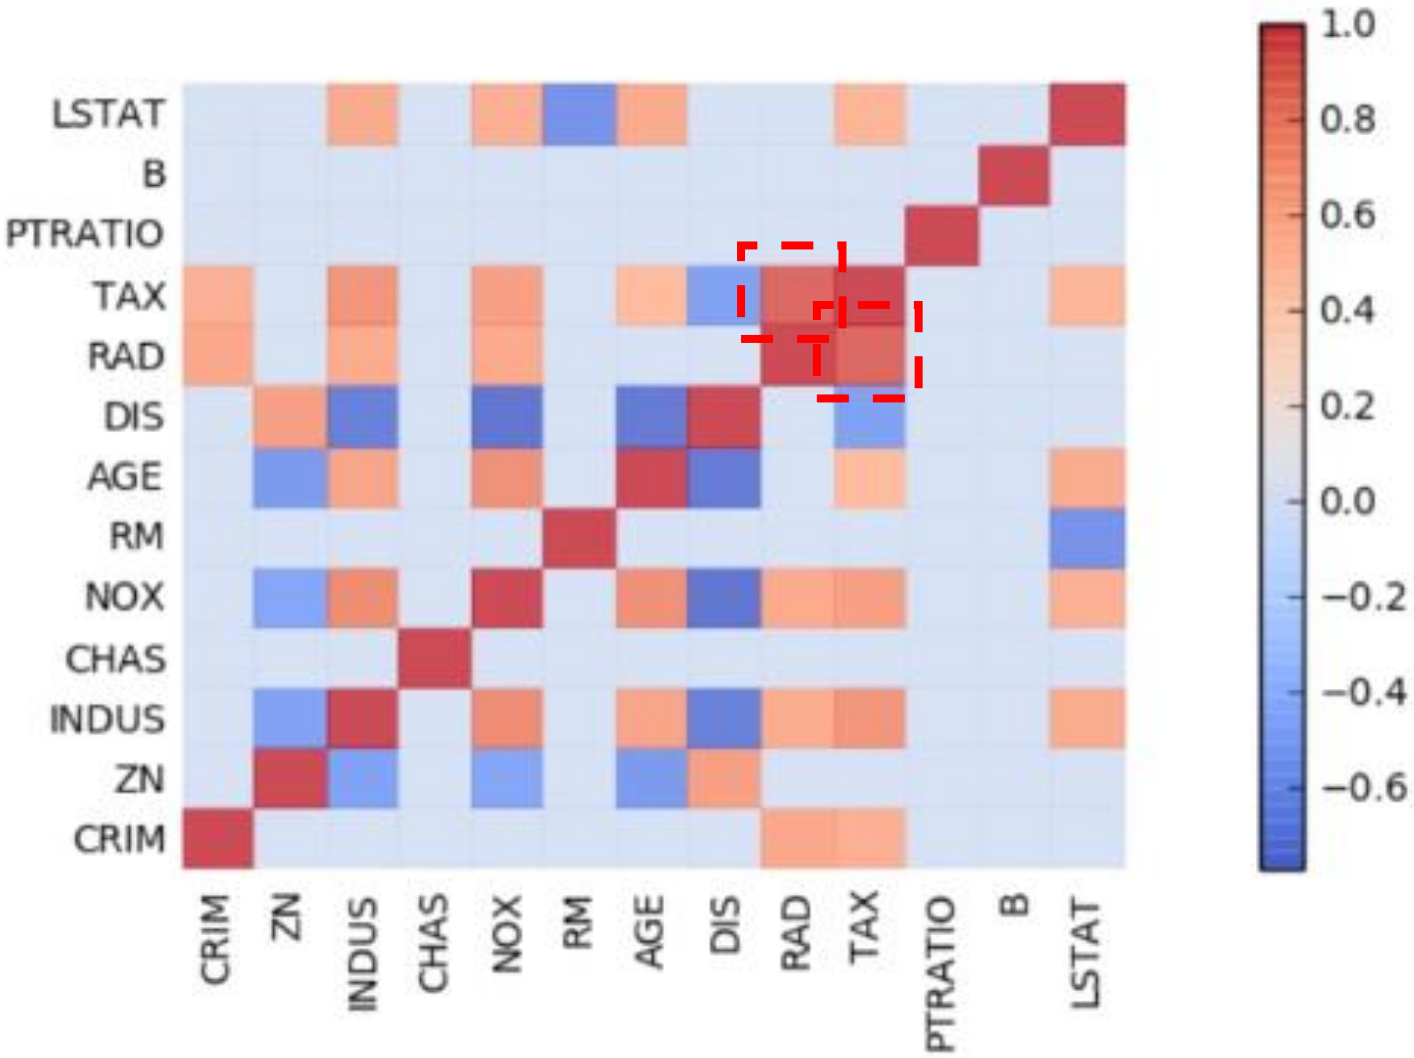

Então, no momento que aplicamos diversos cálculos estatísticos e matemáticos identificamos **variáveis** que **são colineares ou multicolineares** (**entre duas ou mais variáveis**).

Isso é um problema e **com certeza vai gerar um modelo problemático**.

A **remoção de alguma delas é geralmente a melhor solução**.

Bibliografia

BÁSICA:

- AGGARWAL, Charu C. **Artificial Intelligence: A Textbook**. New York: Springer: 2021.
- CHOLLET, François. **Deep Learning with Python, 2ed.** Shelter Island: Manning, 2021.
- GÉRON, Aurélien. **Hands-On Machine Learning with Scikit-Learn and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems**, 2 ed**.** Sebastopol: O'Reilly, 2019.

COMPLEMENTAR:

- GOODFELLOW, Ian; BENGIO, Yoshua, COURVILLE, Aaron. **Deep Learning**. Cambridge: MIT Press, 2016.
- RASCHKA, Sebastian; MIRJALILI, Vahid. **Python Machine Learning**. 3 ed. Birmingham: Packt, 2017.
- RUSSEL, Stuart; NORVIG, Peter. **Artificial Intelligence: A Modern Approach**. 3 ed. Upper Saddle River: Pearson, 2010.
- TAN, Pang-Ning; STEINBACH, Michael; KUMAR, Vipin. **Introduction to Data Mining**. 2 ed. Upper Saddle River: Pearson, 2018.
- VANDERPLAS, Jake. **Python Data Science Handbook**. Sebastopol: O'Reilly, 2017.

ADICIONAIS:

- FACELI, Katti et al. **Inteligência artificial: uma abordagem de aprendizado de máquina**. 2ª Ed. Rio de Janeiro: LTC-Livros Técnicos e Científicos, 2021.
- LUGER, George F. **Inteligência Artificial** - 6ª ed. São Paulo: Pearson Education do Brasil, 2015.
- RUSSELL, Stuart; NORVIG, Peter. **Inteligência artificial: Uma Abordagem Moderna** - 4ª. Ed. GEN LTC, 2022.