Inteligência Artificial

Aprendizado de Máquina Clássico – Parte I
Conceitos Gerais e Regressão Linear

Prof. Dr. Ivan Carlos Alcântara de Oliveira

https://orcid.org/0000-0002-6020-7535

communication
innovation
training
technology
information
machine
science
engineering
learning

Aprendizado de Máquina

Conceitos

Aprendizagem é o processo pelo qual as competências, habilidades, conhecimentos, comportamento ou valores são adquiridos ou modificados, como resultado de estudo, experiência, formação, raciocínio e observação. (1)

- Área da Inteligência Artificial que, segundo Michell (1997, apud CARVALHO et al, 2011), Aprendizado de Máquina (AM) ou *Machine Learning* é definida como:

"A capacidade de melhorar o desempenho na realização de alguma tarefa por meio da experiência".

1. TEIXEIRA, H. O que é Aprendizagem? 10 de Novembro de 2015. Disponível em: helioteixeira.org/ciencias-da-aprendizagem/o-que-e-aprendizagem/. Data da Consulta: 11 de fevereiro de 2024.

Aprendizado de Máquina

Conceitos

Em AM ou ML (*Machine Learning*):

- o **foco** é **extrair informação/conhecimento** a partir de **dados** de **maneira automática**.
- computadores são programados para **aprender** com a **experiência passada**.
- emprega-se a **indução**, no qual se **obtém conclusões a partir de** um conjunto particular de **exemplos (instâncias ou dados de histórico).**

Aprendizado de Máquina

Conceitos – Indução de Hipóteses

- **Algoritmos** de AM **aprendem a induzir uma função ou hipótese (modelo preditivo) capaz de resolver um problema a partir de dados**, representando instâncias do próprio problema**.**

- Os dados utilizados formam um conjunto (denominado, **conjunto de dados ou *datasets***).

Aprendizado de Máquina

Conceitos – Indução de Hipóteses

- Um **algoritmo de AM** aprende **a partir de um conjunto de dados de treinamento.**

- **Tenta encontrar um modelo genérico que permita realizar novas previsões**.

- **Cada algoritmo** utiliza uma **forma ou representação** para **descrever a hipótese induzida**.

Aprendizado de Máquina

Conceitos – Indução de Hipóteses

- Para **algumas tarefas de aprendizado um dos atributos** do conjunto de dados é considerado de **saída**, **os** valores dos **demais** denominados **atributos de entrada.**

- O **objetivo** de um **algoritmo de AM é aprender**, **a partir de um subconjunto** dos dados, denominados **dados de treinamento**, **um modelo ou hipótese capaz de relacionar** os valores dos **atributos de entrada ao valor** de seu **atributo de saída**.

Aprendizado de Máquina

Conceitos – Indução de Hipóteses

- Os **algoritmos de AM devem saber lidar com dados imperfeitos**, ou seja, com ruídos, inconsistências, ausências e redundâncias.

- **Dependendo da sua extensão, podem prejudicar o processo indutivo.**

- **Técnicas de pré-processamento** são utilizadas para **identificar e minimizar a ocorrência**.

Aprendizado de Máquina

Conceitos – Indução de Hipóteses – Exemplo - hospital

Atributo de Saída/Alvo (classe)

Candidatos a Atributos de Entrada

Id.	Nome	Idade	Sexo	Peso	Manchas	Temp.	# Int.	Est.	Diagnóstico
4201	João	28	M	79	Concentradas	38,0	2	SP	Doente
3217	Maria	18	F	67	Inexistentes	39,5	4	MG	Doente
4039	Luiz	49	M	92	Espalhadas	38,0	2	RS	Saudável
1920	José	18	M	43	Inexistentes	38,5	8	MG	Doente
4340	Cláudia	21	F	52	Uniformes	37,6	1	PE	Saudável
2301	Ana	22	F	72	Inexistentes	38,0	3	RJ	Doente
1322	Marta	19	F	87	Espalhadas	39,0	6	AM	Doente
3027	Paulo	34	M	67	Uniformes	38,4	2	GO	Saudável

Aprendizado de Máquina

Conceitos – Indução de Hipóteses – Exemplo - hospital

Importante!

- O que queremos é **induzir uma hipótese capaz de fazer diagnósticos corretos para NOVOS pacientes**, diferentes daqueles que foram utilizados para aprender a regra de decisão.

- **Induzida uma hipótese (função – modelo preditivo)**, é **desejável** que ela seja **válida** para **outros objetos** do **mesmo domínio ou problema** que **não fazem parte do conjunto de treinamento**.

- A essa capacidade de uma hipótese continuar a ser válida para novos objetos dá-se o nome de **capacidade de generalização da hipótese (modelo preditivo)**.

Aprendizado de Máquina

Conceitos – Indução de Hipóteses - *Overfitting*

- **Hipóteses com baixa capacidade de generalização**

Possível razão

Ela está superajustada aos dados de treinamento (***overfitting***), ou seja, se especializou somente nos dados de treinamento.

O **nosso modelo preditivo (hipótese de indução) aprendeu tanto sobre os dados que consegue percorrer exatamente os valores observados no momento que faz as previsões**

Aprendizado de Máquina

Conceitos – Indução de Hipóteses – Exemplo - ***Overfitting***

Aprendizado de Máquina

Conceitos – Indução de Hipóteses - ***undeffiting***

- **Hipóteses com baixa capacidade de acertos, mesmo no conjunto de treinamento**

Possível razão

- **condição de subajustamento** (***underfitting***). **Nenhum dos valores previstos ou quase nenhum coincide com o valor real**. Isso indica que o modelo não conseguiu capturar exatamente a relação entre os atributos de entrada e saída.

Exemplo: **dados de treinamento pouco representativos** ou o modelo usado é muito simples e não captura o padrão existente nos dados.

Aprendizado de Máquina

Conceitos – Indução de Hipóteses – Exemplo - ***Underfitting***

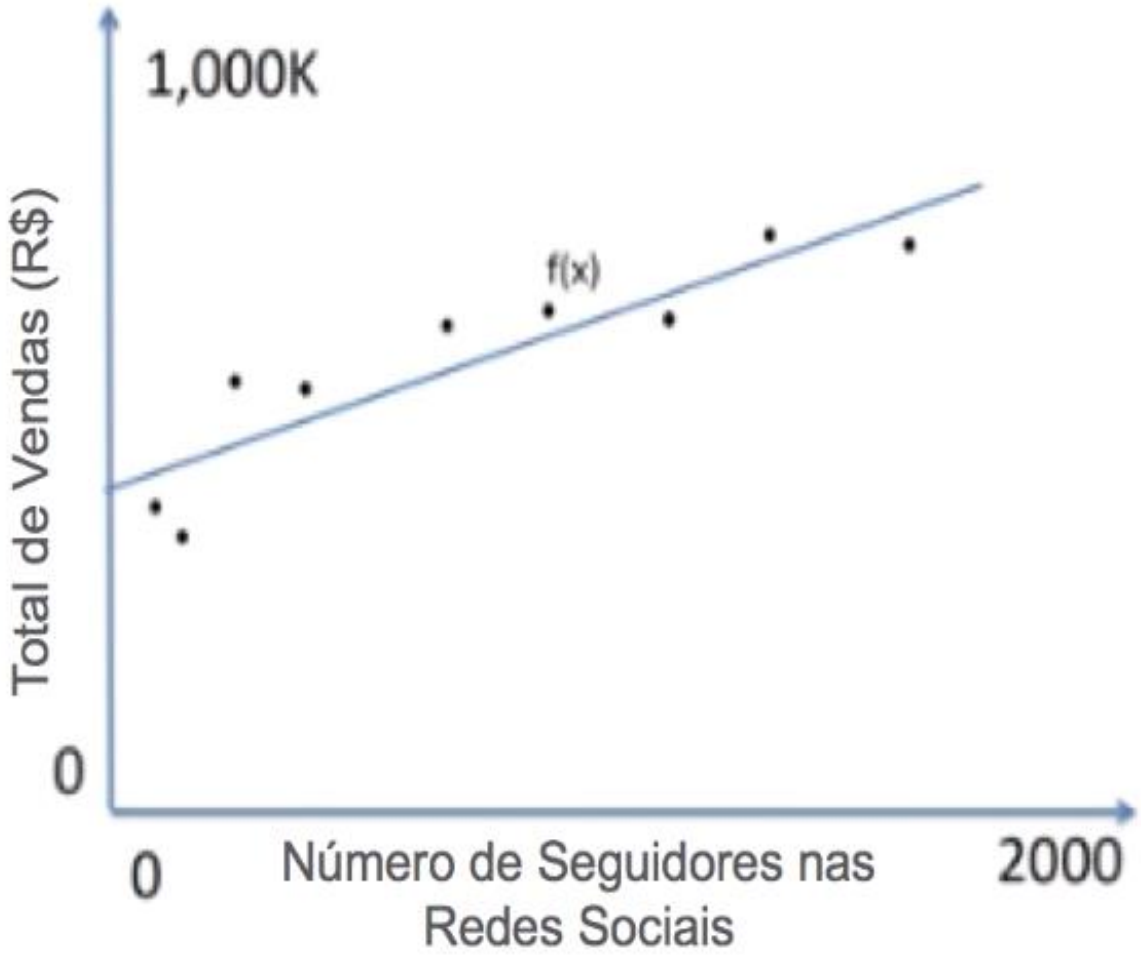

Aprendizado de Máquina

Os principais tipos de Aprendizado de Máquina

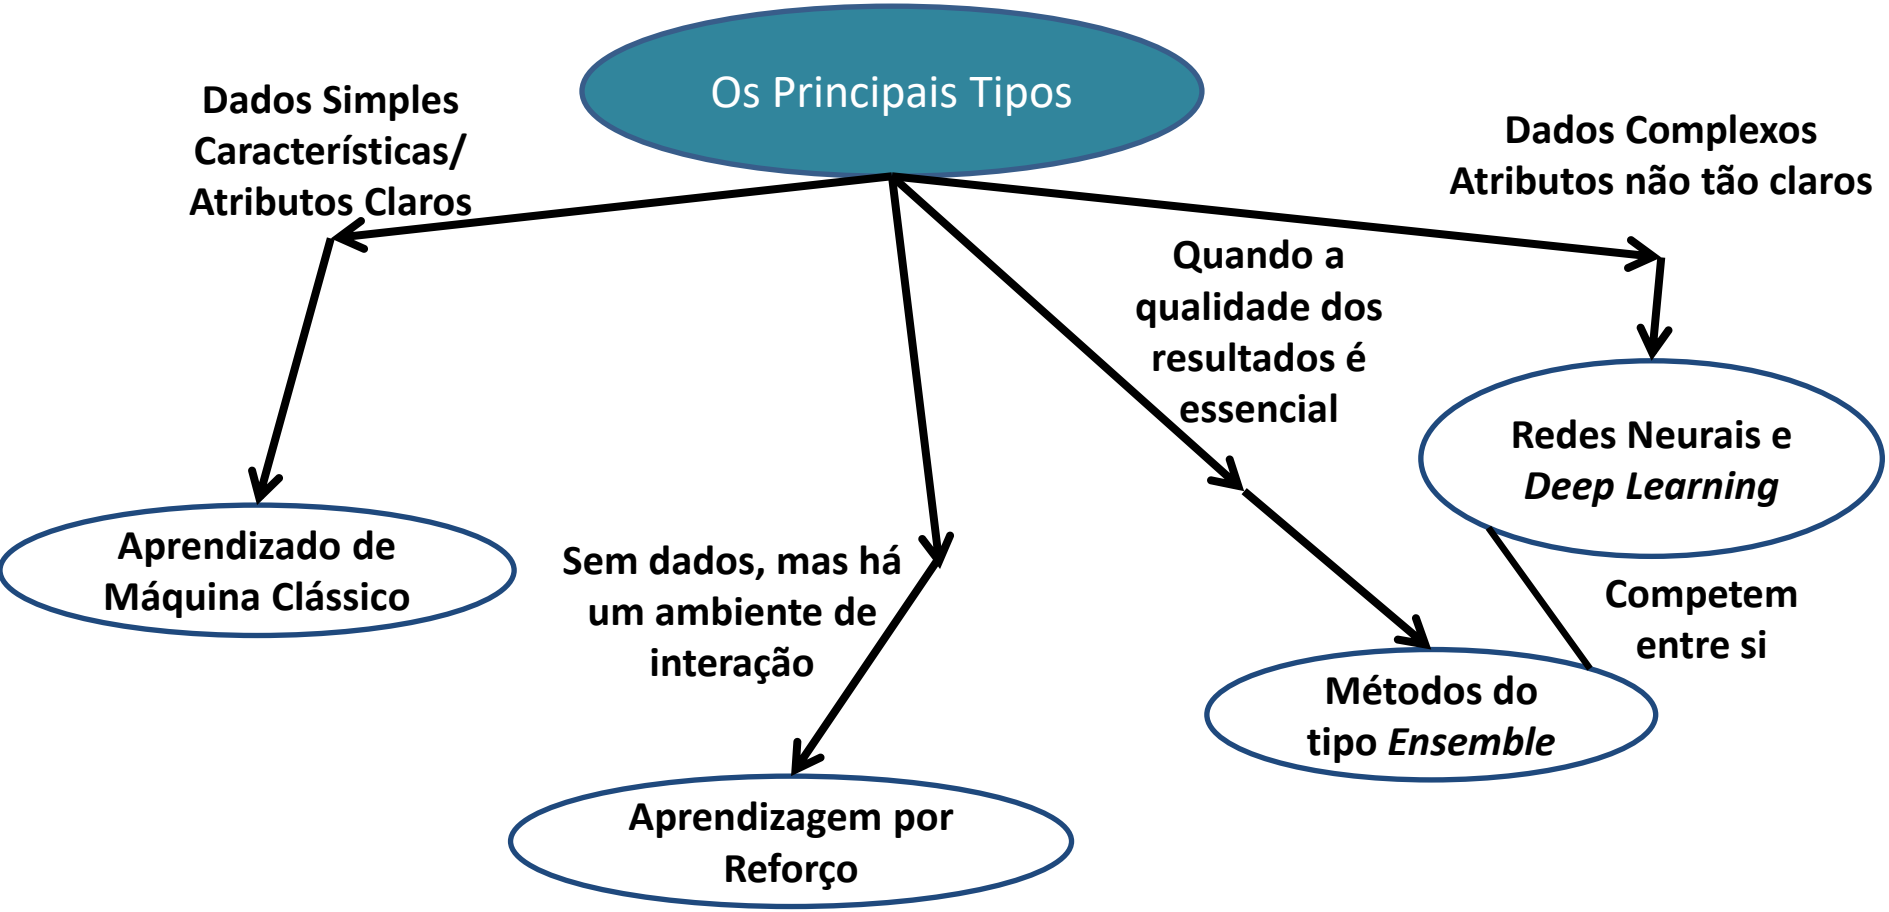

Aprendizado de Máquina Clássico

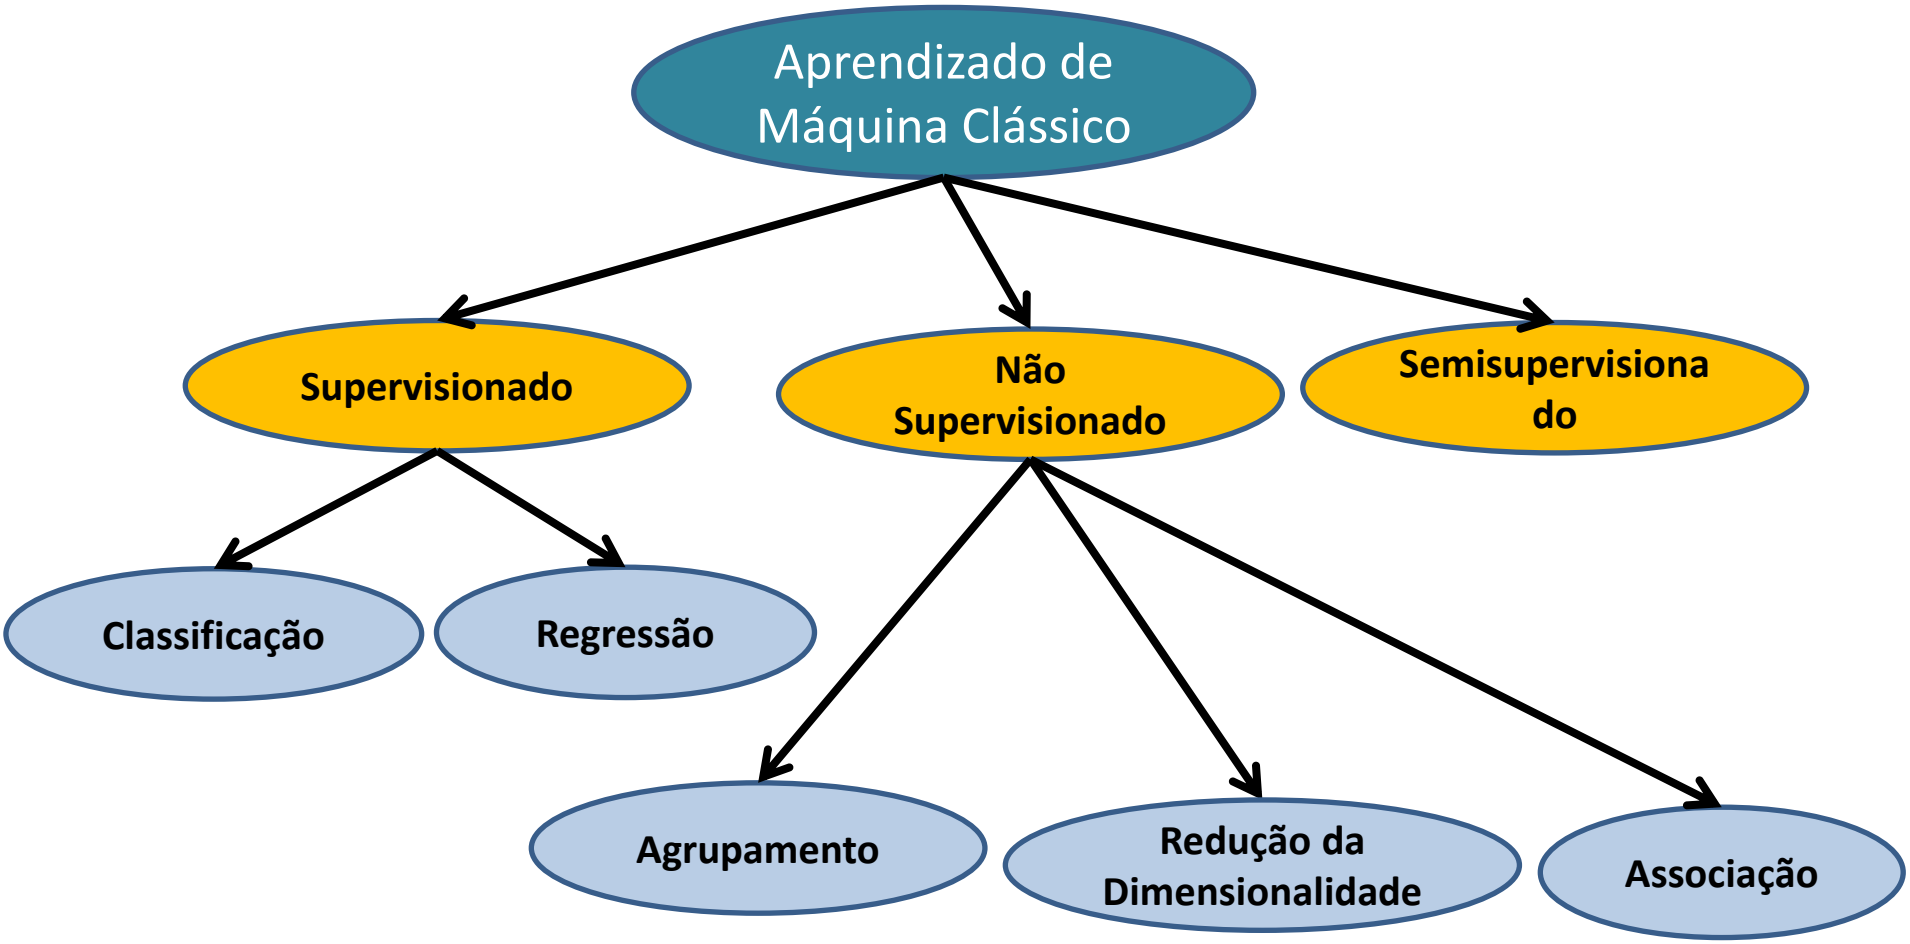

Aprendizado de Máquina

Aprendizado Supervisionado

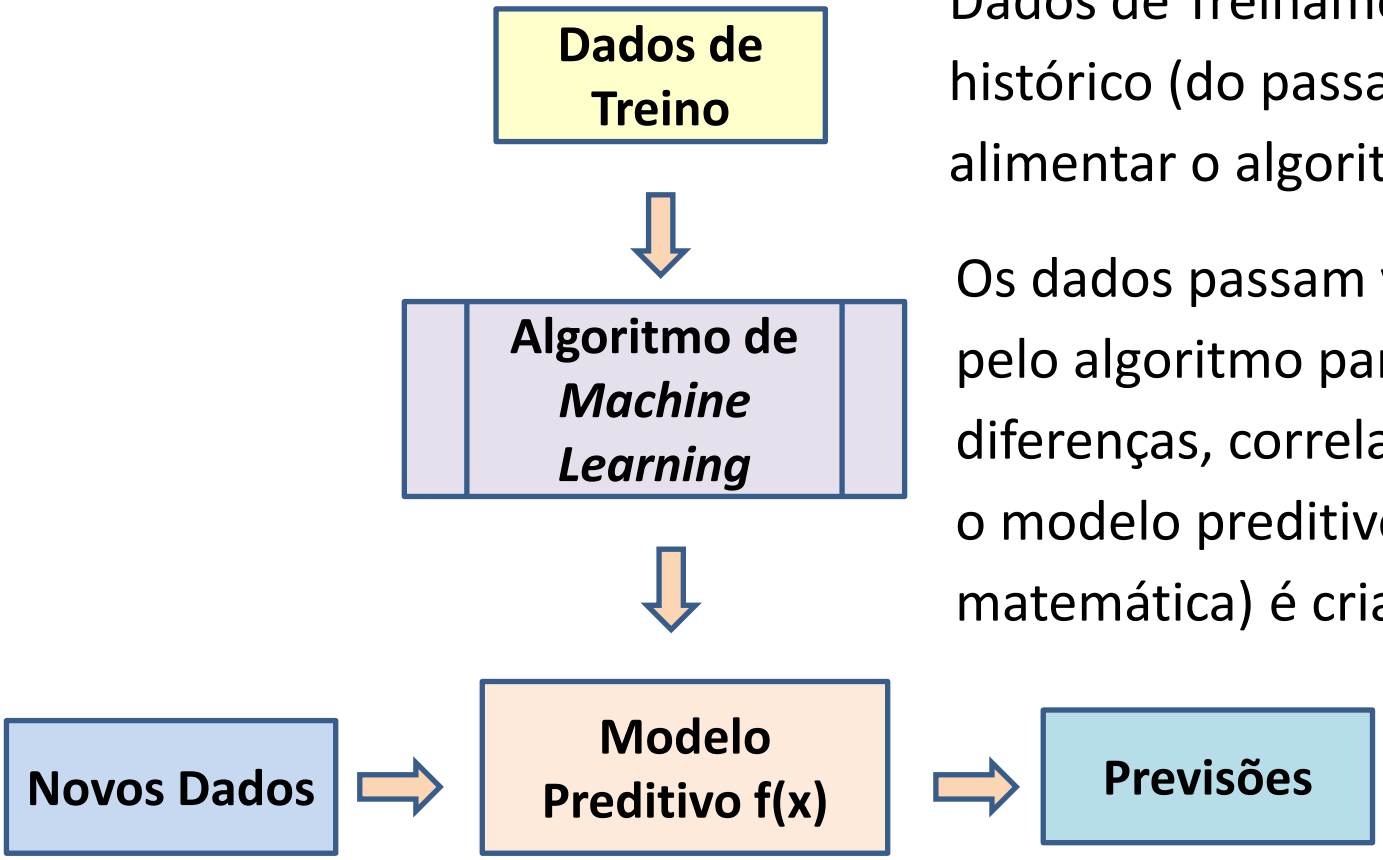

Dados de Treinamento são dados de histórico (do passado) utilizados para alimentar o algoritmo.

Os dados passam várias e várias vezes pelo algoritmo para aprender as diferenças, correlações etc. E, então, o modelo preditivo (função matemática) é criado.

Exemplo: Classificação

Posts de usuários em rede social

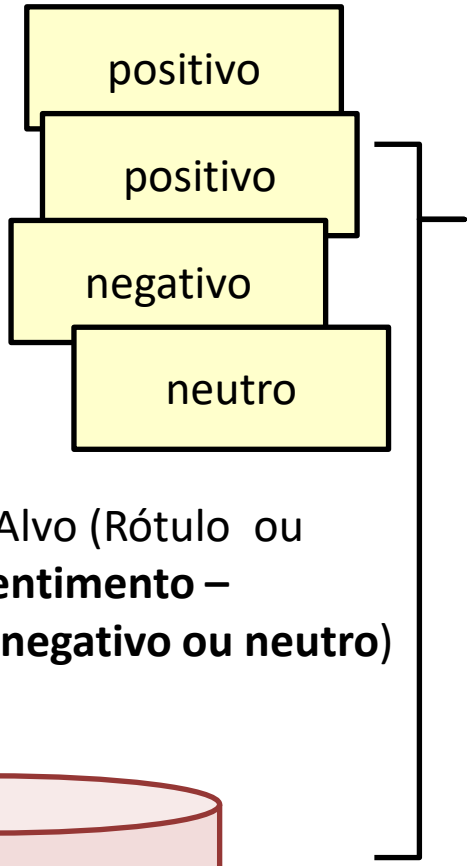

Atributos de Entrada

Atributo Alvo (Rótulo ou Saída) (**Sentimento – Positivo, negativo ou neutro**)

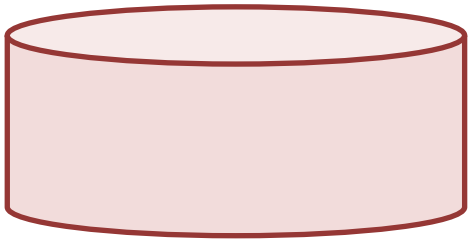

Dados de Histórico (Amostra significativa- conjunto de exemplos)

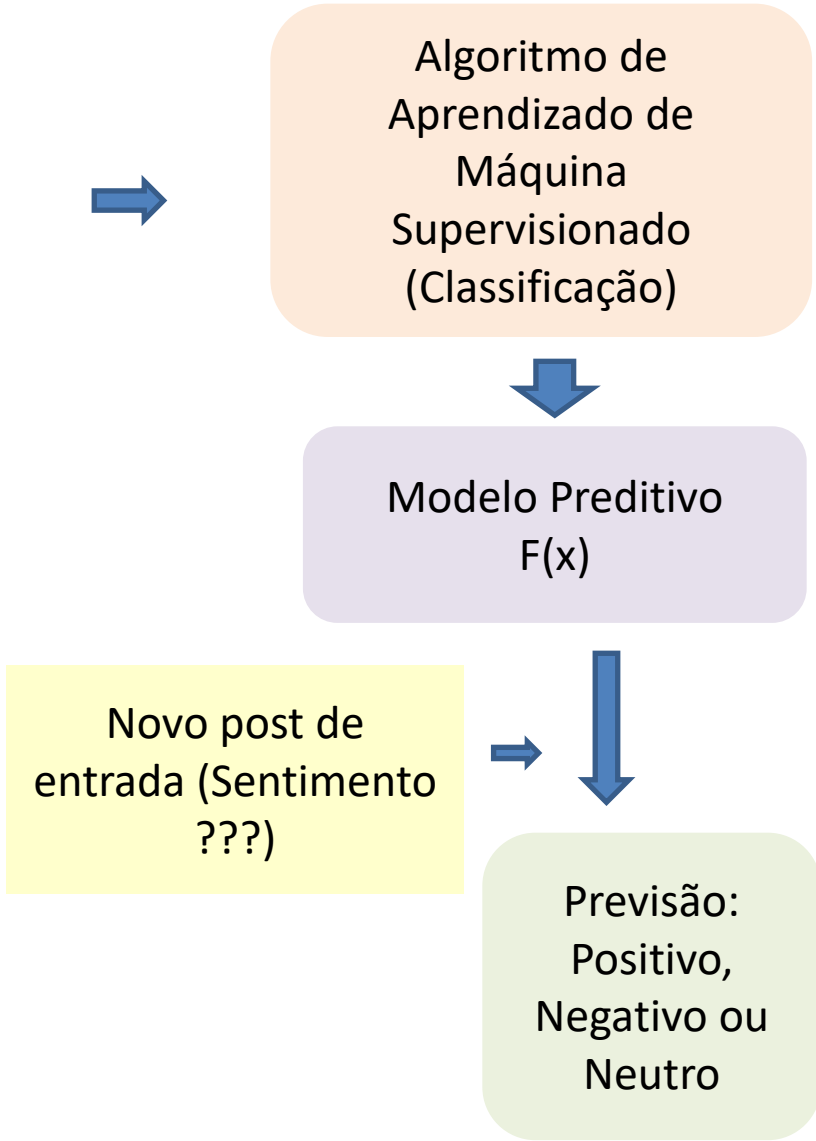

Análise de Sentimentos em Redes Sociais

Exemplo: Regressão

- Tipo de Imóvel (casa ou apto)
- Tamanho
- Número de quartos
- Região
- Vagas de Garagem

R$ 300000

R$ 400000

R$ 250000

R$ 390000

Atributos de Entrada

Atributo Alvo (Rótulo ou Saída) (**Preço - valor numérico não categórico e de espectro contínuo**)

Algoritmo de Aprendizado de Máquina Supervisionado (Regressão)

Modelo Preditivo F(x)

Novo dado de entrada (Preço ???)

Previsão: Preço = por ex.: R$ 360000

Dados de Histórico (Amostra significativa- conjunto de exemplos)

Previsão de Preços de Imóveis

Aprendizado de Máquina

Conceitos – Semisupervisionado

- O aprendizado semissupervisionado combina dados rotulados e não rotulados para treinar modelos.
- Ele usa poucos exemplos com rótulo para guiar o aprendizado e muitos dados sem rótulo para melhorar a generalização.
- É útil quando rotular dados é caro, mas há grande volume de dados disponíveis.

Aprendizado de Máquina

Conceitos – Semisupervisionado - Fluxo

Entrada

Processamento

Saída

Dados Rotulados (Poucos Exemplos)

Dados não Rotulados (Grande Volume)

Pré-processamento dos dados (Limpeza, vetorização, etc.)

Treinamento Inicial com dados rotulados

Predição dos dados não rotulados

Seleção dos exemplos com alta confiança (qualidade de predição)

Inclusão dos pseudo-rótulos no conjunto de treinamento

Re-treinamento do modelo com mais dados

Modelo final e mais robusto

Aprendizado de Máquina

Ciclo de Vida de Projeto de Data Science

1. compreensão do problema → 2. compreensão dos dados → 3. preparação dos dados → 4. modelagem → 5. avaliação → 6. implementação

   → 1. compreensão do problema →

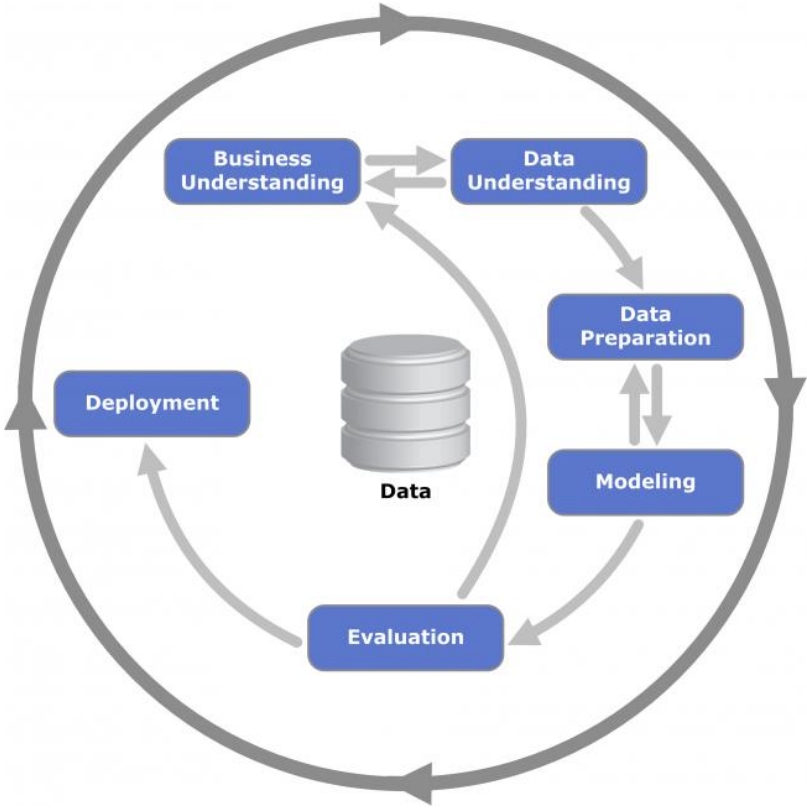

Aprendizado de Máquina

Ciclo de Vida de Projeto de Data Science

1. **Compreensão do Problema**

Conversar com gestores, profissionais da área de negócio/interesse, *stakeholders* e definir o problema (a(s) questão (questões) do que se pretende investigar). Voltar ao *stakeholder*, verificar se está correto e continuar.

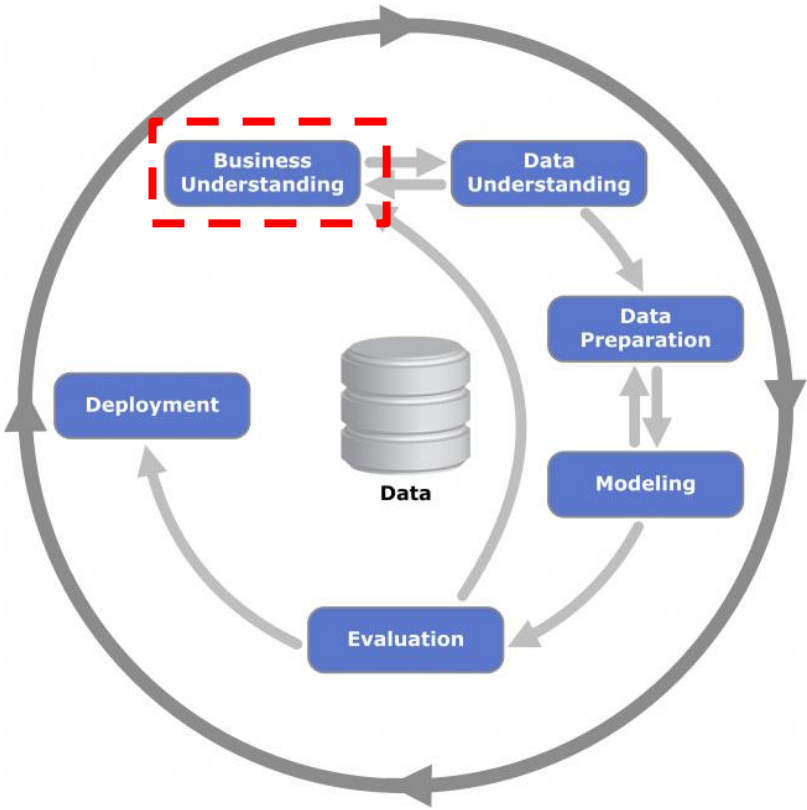

Aprendizado de Máquina

Ciclo de Vida de Projeto de Data Science

2. **Compreensão dos Dados**

Coletar e Entender os dados para resolver aquele problema.

Nesse processo, pode ser útil utilizar análise exploratória e elaboração de gráficos.

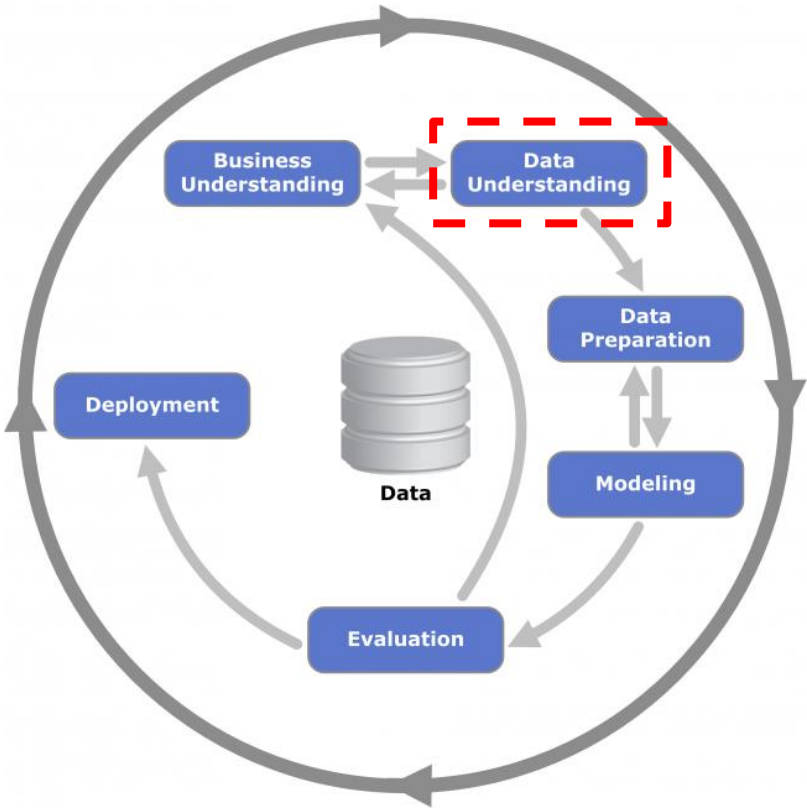

Aprendizado de Máquina

Ciclo de Vida de Projeto de Data Science

3. **Preparação dos Dados**

Data Wrangling: pré-processamento, transformação, limpeza dos dados, etc.

Até aqui, aproximadamente 70% do tempo de um Cientista de Dados.

Aprendizado de Máquina

Ciclo de Vida de Projeto de Data Science

4. **Modelagem**

Preparamos o modelo preditivo com um dos vários algoritmos de *machine learning.*

Qual é o melhor?

Depende da definição do problema.

Não há como escolher o melhor ou pior. O que existe é o algoritmo que resolve aquele problema. A escolha do algoritmo depende do problema de negócio que foi definido!

Pode ser mais rápido, mais lento, mais moderno, mais antigo.

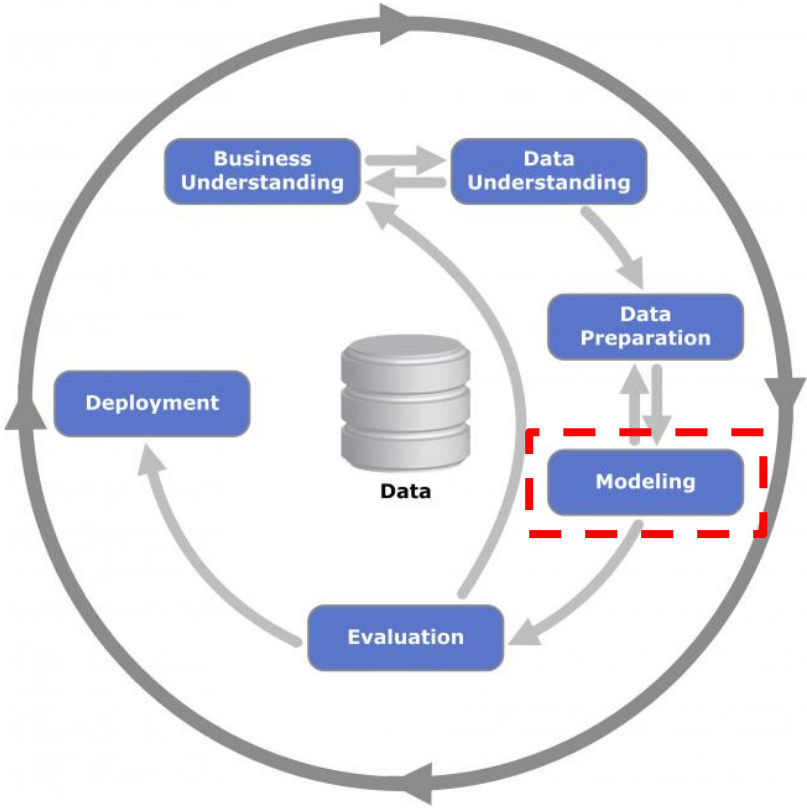

Aprendizado de Máquina

Ciclo de Vida de Projeto de Data Science

5. **Avaliação**

Avaliamos o modelo pelas métricas de erro. Olhar para as métricas para saber se o modelo preditivo atende ao seu propósito.

Qual métrica vou utilizar e com qual valor? **A métri e o percentual esperado devem ser definidos durante a fase de planejamento do projeto**.

Por exemplo, uma boa métrica para predição de câncer de mama, deve ter 98% de acurácia.

Desejar uma acurácia de 100% exige dados e capacidade (máquina), mas não é assim que funciona.

Comum criar 7 ou 8 versões do modelo preditivo até atender a métrica. Pode ser que você detecte que com este algoritmo eu não consigo atender a métrica necessária, então altero o algoritmo e realizo nova modelagem!

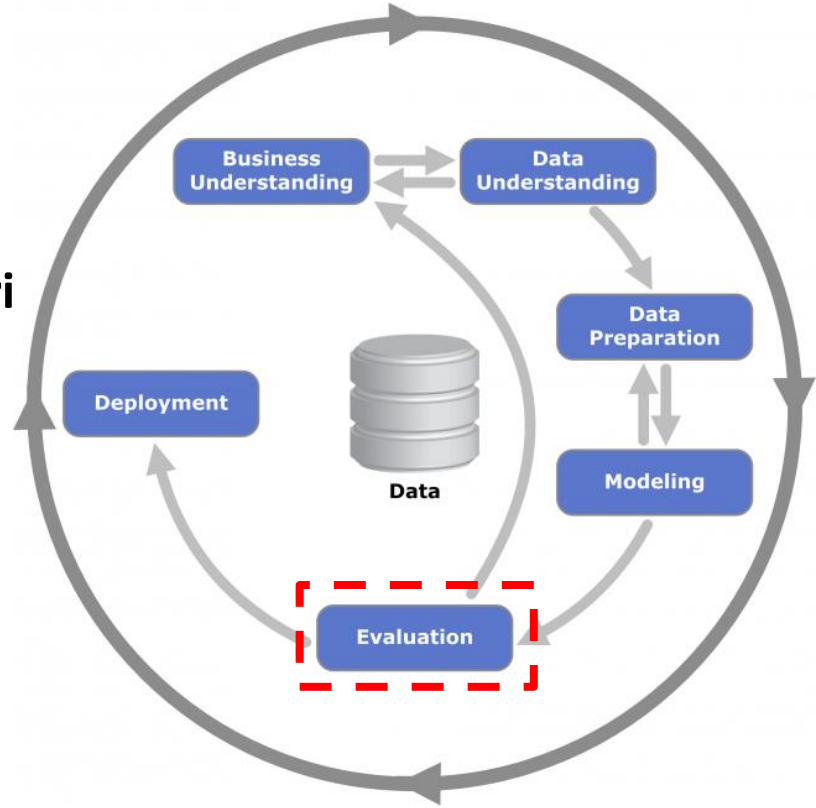

Aprendizado de Máquina

Ciclo de Vida de Projeto de Data Science

6. **Implementação**

Apresentação dos resultados.

Implementação da solução obtida, que pode ser na forma de uma aplicação analítica, um relatório, geração de gráficos, etc.

O tipo de produto a ser entregue depende do interesse.

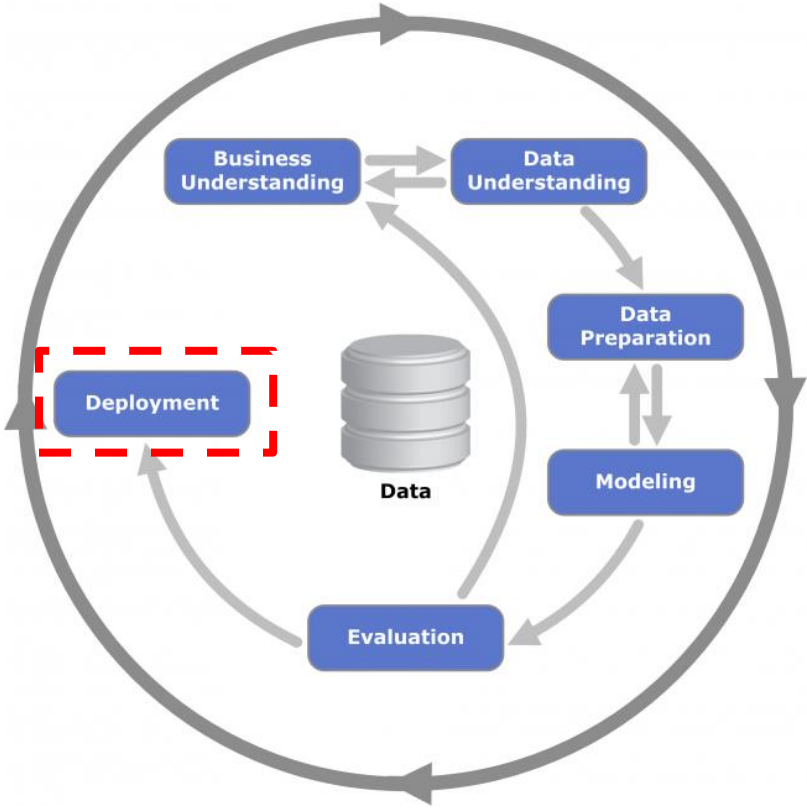

Modelagem: Aprendizado Supervisionado

Modelos de Aprendizagem

- Modelos de aprendizagem podem ser baseado em árvores, baseado em instâncias, baseado em regressão, e assim por diante e possuem um ou mais algoritmos.

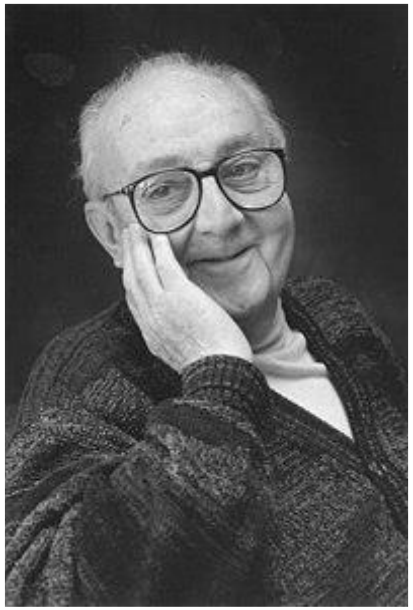

"Nenhum modelo é correto, mas alguns são úteis" . Tenha isso sempre em mente ao empregar modelos de Aprendizado de Máquina.

George Box

Uma das grandes mentes estatísticas do século XX e XXI

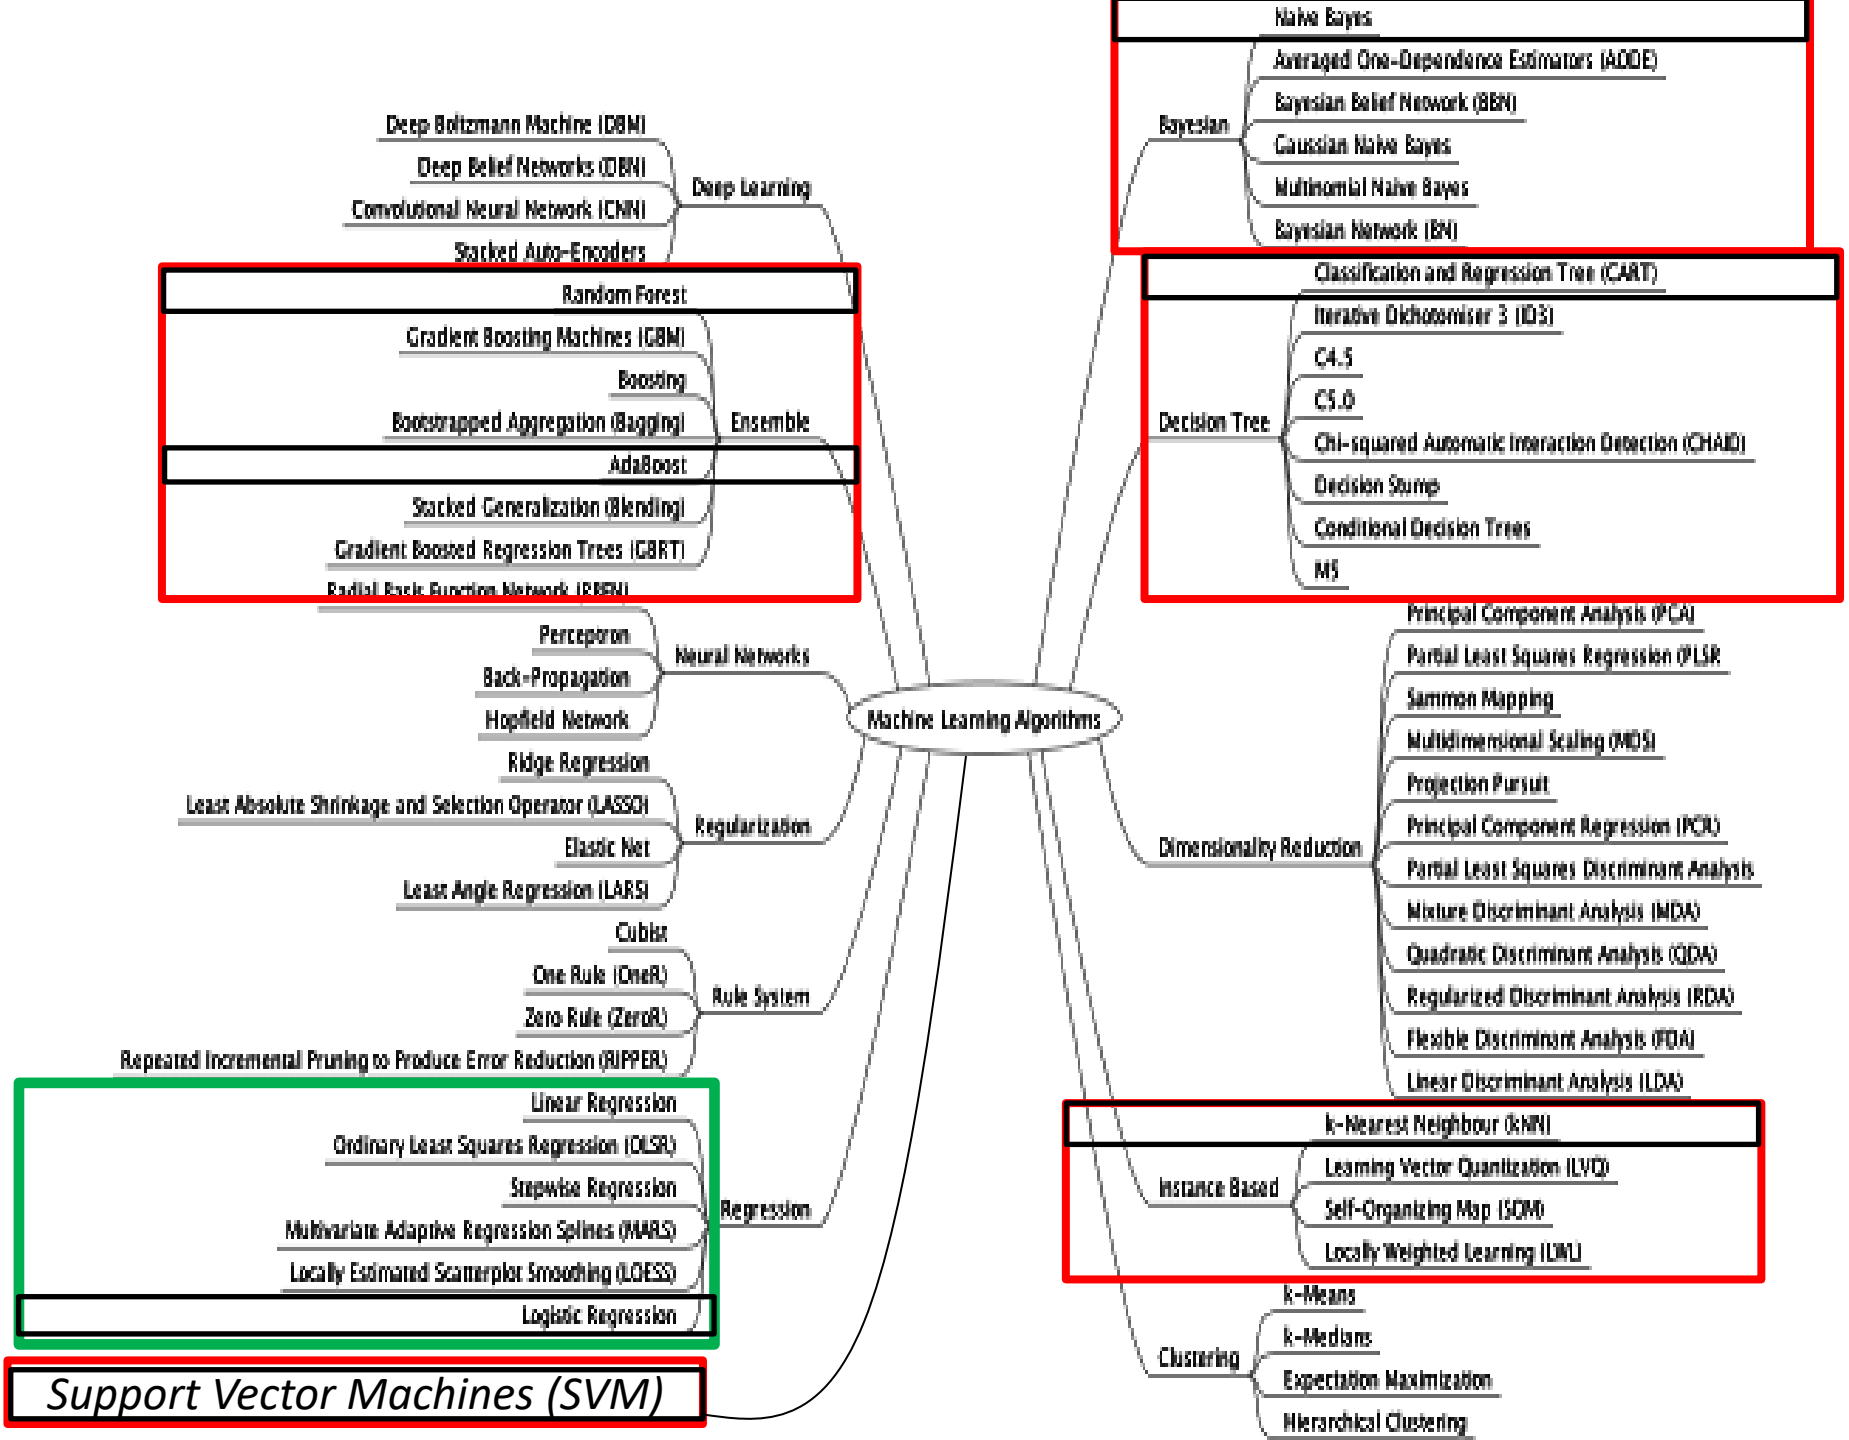
Machine Learning Algorithms
Deep Learning
Deep Boltzmann Machine (DBM)
Deep Belief Networks (DBN)
Convolutional Neural Network (CNN)
Stacked Auto-Encoders
Ensemble
Random Forest
Gradient Boosting Machines (GBM)
Boosting
Bootstrapped Aggregation (Bagging)
AdaBoost
Stacked Generalization (Blending)
Gradient Boosted Regression Trees (GBRT)
Radial Basis Function Network (RBFN)
Neural Networks
Perceptron
Back-Propagation
Hopfield Network
Regularization
Ridge Regression
Least Absolute Shrinkage and Selection Operator (LASSO)
Elastic Net
Least Angle Regression (LARS)
Rule System
Cubist
One Rule (OneR)
Zero Rule (ZeroR)
Repeated Incremental Pruning to Produce Error Reduction (RIPPER)
Regression
Linear Regression
Ordinary Least Squares Regression (OLSR)
Stepwise Regression
Multivariate Adaptive Regression Splines (MARS)
Locally Estimated Scatterplot Smoothing (LOESS)
Logistic Regression
Support Vector Machines (SVM)
Bayesian
Naive Bayes
Averaged One-Dependence Estimators (AODE)
Bayesian Belief Network (BBN)
Gaussian Naive Bayes
Multinomial Naive Bayes
Bayesian Network (BN)
Decision Tree
Classification and Regression Tree (CART)
Iterative Dichotomiser 3 (ID3)
C4.5
C5.0
Chi-squared Automatic Interaction Detection (CHAID)
Decision Stump
Conditional Decision Trees
M5
Dimensionality Reduction
Principal Component Analysis (PCA)
Partial Least Squares Regression (PLSR)
Sammon Mapping
Multidimensional Scaling (MDS)
Projection Pursuit
Principal Component Regression (PCR)
Partial Least Squares Discriminant Analysis
Mixture Discriminant Analysis (MDA)
Quadratic Discriminant Analysis (QDA)
Regularized Discriminant Analysis (RDA)
Flexible Discriminant Analysis (FDA)
Linear Discriminant Analysis (LDA)
Instance Based
k-Nearest Neighbour (kNN)
Learning Vector Quantization (LVQ)
Self-Organizing Map (SOM)
Locally Weighted Learning (LWL)
Clustering
k-Means
k-Medians
Expectation Maximization
Hierarchical Clustering

Modelagem: Aprendizado Supervisionado

Elementos do processo de Aprendizagem

Entrada

X { Atributos Preditores }

Saída

Y { Atributo Alvo }

Função real

f: X -> Y { Relaciona os atributos preditores ao atributo alvo }

Dados

(x1, y1), (x2, y2), ... (xn, yn)

{ Dados de histórico necessários para treinar o modelo }

{ Para fazer previsões para o futuro, observa-se o passado, ou seja, busca-se os padrões do passado para prever o futuro }

Hipótese

g: X -> Y

{ Aproximação da função f , ou seja, função a ser descoberta pelo algoritmo de Aprendizado de Máquina. Há um espaço de hipóteses e o algoritmo, a partir de pontuações atribuídas a cada uma delas, determina a melhor hipótese (aproximação da função f) }

Modelagem: Aprendizado Supervisionado

Elementos do processo - Síntese

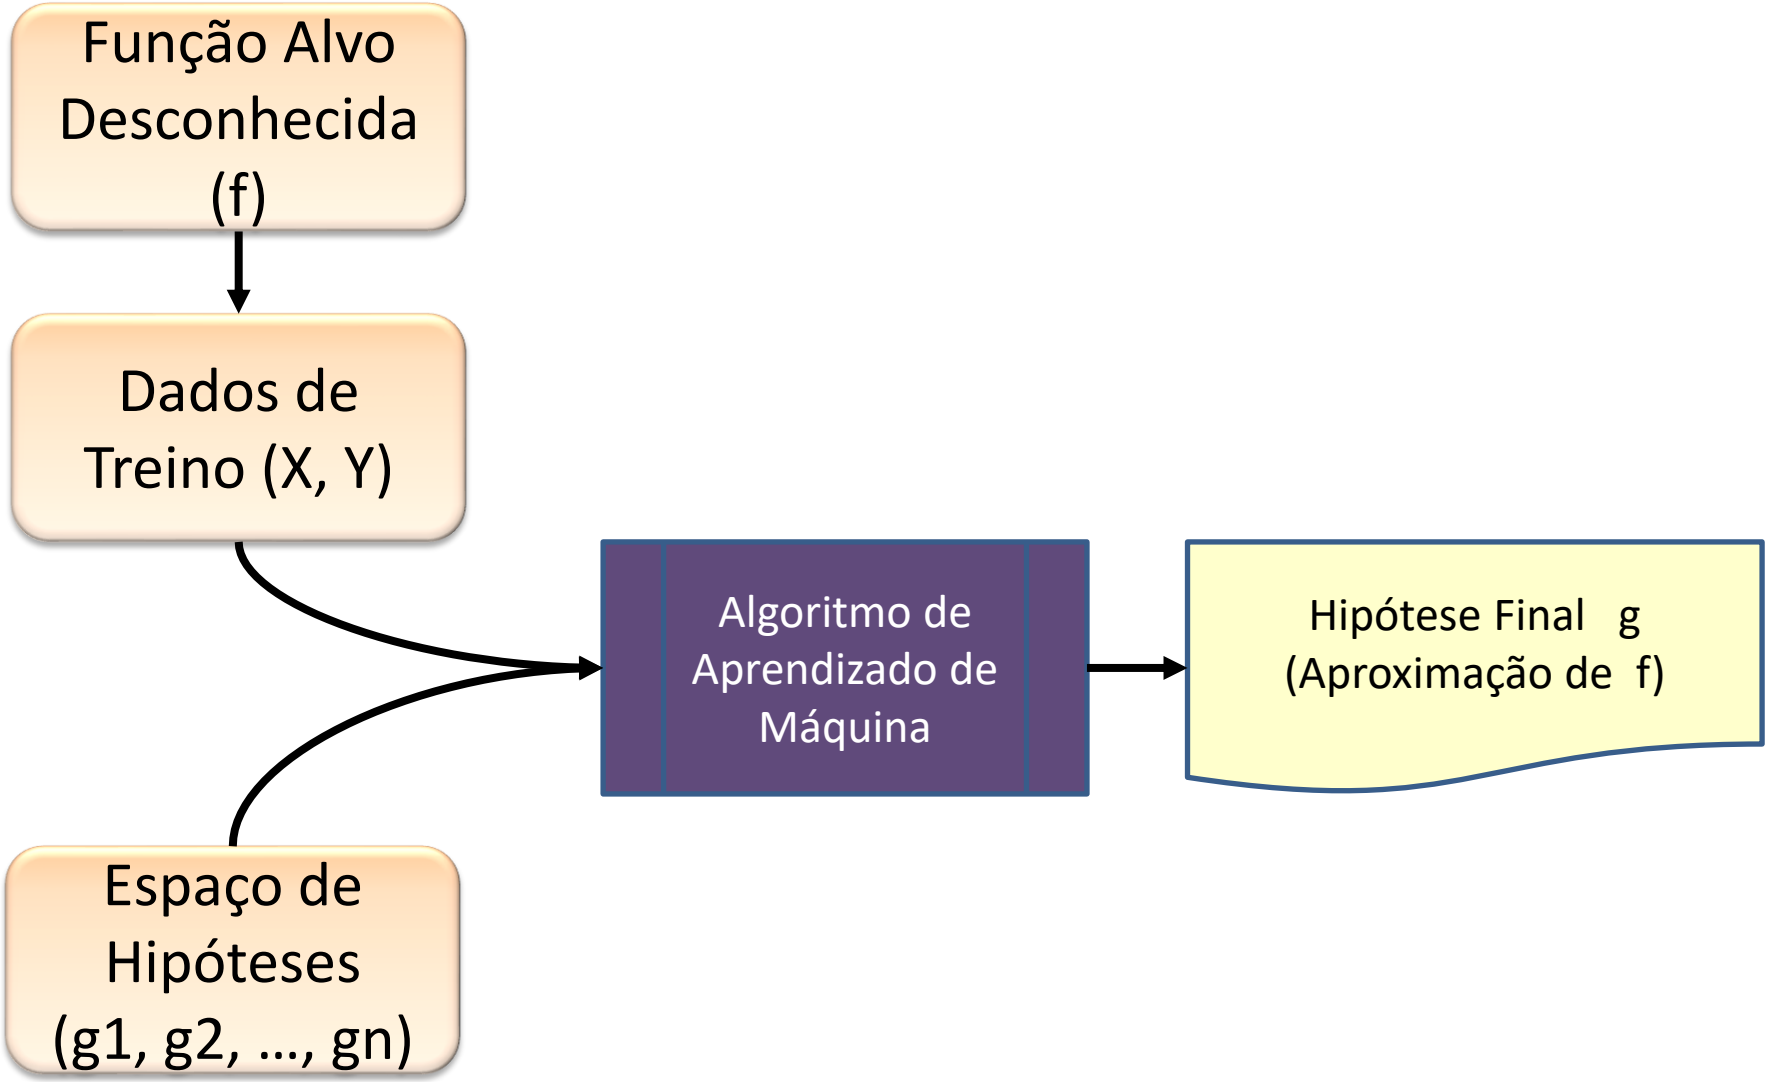

Modelagem: Aprendizado Supervisionado

O processo de Aprendizagem – Treinamento e Teste

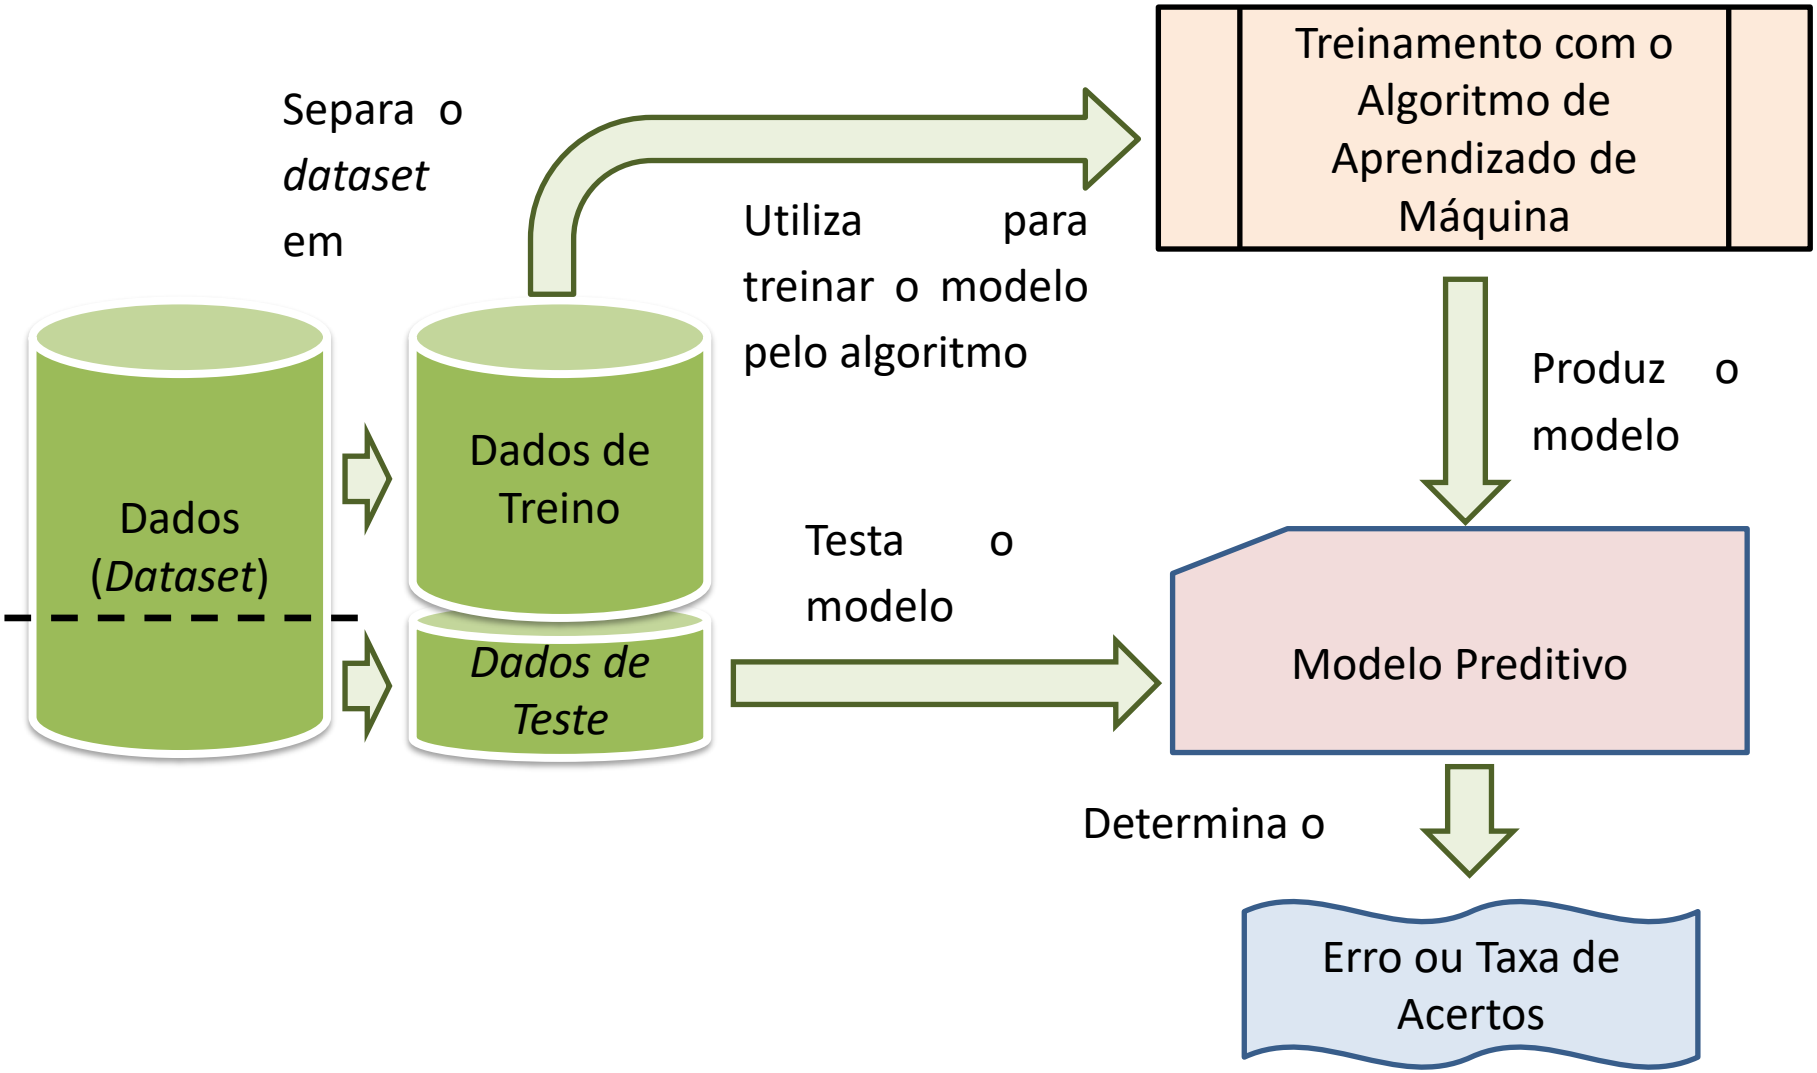

Regressão Linear

Regressão

Análise de regressão é uma **metodologia estatística** que **utiliza a relação entre duas ou mais variáveis quantitativas para predizer outra**.

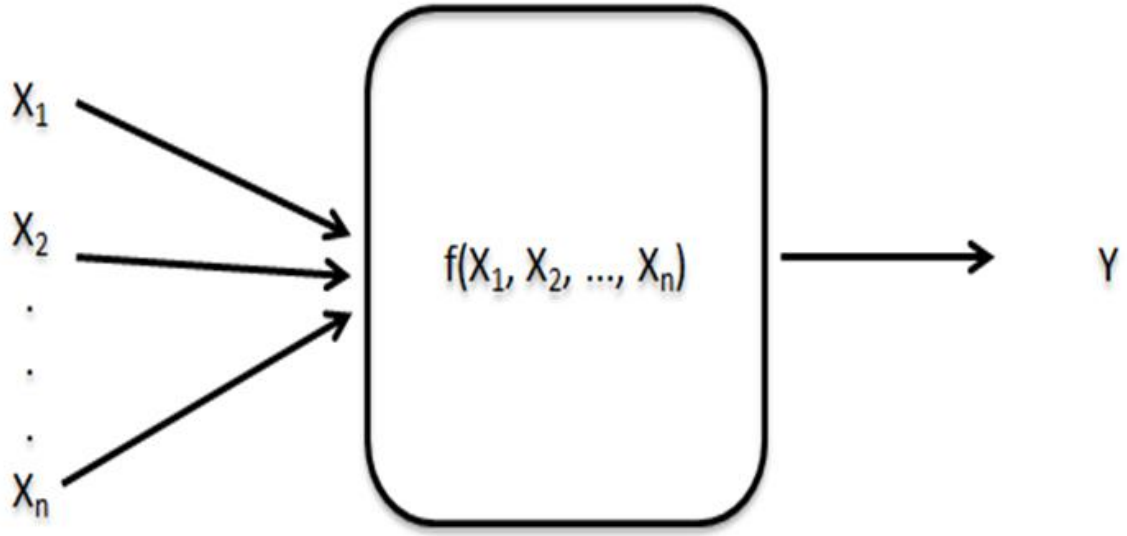

Variáveis independentes (entrada/preditoras)

$f: X \rightarrow y$

Variável dependente (saída/alvo)

Regressão

Tipos de Modelos de Regressão

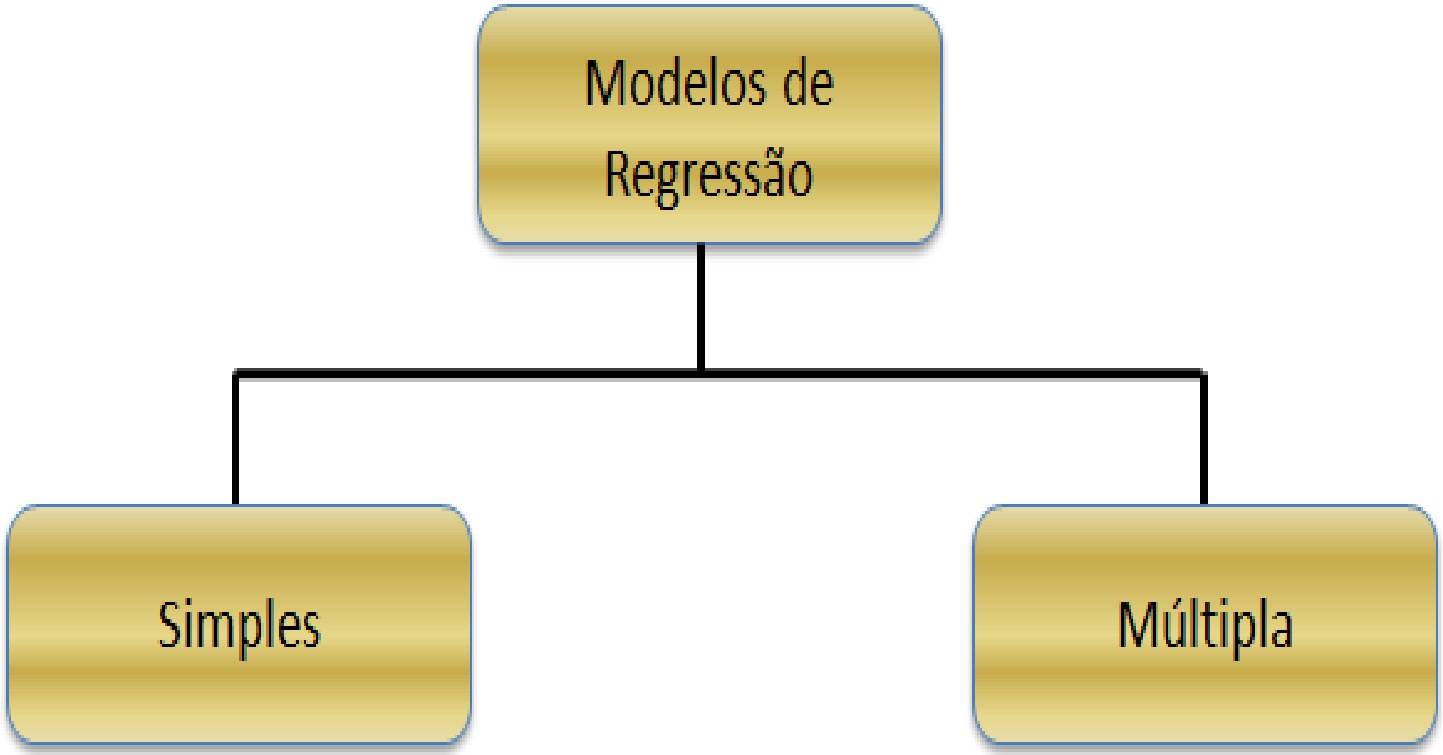

1 variável dependente y

1 variável independente x

1 variável dependente y

2 ou mais variáveis independentes xi

Modelagem: Aprendizado Supervisionado

Algoritmos - Regressão Linear Simples e Múltipla - Fórmula

- **Regressão Linear Simples:**

$$\mathbf{Y = a + b\,X + e},$$ Y é o valor a ser previsto.

Os coeficientes a (intercepta o eixo y, X = 0) e b (inclinação) são os valores a serem encontrados pelo algoritmo. Onde “e” é o erro residual.

- **Regressão linear múltipla:**

$$\mathbf{Y = a + b_1\,X_1 + b_2\,X_2 + \ldots + b_n\,X_n + e},$$ Y é o valor a ser previsto.

Os coeficientes a (intercepta o eixo y, Xs = 0) e b_1, b_2 , ..., b_n são os valores a serem encontrados pelo algoritmo.
Onde “e” é o erro residual.

Modelagem: Aprendizado Supervisionado

Algoritmos - Regressão Linear Simples e Múltipla

- y_i "chapeuzinho do vovô" é a previsão ($y_i = a + b\,X + e_i$).
- e_i é a taxa de erro.

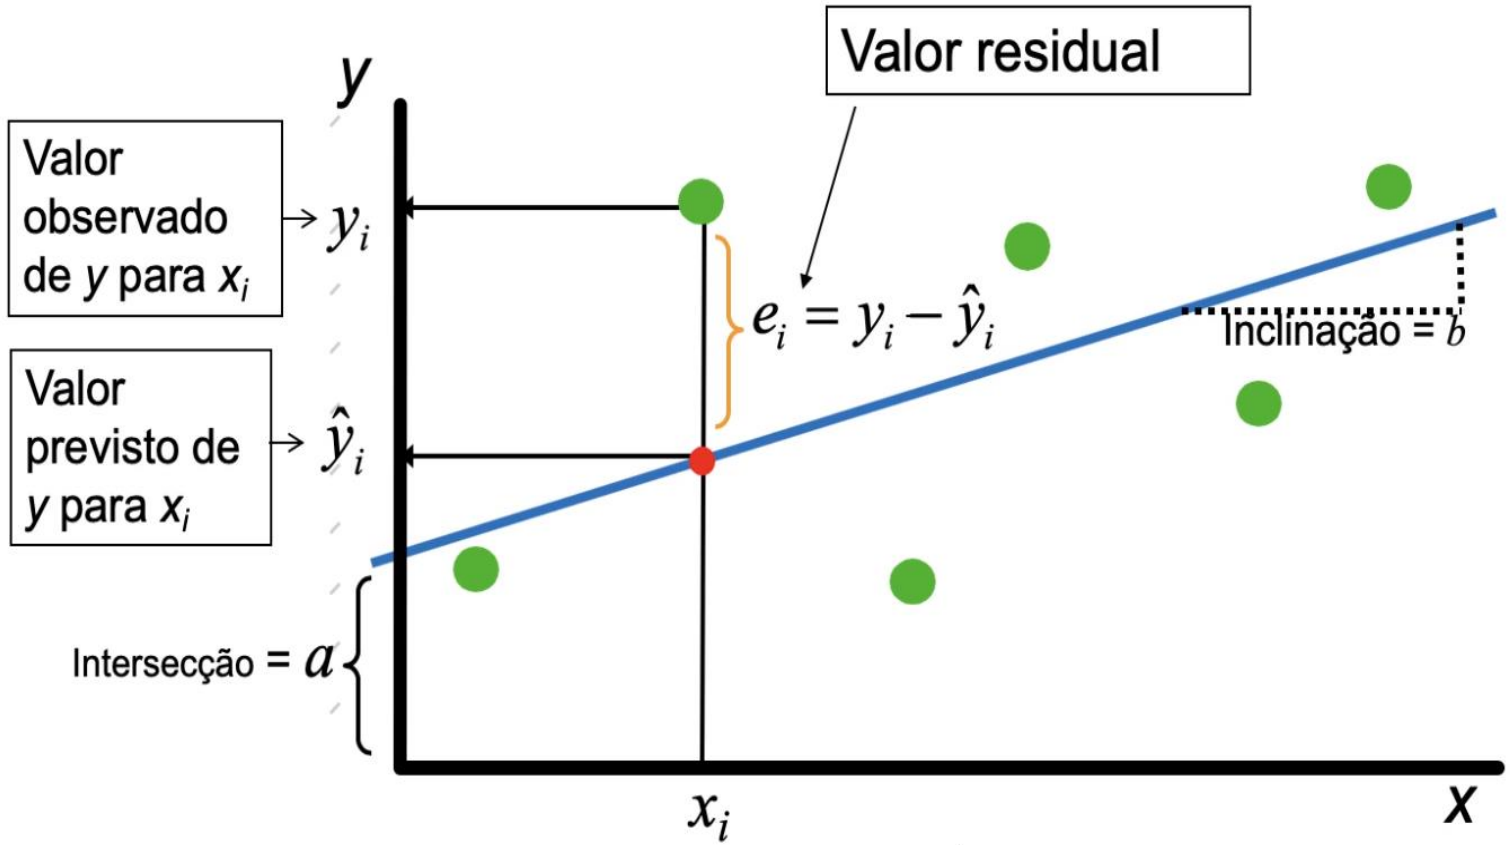

Modelagem: Aprendizado Supervisionado

Algoritmos - Regressão Linear Simples e Múltipla

- Existem diversos modelos de regressão:
  - Regressão Linear Simples e Múltipla
  - Regressão Logística Binária
  - Regressão Logística Multinomial
  - Regressão Poisson
  - Regressão Binomial
  - Regressão Ridge
  - Regressão Lasso
  - Regressão ElasticNet

Regressão Linear Simples

- Quando treinamos o modelo de *Machine Learning* utilizando regressão, **o que estamos fazendo na prática é encontrar uma equação que relaciona as variáveis independentes (entrada) com a variável dependente (saída).**
- Regressão linear múltipla estabelece o relacionamento entre mais de duas variáveis.
- **Antes de fazer a análise de regressão 1º precisamos coletar as informações de correlação (r) entre as variáveis**.
- Para isso, podemos fazer um gráfico de dispersão.
- A análise de correlação nos permite medir a força e direção de um relacionamento linear entre duas variáveis.

Regressão Linear Simples

- O relacionamento entre duas variáveis é linear, se o gráfico de dispersão entre elas tem o padrão de uma linha reta.
- Exemplos de relação linear:

Fonte: https://www.ebah.com.br/content/ABAAAAScQAG/probabilidade?part=11. Data da Consulta: 03/08/2024.

Regressão Linear Simples

a) Correlação positiva perfeita

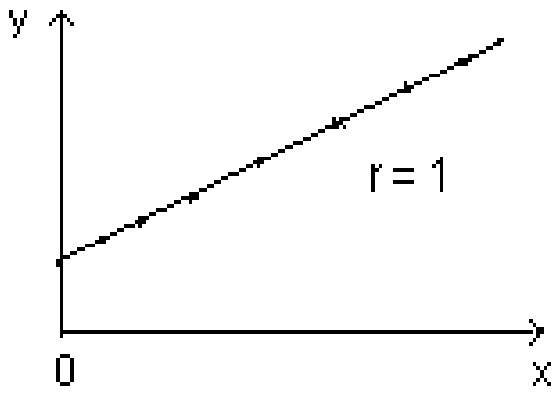

b) Correlação negativa perfeita

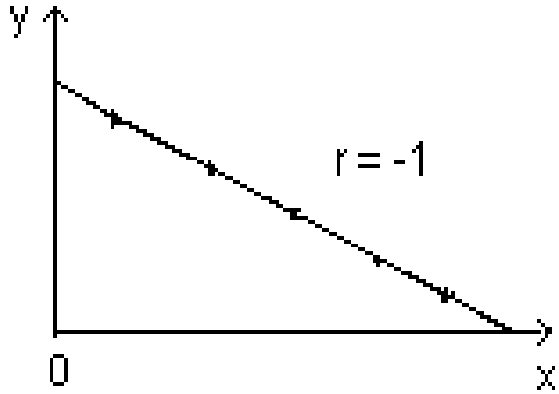

c) Correlação inexistente

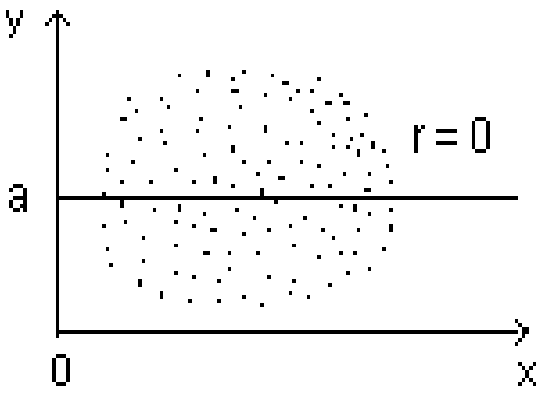

d) Correlação positiva

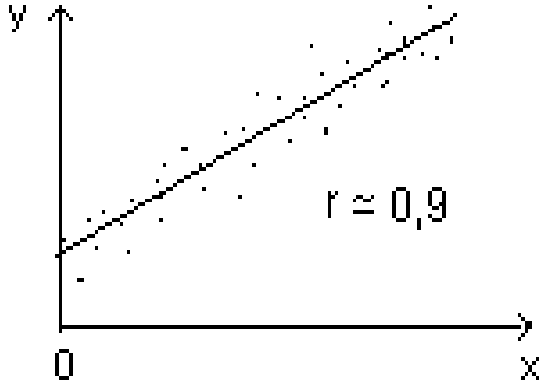

e) Correlação negativa

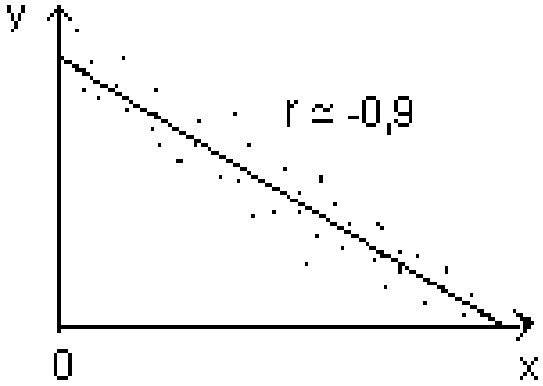

f) Correlação inexistente

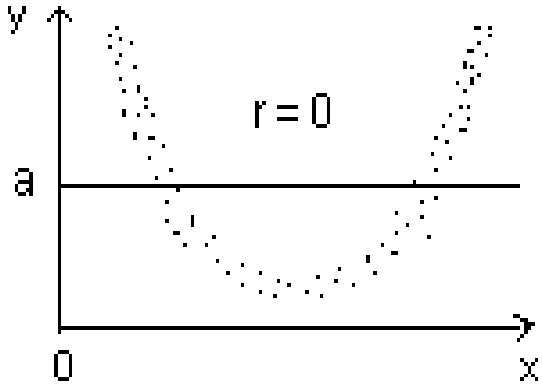

Regressão Linear Simples

Armadilhas da Análise de Regressão

- **Não faça previsões para a variável dependente (y), além do range de valores da variável independente (x).** Ou seja, se você não tem dados suficientes para fazer uma previsão não invente, trabalhe com os dados de histórico que você possui!
- **Seja bastante responsável ao fornecer as previsões aos tomadores de decisão.**
- Visto que as decisões podem impactar a vida de pessoas.
- **Não há garantia que o relacionamento estimado é apropriado além do range que foi observado.**

Regressão Linear Simples

Armadilhas da Análise de Regressão

- **Não confunda correlação com causalidade.**
- Apesar do relacionamento entre as variáveis ser estatisticamente significante, não prova que a variável independente realmente causou a mudança na variável dependente.

Regressão Linear
Analisando a eficiência do Modelo

Regressão

Interpretando Modelos de Regressão Linear Simples e Múltipla

- Podemos utilizar:
  - Teste F de Significância Global (ou estatística F).
  - Testes de Significância Individuais
  - Coeficientes R^2 e R^2 ajustado; e os
  - Coeficientes, propriamente ditos.

Regressão Linear

Analisando a eficiência do modelo

- **Teste F de Significância global (ou estatística F)**
- O teste F de significância global é útil para responder a seguinte pergunta: **O modelo é útil para prever**, por exemplo, a quantidade de gorjeios dos grilos em função da temperatura do ambiente?

Regressão Linear

Gorjeios dos Grilos e Temperatura

```
                            OLS Regression Results
==============================================================================
Dep. Variable:            temperature   R-squared:                       0.992
Model:                            OLS   Adj. R-squared:                  0.992
Method:                 Least Squares   F-statistic:                     5334.
Date:                Sun, 06 Mar 2022   Prob (F-statistic):           9.94e-47
Time:                        02:06:15   Log-Likelihood:                -70.585
No. Observations:                  45   AIC:                             145.2
Df Residuals:                      43   BIC:                             148.8
Df Model:                           1
Covariance Type:            nonrobust
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
Intercept     -0.9595      0.361     -2.659      0.011      -1.687      -0.232
chirps         0.7761      0.011     73.034      0.000       0.755       0.798
==============================================================================
Omnibus:                        3.593   Durbin-Watson:
Prob(Omnibus):                  0.166   Jarque-Bera (JB):
Skew:                           0.230   Prob(JB):
Kurtosis:                       2.091   Cond. No.
==============================================================

Warnings:
[1] Standard Errors assume that the covariance matrix of the
```

Teste F de significância global do modelo. “Há evidências de que pelo menos uma variável do modelo está relacionada com os gorjeios?”. Como valor-p do teste F < 0.05, há evidências estatísticas.

Regressão Linear

Analisando a eficiência do modelo

- Resposta: Sim, se o valor p do teste F < 0,05, há evidências estatísticas.
- Esse valor p do teste F vai dizer o seguinte: Se < 0,05, sim, existem evidências estatísticas que pelo menos uma variável no modelo está relacionada com o preço. No caso da figura, observe que o resultado foi $9{,}94*10^{-47} \approx 0{,}00$. Então, esse modelo possui ao menos uma variável que nos ajuda a explicar a quantidade de gorjeios.
- Se o valor p do teste F > 0,05, o modelo pode ser abandonado, pois não há dados suficientes ou seus dados estão incorretos para prever a quantidade de gorjeios.
- Nesse caso, pode-se tentar retornar a fase de pré-processamento ou eventualmente coletar novos dados.

Regressão Linear Múltipla

Analisando a eficiência do modelo

- **Testes de Significância Individuais**
- As próximas métricas para interpretar o modelo são os testes de significância individuais e nos ajudam a identificar: **quais variáveis preditoras estão relacionadas com a variável alvo**?

Regressão Linear

Estimando o Preço de Veículos

```
                            OLS Regression Results
==============================================================================
Dep. Variable:                  Price   R-squared:                       0.727
Model:                            OLS   Adj. R-squared:                  0.689
Method:                 Least Squares   F-statistic:                     18.94
Date:                Sun, 06 Mar 2022   Prob (F-statistic):           2.32e-16
Time:                        02:04:54   Log-Likelihood:                -251.04
No. Observations:                  82   AIC:                             524.1
Df Residuals:                      71   BIC:                             550.6
Df Model:                          10
Covariance Type:            nonrobust
==================================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
----------------------------------------------------------------------------------
Intercept     53.1792     28.749      1.850      0.069      -4.146     110.504
Passengers    -0.3768      1.317     -0.286      0.776      -3.004       2.250
Length         0.0090      0.130      0.069      0.945      -0.251       0.269
Wheelbase      0.6436      0.280      2.301      0.024       0.086       1.201
Width         -1.5020      0.457     -3.289      0.002      -2.413       0.591
Turncircle    -0.5811      0.374     -1.555      0.124      -1.326       0.164
Luggageroom    0.0801      0.349      0.230      0.819      -0.615       0.776
Weight         0.0066      0.005      1.366      0.176      -0.003       0.016
Horsepower     0.1430      0.046      3.123      0.003       0.052       0.234
EngineSize    -0.7457      2.409     -0.310      0.758      -5.549       4.057
RPM           -0.0025      0.002     -1.081      0.283      -0.007       0.002
==============================================================================
Omnibus:                       28.002   Durbin-Watson:                   1.869
Prob(Omnibus):                  0.000   Jarque-Bera (JB):               81.343
Skew:                           1.048   Prob(JB):                     2.17e-18
Kurtosis:                       7.406   Cond. No.                     2.88e+05
==============================================================================

Warnings:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
[2] The condition number is large, 2.88e+05. This might indicate that there are
strong multicollinearity or other numerical problems.
```

Há evidências estatísticas de relação das variáveis preditoras com p-value < 0.05 com a variável alvo (dependente). Se o p-value > 0.05 a variável preditora estatisticamente não relaciona-se a variável alvo

Regressão Linear

Analisando a eficiência do modelo

- Nesse caso, **caso o valor p das variáveis seja < 0,05, há evidências estatísticas de que as variáveis preditoras estão relacionadas ao atributo alvo** (preço da veículo) **e nos ajuda a prevê-lo**.
- No exemplo, o valor p das variáveis width e weight é < 0,05, então, há evidências estatísticas da elas estão relacionadas ao atributo alvo.

Regressão Linear

Analisando a eficiência do modelo

- **Coeficientes R^2 e R^2 ajustado:**
- O coeficiente R^2 nos ajuda a responder a seguinte pergunta: **Qual o percentual de variabilidade é explicado pelas variáveis preditoras usadas do modelo?**
- O R^2 ajustado nos ajuda a responder: **quando tenho mais de um modelo, qual escolher?**

Regressão Linear

Exemplo de Regressão Linear Simples com dados aleatórios de f: X → Y

```
                            OLS Regression Results
==============================================================================
Dep. Variable:                      y   R-squared:                       0.979
Model:                            OLS   Adj. R-squared:                  0.979
                                        F-statistic:                     2246.
                                        Prob (F-statistic):           5.71e-42
                                        Log-Likelihood:                -65.935
                                        AIC:                             135.9
Df Residuals:                      48   BIC:                             139.7

                                                                 ==============
                                                            25      0.975]
------------------------------------------------------------------------------
Intercept     -4.9986      0.239    -20.948      0.000      -5.478      -4.519
x              2.0272      0.043     47.397      0.000       1.941       2.113
==============================================================================
Omnibus:                        0.058   Durbin-Watson:                   1.590
Prob(Omnibus):                  0.971   Jarque-Bera (JB):                0.057
Skew:                           0.048   Prob(JB):                        0.972
Kurtosis:                       2.865   Cond. No.                         10.4
==============================================================================

Warnings:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
```

R2: 97.9% da variabilidade da variável alvo y é explicada pela variável preditora x

R2 ajustado é sempre menor ou igual ao R2, deve ser utilizado para comparer modelos com diferentes quantidades de variáveis preditoras

Regressão Linear

Analisando a eficiência do modelo

- **Quanto maior o R^2, melhor**! Significa que as nossas variáveis são variáveis fortes! Elas realmente nos ajudam a prever a variável alvo.
- **Um dos objetivos na construção do modelo de regressão é buscar aumentar o coeficiente R^2.**
- **O R^2 ajustado**, sempre vai ser um pouco menor do que o R^2 e ele deve ser **utilizado para comparar modelos com diferentes quantidades de variáveis**.

Regressão Linear

Analisando a eficiência do modelo

- R^2 qual é um bom valor?
- Não existe um modelo 'certo' e a questão pode ser melhor formulada por:
- **Qual valor de R^2 é um bom resultado para os seus propósitos?**
- Mas de modo geral valores **R^2>0.8 são bastante úteis para predições** e com valores abaixo **R^2<0.6 recomenda-se buscar outros modelos de aproximação dos dados e/ou outros dados**.

Regressão Linear

Analisando a eficiência do modelo

- **Coeficientes, propriamente ditos.**
- Finalmente, os coeficientes da fórmula de regressão múltipla obtido.

Regressão Linear

Estimando preço de imóveis de São Paulo

```
                            OLS Regression Results
==============================================================================
Dep. Variable:                   preco   R-squared:                       0.637
Model:                             OLS   Adj. R-squared:                  0.637
Method:                  Least Squares   F-statistic:                     5217.
Date:                 Sun, 10 Mar 2024   Prob (F-statistic):               0.00
Time:                         16:57:06   Log-Likelihood:            -1.0727e+05
No. Observations:                14873   AIC:                         2.146e+05
Df Residuals:                    14867   BIC:                         2.146e+05
Df Model:                            5
Covariance Type:             nonrobust
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
Intercept   -102.3474     11.195     -9.142      0.000    -124.291     -80.404
metros         3.4466      0.054     64.068      0.000       3.341       3.552
quartos       59.7761      5.050     11.838      0.000      49.878      69.674
banheiros    121.3912      4.432     27.387      0.000     112.703     130.079
suites       -21.5647      4.473     -4.821      0.000     -30.333     -12.796
vagas         64.2579      4.623     13.900      0.000      55.197      73.319
==============================================================================
Omnibus:                     1482.160   Durbin-Watson:                   1.163
Prob(Omnibus):                  0.000   Jarque-Bera (JB):             6293.774
Skew:                           0.421   Prob(JB):                         0.00
Kurtosis:                       6.074   Cond. No.                         616.
==============================================================================

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
```

Preco = -102.3474 + 3.4466*metros + 59.7761*quartos + 121.3912*banheiros -21.5647*suites + 64.2579*vagas

Regressão Linear

Problemas Regressão Linear Múltipla - Multicolinearidade

- Quando duas ou mais variáveis independentes são altamente correlacionadas, elas passam a "competir" para explicar o mesmo efeito no modelo, pode ser adequado remover uma delas.

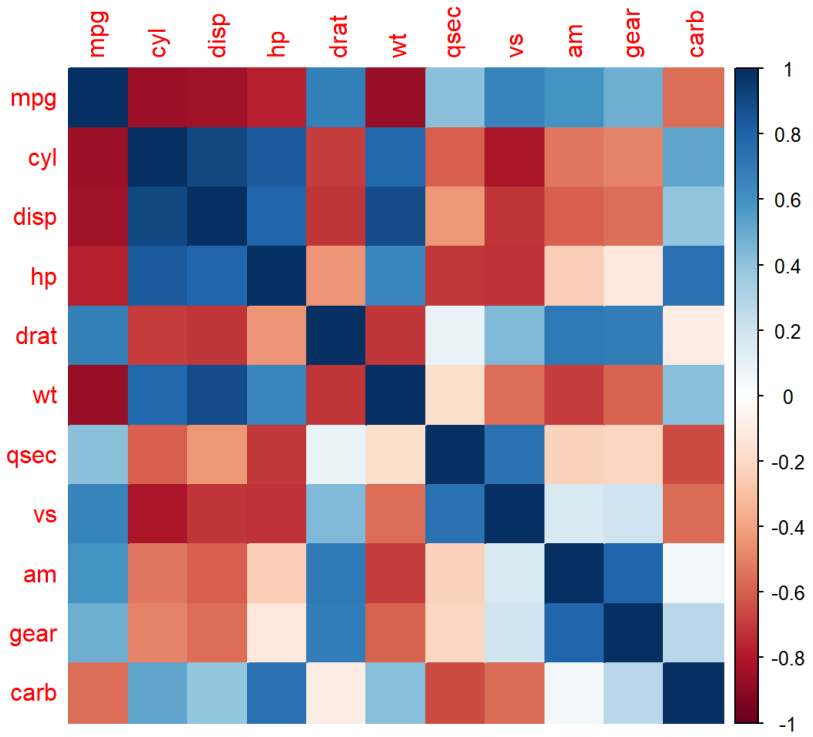

Regressão Linear

Critérios para escolher QUAL variável remover

- **Mantenha** a variável **mais correlacionada com a variável alvo**.
- **Escolha a mais** interpretável / **relevante**.
- **Remova a variável com maior VIF** (*Variance Inflation Factor* - Fator de Inflação da Variância): mede quanto a variância de um coeficiente de regressão está sendo "inflada" devido à correlação com outras variáveis independentes. (VIF = $1/(1- R^2)$). Ele indica o quanto uma variável está sendo explicada pelas outras variáveis do modelo.

Código Python:

```
from statsmodels.stats.outliers_influence import
variance_inflation_factor
...
# Exemplo
vif = [variance_inflation_factor(df.values, i) for i in
range(df.shape[1])]
```

Regressão Linear

VIF	Interpretação
1	Sem correlação
1 – 5	Correlação moderada
5 – 10	Alta correlação
> 10	Multicolinearidade forte

Quando NÃO precisa remover?

- Em modelos como: Árvores de decisão, Random Forest e XGBoost
- Esses modelos não sofrem tanto com multicolinearidade.

Regressão

Exemplo em Python: datasets de teste

Considere os dados de valores de imóveis da capital de São Paulo depois coletados e tendo sido preparados gerando o arquivo CSV "**dadosSP_depoisLimpeza.csv**" contendo como **atributo alvo (preço – variável dependente)** e atributos candidatos a preditores (entrada – variáveis independentes): **bairro, metros, quartos, banheiros, suites e vagas**".

Regressão

statsmodels - construindo o modelo linear

Modelos de regressão simples e múltipla empregando o pacote **statsmodels** do Python.

Regressão

statsmodels - construindo o modelo linear – import de pacotes e carga de dataset

```
# importação de pacotes
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
# Necessário importar a biblioteca stasmodels.formula.api
import statsmodels.formula.api as sm

# Carregando arquivo csv usando Pandas
dfaptos_SP = pd.read_csv('aptoSP_depoislimpeza.csv',
    sep = ',', encoding = 'UTF-8')
```

Regressão

statsmodels - construindo o modelo linear – definição do modelo

Construindo o modelo linear, sm.ols(formula = , data=)

A função sm.ols() (*ordinary least squares*), se refere ao método de otimização empregado) requer um conjunto de treinamento e um parâmetro formula (bastante empregado em modelos) que indica a variável dependente (objetivo) e as variáveis independentes (preditoras) do modelo.

formula = 'y ~ x'

Significa y <- x

para um modelo y = a_0 + a_1 x

```
# Definição do modelo
model = sm.ols(formula='preco ~ metros', data=dfaptos_SP)
```

Regressão

statsmodels - construindo o modelo linear – treinamento

```
# Treinamento

result = model.fit()
```

Regressão

statsmodels - construindo o modelo linear – resumo do treinamento

O método summary() apresenta, então, vários resultados do modelo

print(result.summary())

```
                            OLS Regression Results
==============================================================================
Dep. Variable:                   preco   R-squared:                       0.573
Model:                             OLS   Adj. R-squared:                  0.573
Method:                  Least Squares   F-statistic:                 1.998e+04
Date:                 Mon, 15 Sep 2025   Prob (F-statistic):               0.00
Time:                         23:14:25   Log-Likelihood:            -1.0847e+05
No. Observations:                14873   AIC:                         2.169e+05
Df Residuals:                    14871   BIC:                         2.170e+05
Df Model:                            1
Covariance Type:             nonrobust
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
Intercept    217.2954      5.347     40.637      0.000     206.814     227.777
metros         5.4421      0.039    141.345      0.000       5.367       5.518
==============================================================================
Omnibus:                     1416.556   Durbin-Watson:                   1.088
Prob(Omnibus):                  0.000   Jarque-Bera (JB):            10570.487
Skew:                           0.079   Prob(JB):                         0.00
Kurtosis:                       7.127   Cond. No.                         255.
==============================================================================

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
```

Regressão

Biblioteca scikit-learn - Python

Documentação: https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LinearRegression.html.

Assume que os dados estão em Distribuição Normal e também assume que as variáveis são relevantes para a construção do modelo e que não sejam colineares, ou seja, variáveis com alta correlação (Então, devemos entregar ao algoritmo as variáveis realmente relevantes).

Regressão

1. Realizar o **import** dos pacotes necessários e do(s) algoritmo(s)

```
# Import dos módulos
import sklearn as sl
import numpy as np
import pandas as pd
import matplotlib.pyplot as pltfrom sklearn.model_selection
import train_test_split
from sklearn.metrics import r2_score
from sklearn.linear_model import LinearRegression
```

Regressão

2. Carregar o dataset em um Dataframe

```
# leitura dos dados
dfaptos_SP =
pd.read_csv('aptoSP_depoislimpeza.csv', sep = ',',
encoding = 'UTF-8’)

# Carregando os dados
array = dfaptos_SP.values
```

Regressão

3. A partir do **Dataframe**, preparar os dados, definir as entradas e saídas do modelo

```
# Os dados já foram preparados, então, não é necessário
# novo tratamento, porém, geralmente esta etapa é uma
# das mais trabalhosas
# Separando o array em atributos de entrada e saída
X = array[:,1:6]
# seleciona os atributos preditores do 1 ao 5 (exclusivo)
Y = array[:,6] # Atributo alvo (preco)
```

Regressão

4. Amostragem do *dataset*, por exemplo, divisão em treino (65% a 80%) e teste (20% a 35%).

```
# Definindo o tamanho das amostras
teste_size = 0.35
# Garante que os resultados podem ser reproduzidos
# Isso é importante para comparar a métrica com outros
algoritmos de Aprendizado de Máquina.
seed = 7
# Divide os dados em treino e teste
X_train, X_test, Y_train, Y_test = train_test_split(X, Y,
test_size = teste_size, random_state = seed)
```

Regressão

5. Definir a Classe de Modelos a ser empregada e 6) Treinar o Modelo.

```
# Instanciando o modelo

modelo = LinearRegression()


# Treinando o modelo

modelo.fit(X_train, Y_train)
```

Regressão

7. Avaliar o modelo por meio de métricas de avaliação de erro e 8. Prever novos casos. Aplicamos o modelo para novos casos.

```
# R2 explica a variação nos preços dos imóveis
r2 = r2_score(Y_test, Y_pred)
print("O R2 do modelo é:", r2)

# Prever no conjunto de teste
y_pred = model.predict(X_test)
print("Previsões no teste:", y_pred)
```

Bibliografia

BÁSICA:

- AGGARWAL, Charu C. **Artificial Intelligence: A Textbook**. New York: Springer: 2021.
- CHOLLET, François. **Deep Learning with Python, 2ed.** Shelter Island: Manning, 2021.
- GÉRON, Aurélien. **Hands-On Machine Learning with Scikit-Learn and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems**, 2 ed**.** Sebastopol: O'Reilly, 2019.

COMPLEMENTAR:

- GOODFELLOW, Ian; BENGIO, Yoshua, COURVILLE, Aaron. **Deep Learning**. Cambridge: MIT Press, 2016.
- RASCHKA, Sebastian; MIRJALILI, Vahid. **Python Machine Learning**. 3 ed. Birmingham: Packt, 2017.
- RUSSEL, Stuart; NORVIG, Peter. **Artificial Intelligence: A Modern Approach**. 3 ed. Upper Saddle River: Pearson, 2010.
- TAN, Pang-Ning; STEINBACH, Michael; KUMAR, Vipin. **Introduction to Data Mining**. 2 ed. Upper Saddle River: Pearson, 2018.
- VANDERPLAS, Jake. **Python Data Science Handbook**. Sebastopol: O'Reilly, 2017.

ADICIONAIS:

- FACELI, Katti et al. **Inteligência artificial: uma abordagem de aprendizado de máquina**. 2ª Ed. Rio de Janeiro: LTC- Livros Técnicos e Científicos, 2021.
- LUGER, George F. **Inteligência Artificial** - 6ª ed. São Paulo: Pearson Education do Brasil, 2015.
- RUSSELL, Stuart; NORVIG, Peter. **Inteligência artificial: Uma Abordagem Moderna** - 4ª. Ed. GEN LTC, 2022.