Assistente Virtual Acadêmico Baseado em RAG: Uma Abordagem Local com LLMs para Apoio ao Aprendizado

Matteo Porcare[1], Tomy Goldberg Boimel[1], Yuri Milliet[1], Lucas Tuon de Matos[1]

[1]Curso de Ciência da Computação – Faculdade de Computação e Informática (FCI) – Universidade Presbiteriana Mackenzie – São Paulo, SP – Brasil

{10418276, 10417109, 10417884, 10417987}@mackenzista.com.br

Abstract. *This project describes the development of an academic virtual assistant based on Large Language Models (LLMs) and the Retrieval-Augmented Generation (RAG) architecture. The main objective is to facilitate access to information and support student learning by answering questions accurately and contextualized to the teaching materials of the Artificial Intelligence course. To mitigate the problem of hallucinations common in generic models, the system restricts its answers to the provided corpus (teacher's materials and supporting literature). The technical solution involves text extraction, embedding generation, vector indexing using the FAISS library, and the execution of a lightweight, local LLM through Ollama. User interaction occurs through a Streamlit interface. Partial results indicate the technical feasibility of building a secure, functional prototype focused on accuracy and source traceability.*

Resumo. *Este projeto descreve o desenvolvimento de um assistente virtual acadêmico baseado em Large Language Models (LLMs) e na arquitetura Retrieval-Augmented Generation (RAG). O objetivo principal é facilitar o acesso à informação e apoiar o aprendizado dos alunos, respondendo a dúvidas de forma precisa e contextualizada aos materiais didáticos da disciplina de Inteligência Artificial. Para mitigar o problema das alucinações comuns em modelos genéricos, o sistema restringe suas respostas ao corpus fornecido (materiais do professor e literatura de apoio). A solução técnica envolve a extração de textos, geração de embeddings, indexação vetorial utilizando a biblioteca FAISS e a execução de um LLM leve e local através do Ollama. A interação com o usuário ocorre por meio de uma interface em Streamlit. Resultados parciais indicam a viabilidade técnica da construção de um protótipo funcional seguro, focado em precisão e rastreabilidade das fontes.*

1. Resumo

1.a. Contextualização

A popularização dos *Large Language Models* (LLMs) transformou a maneira como os estudantes buscam informações. No entanto, o uso de modelos genéricos no contexto acadêmico apresenta um desafio significativo: as respostas muitas vezes carecem de especificidade em relação ao conteúdo ministrado em sala de aula ou, em casos mais graves, geram "alucinações" (informações incorretas apresentadas como fatos). Nesse cenário, ferramentas que consigam juntar o processamento de linguagem natural das IAs com bases de conhecimento restritas e confiáveis tornam-se essenciais para o apoio pedagógico.

1.b. Justificativa

O desenvolvimento deste assistente virtual justifica-se pela necessidade de fornecer aos alunos respostas precisas, rápidas e estritamente fundamentadas no material da disciplina. A escolha de utilizar LLMs com uma arquitetura de recuperação de informação, garante que a IA não invente respostas, aumentando a confiabilidade do processo. Além disso, a utilização de ferramentas de código aberto e execução local democratiza o acesso a essas tecnologias sem comprometer a privacidade dos dados.

1.c. Objetivo

O objetivo deste projeto é desenvolver um protótipo funcional de um assistente virtual acadêmico capaz de responder a dúvidas de alunos sobre a disciplina de Inteligência Artificial. O sistema deve recuperar trechos relevantes do material didático e gerar respostas contextualizadas, citando a fonte da informação.

1.d. Opção do projeto

A ideia é ter a construção de um pipeline RAG (*Retrieval-Augmented Generation*) focado em um escopo realista e exequível no prazo de dois meses. A arquitetura escolhida inclui o processamento de um *corpus* restrito (PDFs, *slides* e listas de exercícios), o uso da biblioteca FAISS para busca vetorial por similaridade e a execução local de um modelo leve utilizando o Ollama. Esta abordagem prioriza o desenvolvimento de um protótipo funcional eficiente em detrimento de técnicas mais demoradas e custosas, como o *fine-tuning* do modelo. A interface de interação será desenvolvida utilizando o *framework* Streamlit pela sua simplicidade e agilidade.

2. Referencial Teórico

Fundamentação Teórica (Resumida) ou Revisão da Literatura

a. Descrever os conceitos fundamentais, especialmente os relacionados ao uso da Inteligência Artificial no projeto
b. Trabalhos Relacionados: apresentar trabalhos similares ao do projeto proposto e a solução obtida por cada um deles.

2.a. Conceitos Fundamentais

A construção de um assistente virtual acadêmico baseado em recuperação de informação exige a compreensão de uma cadeia de conceitos interligados na ciência da computação:

1. **Inteligência Artificial (IA) e Processamento de Linguagem Natural (PLN):**

A IA abrange sistemas capazes de mimetizar funções cognitivas humanas (RUSSELL; NORVIG, 2020). Dentro da IA, o PLN é a subárea dedicada a dotar os computadores da capacidade de compreender, interpretar e gerar a linguagem humana. É a base fundamental que permite a interação natural entre o aluno e o sistema.

2. ***Large Language Models* (LLMs) e o Problema da Alucinação:**

Os LLMs são a evolução do PLN. Baseados na arquitetura *Transformer* (VASWANI et al., 2017), esses modelos são treinados em volumes massivos de dados textuais para prever a próxima palavra em uma sequência, demonstrando alta capacidade de raciocínio e fluência. Contudo, apresentam uma limitação crítica: as "alucinações", fenômeno onde o modelo gera informações factualmente incorretas ou inventadas com alto grau de confiança (ZHAO et al., 2023).

3. **LLMs na Educação:**

A aplicação de LLMs no ensino oferece oportunidades ímpares para tutoria personalizada e democratização do conhecimento. No entanto, o uso educacional exige precisão factual rigorosa. Modelos genéricos tendem a falhar ao responder perguntas sobre currículos específicos, evidenciando a necessidade de sistemas que restrinjam a IA a bases de conhecimento validadas por docentes (KASNECI et al., 2023).

4. ***Retrieval-Augmented Generation* (RAG):**

Para solucionar a desatualização e as alucinações dos LLMs, Lewis et al. (2020) formalizaram a arquitetura RAG. Em vez de depender apenas do conhecimento internalizado durante o treinamento (memória paramétrica), o RAG adiciona uma etapa de "recuperação" (memória não paramétrica). O sistema primeiro busca a resposta em uma base de documentos confiáveis (o *corpus* da disciplina) e, em seguida, instrui o LLM a formular a resposta utilizando *exclusivamente* o texto recuperado.

5. **Segmentação de Texto (*Chunking*):**

Para que a recuperação no RAG seja eficiente, os documentos (PDFs e *slides*) não podem ser processados inteiros de uma só vez devido ao limite de janela de contexto dos LLMs. O *chunking* é o processo fundamental de dividir o texto em fragmentos menores e semanticamente coesos, permitindo que a busca encontre a agulha no palheiro de forma precisa.

6. ***Embeddings* e Busca Vetorial:**

Para que o computador consiga comparar a pergunta do aluno com os *chunks* de texto, ambos precisam ser convertidos em *embeddings* (vetores numéricos densos que representam o significado semântico das palavras). Textos com significados semelhantes terão vetores próximos no espaço multidimensional. A busca por essa similaridade é realizada por bibliotecas de indexação de alta performance, destacando-se o FAISS (*Facebook AI Similarity Search*), que permite encontrar rapidamente os trechos mais relevantes para fundamentar a resposta da IA (JOHNSON; DOUZE; JÉGOU, 2019).

7. **2.b. Trabalhos Relacionados**

A aplicação da arquitetura RAG (*Retrieval-Augmented Generation*) para a criação de assistentes de ensino tem sido amplamente documentada na literatura recente, comprovando ser a solução mais eficaz para o problema da alucinação no contexto educacional.

8. **2.b.1. Assistentes Baseados em Modelos Locais:**

Um estudo recente publicado pela MDPI (2024) descreveu o desenvolvimento de um Assistente de Ensino de IA Generativa Local, com uma arquitetura muito similar à proposta neste projeto. Os autores utilizaram RAG, bancos de dados vetoriais e LLMs *open-source* rodando localmente para processar PDFs de disciplinas. A solução obtida garantiu a privacidade dos dados da universidade e atingiu uma taxa de precisão de respostas de 86%, demonstrando a viabilidade técnica de sistemas restritos e executados localmente para apoiar alunos em campi universitários.

9. **2.b.2. Percepção e Aceitação Docente:**

Em outro estudo relevante, Kumar et al. (2024) implementaram aplicações RAG para atuar como assistentes virtuais de ensino em disciplinas de Ciência da Computação no Ensino Superior. A solução desenvolvida substituiu a restrição total de IAs genéricas na sala de aula por uma abordagem "protegida" (ancorada nos materiais do professor). Os resultados obtidos revelaram que o uso do RAG foi amplamente aceito pelo corpo docente justamente por sua capacidade de manter as respostas dentro do escopo do curso, mitigando a geração de respostas falsas ou fora do contexto pedagógico esperado.

10. **2.b.3. CS50 em Harvard:**

Destaca-se também a implementação pioneira do *CS50 Bot* na Universidade de Harvard (LIU et al., 2024). A equipe utilizou uma infraestrutura similar ao RAG para fornecer tutoria aos alunos de programação. A solução obtida não dava a resposta direta aos problemas, mas guiava o raciocínio do

aluno com base nos materiais e *scripts* de aula. A avaliação empírica validou que a abordagem reduziu a sobrecarga dos monitores humanos e melhorou significativamente o tempo de resolução de dúvidas.

A análise desses trabalhos comprova que a substituição de LLMs puros por *pipelines* RAG integrados a conteúdos específicos da disciplina é o atual estado da arte para tecnologias de apoio ao aprendizado.

3. Metodologia e Resultados Esperados

Metodologia e Resultados Esperados:

a. apresentar a abordagem que pretende empregar na resolução do problema, suas etapas e quais são os resultados esperados.
b. *Dataset*, se for o caso (anonimizados quando necessário), descrição detalhada do seu conteúdo/origem, análise exploratória e preparação dos dados.

3.a. Abordagem, etapas e resultados esperados

A presente pesquisa adota uma abordagem aplicada e exploratória, visando a construção de um protótipo de software funcional para a resolução de um problema no ambiente educacional. O ciclo de desenvolvimento do sistema será conduzido seguindo um fluxo de trabalho estruturado nas seguintes etapas:

1. **Recorte e Curadoria de Conteúdo:**

   Delimitação do domínio de conhecimento para a disciplina de "Inteligência Artificial". Será reunido um *corpus* restrito contendo apostilas, *slides* em PDF e listas de exercícios fornecidos pelo professor da disciplina. Como base de apoio, poderão ser usado alguns conteúdos abertos do repositório MIT OpenCourseWare (https://ocw.mit.edu).

2. **Processamento e Organização Estrutural:**

   Os documentos coletados passarão por um processo de extração de texto (*parsing*), onde ruídos de formatação serão removidos. O conteúdo limpo será categorizado hierarquicamente por aulas, tópicos e subtópicos.

3. **Segmentação (*Chunking*) e Indexação:**

   O texto processado será dividido em trechos curtos (*chunks*), preservando a coesão semântica e recebendo metadados de identificação (ex: "Aula 5, Slide 10"). Em seguida, um modelo *open-source* será utilizado para converter esses trechos em *embeddings* (vetores densos), os quais serão indexados utilizando a biblioteca FAISS, otimizada para busca rápida de similaridade.

4. **Construção do Pipeline RAG e Execução Local:**

Implementação do fluxo de recuperação e geração. A pergunta do aluno servirá como vetor de busca no FAISS para recuperar os *chunks* mais relevantes. Esse contexto será enviado a um *Large Language Model* (LLM) leve, executado localmente na máquina através da ferramenta Ollama. Para evitar alucinações, o modelo receberá um *prompt* sistêmico com regras de segurança estritas, obrigando-o a responder exclusivamente com base no contexto injetado e a citar a fonte da informação. O foco será na orquestração (RAG), descartando técnicas custosas como o *fine-tuning*.

5. **Desenvolvimento de Interface:**

   Criação de uma interface *web* simples e interativa utilizando o *framework* Streamlit em Python. A interface permitirá que o aluno digite sua pergunta e visualize a resposta gerada juntamente com a fonte consultada.

6. **Validação do Protótipo:**

   A etapa final consistirá na validação empírica do sistema através de uma bateria de testes com 15 a 30 perguntas reais formuladas por alunos. Serão medidas qualitativa e quantitativamente: (i) a precisão percebida das respostas, (ii) a utilidade pedagógica e (iii) a taxa de abstenção (capacidade do modelo de não responder quando não houver evidência suficiente no material).

3.b Resultados Esperados:

Espera-se obter um protótipo de assistente virtual totalmente funcional, executado localmente. O sistema deverá demonstrar a viabilidade de responder perguntas objetivas de forma precisa, sem inventar fatos, e sempre rastreando a informação até o material base original fornecido pelo professor, apoiando o processo de ensino-aprendizagem de forma segura e ética.

3.c. Dataset

O conjunto de dados (*dataset*) que fundamentará a base de conhecimento do assistente virtual será constituído exclusivamente por materiais didáticos da disciplina de Inteligência Artificial.

1. **Conteúdo e Origem:**

   O *corpus* é formado por arquivos em formato PDF, englobando *slides* de aulas teóricas, listas de exercícios práticas e apostilas redigidas pelo docente responsável. Visando a complementariedade, também poderão ser incorporadas notas de aula de introdução à Inteligência Artificial do repositório público MIT OpenCourseWare.

2. **Análise Exploratória e Preparação de Dados:**

Todo o processo de preparação será conduzido através de *scripts* em Python, documentados em Jupyter Notebooks. A análise exploratória envolverá a contagem e distribuição de *tokens* por documento e por tipo de material. Essa análise é crucial para definir o tamanho da janela de segmentação (*chunk size*) e a taxa de sobreposição (*overlap*), garantindo que os parágrafos não sejam cortados abruptamente no meio de um conceito importante.

3. **Tratamento e Anonimização:**

Durante a limpeza, quaisquer dados sensíveis ou pessoais (como nomes de alunos em fóruns de dúvidas, caso exportados) serão sumariamente removidos ou anonimizados. Cabeçalhos de página e numerações repetitivas serão tratados para não poluir o cálculo de similaridade vetorial. Os *scripts* de análise exploratória conterão, conforme normatizado, cabeçalhos de identificação do grupo, síntese do conteúdo e histórico de alterações detalhado.

4. Resultados Parciais

7) Resultados Parciais
   a. Discussão a respeito dos aspectos Éticos do uso da IA e a sua Responsabilidade no desenvolvimento da solução;
   b. Detalhamento dos resultados parciais obtidos até o momento;
   c. Endereço GitHub criado contendo o descrito a seguir.

4.a. Discussão sobre Aspectos Éticos e Responsabilidade:

O desenvolvimento e a implementação de Inteligência Artificial no ambiente educacional exigem rigorosa cautela com princípios éticos. O uso de *Large Language Models* (LLMs) genéricos pode expor os alunos a vieses e desinformação (alucinações). Diante disso, a responsabilidade no desenvolvimento desta solução norteou duas decisões cruciais do projeto:

1. **Privacidade e Proteção de Dados:**

A adoção do Ollama para execução local do LLM garante que nenhuma pergunta dos alunos ou material intelectual do professor seja enviado para servidores de empresas terceiras (como OpenAI ou Google). Os dados permanecem restritos ao ambiente da aplicação.

2. **Transparência e Combate à Desinformação:**

Do ponto de vista ético, é inaceitável que um assistente acadêmico forneça informações incorretas com tom de autoridade. O uso do pipeline RAG atua como um mecanismo de responsabilização Ao obrigar a IA a citar a fonte exata (ex: "Slide 5, Aula 2"), o sistema transfere a auditoria para o aluno, garantindo transparência e mitigando drasticamente o risco de o estudante ser prejudicado por informações inventadas.

4.b. Detalhamento dos Resultados Parciais Obtidos Até o presente momento do cronograma, os esforços do grupo concentraram-se na estruturação fundacional, planejamento arquitetônico e configuração do ambiente, obtendo-se os seguintes resultados parciais:

1. **Definição e Curadoria do *Dataset*:**

   Foram selecionados materiais-base da disciplina de Inteligência Artificial, incluindo os PDFs e slides do professor.

2. **Configuração do Ambiente de Desenvolvimento:**

   O ambiente local não foi estabelecido ao total ainda, mas ja está contemplando a instalação da biblioteca em Python (Pandas) e a instalação do Anaconda (Jupyter Notebook). Ainda falta a configuração do motor Ollama para a execução de modelos *open-source*.

3. **Estruturação do Repositório e Análise Exploratória Inicial:**

   O repositório no GitHub foi criado e estruturado de acordo com as exigências da disciplina. Os *scripts* iniciais de leitura de PDFs para a futura etapa de *chunking* foram esboçados no formato Jupyter Notebook.

Esses resultados parciais comprovam a viabilidade técnica do projeto e preparam o terreno para a próxima fase: leitura, etapa de chunking, a geração dos *embeddings* e a integração da interface Streamlit com o modelo de linguagem.

4.c. Endereço GitHub O repositório público contendo todos os artefatos do projeto está disponível no seguinte endereço:

https://github.com/LucasTuon/Trabalho-Inteligencia-Artificial

Conforme as diretrizes do projeto, o repositório apresenta a seguinte estrutura de arquivos:

1. O Relatório do Projeto (este documento);
2. O *Dataset* utilizado contendo sua respectiva descrição;
3. O código Python (*Jupyter Notebooks*) referentes à análise exploratória e estruturação dos dados;

5. Referências

JOHNSON, J.; DOUZE, A.; JÉGOU, H. Billion-scale similarity search with GPUs. **IEEE Transactions on Big Data**, v. 7, n. 3, p. 535-547, 2019.

KASNECI, E. et al. ChatGPT for good? On opportunities and challenges of large language models for education. **Learning and Individual Differences**, v. 103, p. 102274, 2023.

LEWIS, P. et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. Em: **Advances in Neural Information Processing Systems (NeurIPS)**, v. 33, p. 9459-9474, 2020.

RUSSELL, S.; NORVIG, P. **Artificial Intelligence: A Modern Approach**. 4. ed. Pearson, 2020.

VASWANI, A. et al. Attention is all you need. Em: **Advances in Neural Information Processing Systems (NIPS)**, v. 30, 2017.

ZHAO, W. X. et al. A Survey of Large Language Models. **arXiv preprint** arXiv:2303.18223, 2023. Disponível em: https://arxiv.org/abs/2303.18223.

KUMAR, A. et al. Faculty Perspectives on the Potential of RAG in Computer Science Higher Education. **arXiv preprint** arXiv:2408.01462, 2024. Disponível em: https://arxiv.org/abs/2408.01462.

LIU, R. et al. Teaching CS50 with AI: Leveraging Large Language Models for Education. Em: **Proceedings of the 55th ACM Technical Symposium on Computer Science Education (SIGCSE)**, 2024.

MDPI. Developing a Local Generative AI Teaching Assistant System: Utilizing Retrieval-Augmented Generation Technology to Enhance the Campus Learning Environment. **Electronics**, v. 14, n. 17, 2024. Disponível em: https://www.mdpi.com/2079-9292/14/17/3402.